Bases de Dados

Módulo 1: Introdução aos banco de dados

Prof. André Bruno de Oliveira

Data 28/02/2024

Introdução a Bancos de Dados

Tópicos

- **Apresentação do Curso**
  - Objetivos
  - Ementa
  - Critério de Avaliação
- **Introdução a banco de dados**
  - O que é banco de dados?
  - Sistemas Gerenciadores de dados: Visão Geral
    - Relacional;
    - NoSQL e Hadoop;
    - Data lake e Data Ware House
    - Escalabilidade
- Software Utilizados no curso
- Bibliografia

Objetivos da Disciplina

- **Objetivo:** Fornecer aos alunos conhecimentos básicos para manipulação e tratamento de bases de dados.
- **Metas**: Habilitar o aluno a **projetar**, **construir**, **atualizar** e **consultar** BD.
  - **Ênfase** especial é dada aos **SGBDs relacionais**, tecnologia predominante no mercado.

Ementa

- SGBD Relacionais,
- Arquitetura e Terminologia;
- Integridade;
- Pesquisa;
- Álgebra Relacional;
- Modelagem de Dados;
- Normalização;
- Padrão SQL;
- SGBDs NoSQL;
- Bancos de Dados Analíticos.

Objetivos da Disciplina

- Tornar o aluno proficiente em **SQL**(*Structured Query Language)*
  - Trata-se da **linguagem padrão** para manipular SGBDs relacionais.
  - O curso prioriza a utilização da SQL para **explorar** e **combinar** bases de dados, além de outras tarefas relacionadas à **Ciência de Dados**.

Material de Estudo

Notas de Aula* e **Listas de Exercícios**

- Serão sempre disponibilizadas na minha pasta no site **https://aulasence.ibge.gov.br/**
- ***OBS**: as notas de aula foram criadas com base no conteúdo dos livros a seguir:

Critério de avaliação

- VAE1 - 03/05
- VAE2 – 28/06
- Listas de exercícios, resumos, trabalhos
- Nota final = (VAE1+VA2)/2 + 1* aproveitamento nos trabalhos (ex.: 1 equivale a 100% de aproveitamento, 0,8 equivale 80%).
- FINAL – 09/07

- Para tirar dúvidas envie mensagens preferencialmente pelo teams.
  - Basta ir no chat e procurar menu nome (André Bruno de Oliveira)
  - email: andrebruno.ence@gmail.com

Material de Estudo

Projeto de banco de dados [recurso eletrônico] / Carlos

Alberto Heuser. – 6. ed. – Dados eletrônicos. – Porto Alegre :

Bookman, 2009.

Fundamentals ofDatabaseSystems, 7thEdition

Ramez Elmasri& ShamkantB. Navathe

Pearson, 2016.

DatabaseSystems: The Complete Book, 2ndEdition

Hector Garcia-Molina, Jeffrey D. Ullman& Jennifer Widom

Pearson, 2009.

NoSQLDistilled

Sadalage, P. J. & Fowler, M.

Addison-Wesley, 2012.

Introdução

O termo banco de dados (do original *database*) é tão utilizado que precisamos começar por sua definição.

Banco de dados (BD) é uma coleção de dados relacionados.

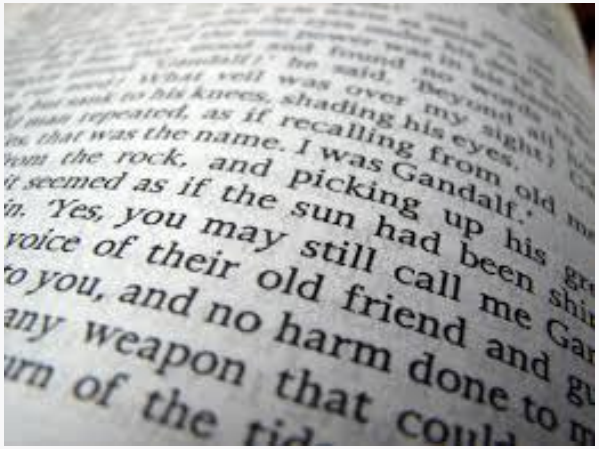

Esta é uma definição bastante genérica, por exemplo, a coleção de palavras que compõe uma página de livro pode ser considerada como dados relacionados? Quando nos referimos à banco de dados é preciso compreender que estamos nos referindo a algo mais específico.

Introdução

Os bancos de dados e sua tecnologia têm um impacto importante sobre diversas áreas em que os computadores são usados, incluindo negócios, comércio eletrônico, engenharia, medicina, genética, direito, educação e biblioteconomia e etc.

BD é uma tecnologia importante que contribui para formar uma base de tomada de decisão.

O Que é um BD?

- Um banco de dados representa algum aspecto do mundo real, às vezes chamado de minimundo ou de universo do discurso. Mudanças no minimundo precisam ser refletidas no banco de dados em um espaço tempo o mais breve possível para manter boa precisão e confiança.

Imagem do Minimundo em Gramado

O Que é um BD?

- Um BD é uma coleção logicamente coerente de dados com algum significado inerente. Uma variedade aleatória de dados não pode ser corretamente chamada de BD.

$\neq$ Aleatório

O Que é um BD?

- É projetado e construído com dados para um propósito específico.

O Que é um BD? Aplicações com objetivo

- Possui um grupo definido de usuários e algumas aplicações previamente concebidas nas quais esses usuários estão interessados.

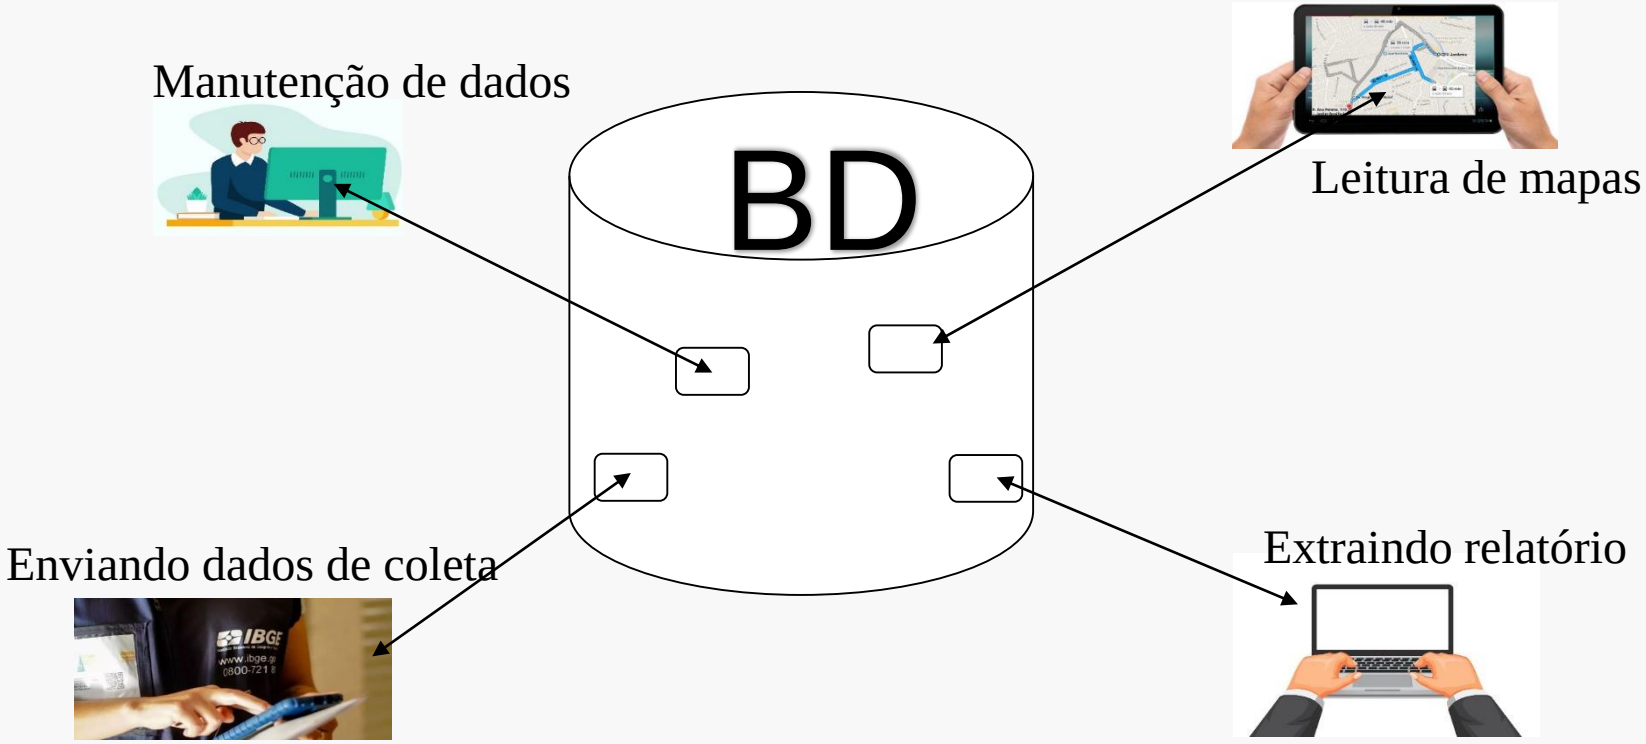

O Que é um BD?

- BD centraliza as informações de modo que seus dados sejam mantidos e recuperados por seus usuários para produzir informações relevantes.

O Que é um BD? Tem um grupo usuários

- Quem são os Usuários? São pessoas que podem ler, inserir, atualizar e excluir informações.
- O que são dados? São fatos conhecidos que podem ser registráveis e possuem um significado implícito (nome, número de telefone, endereços).

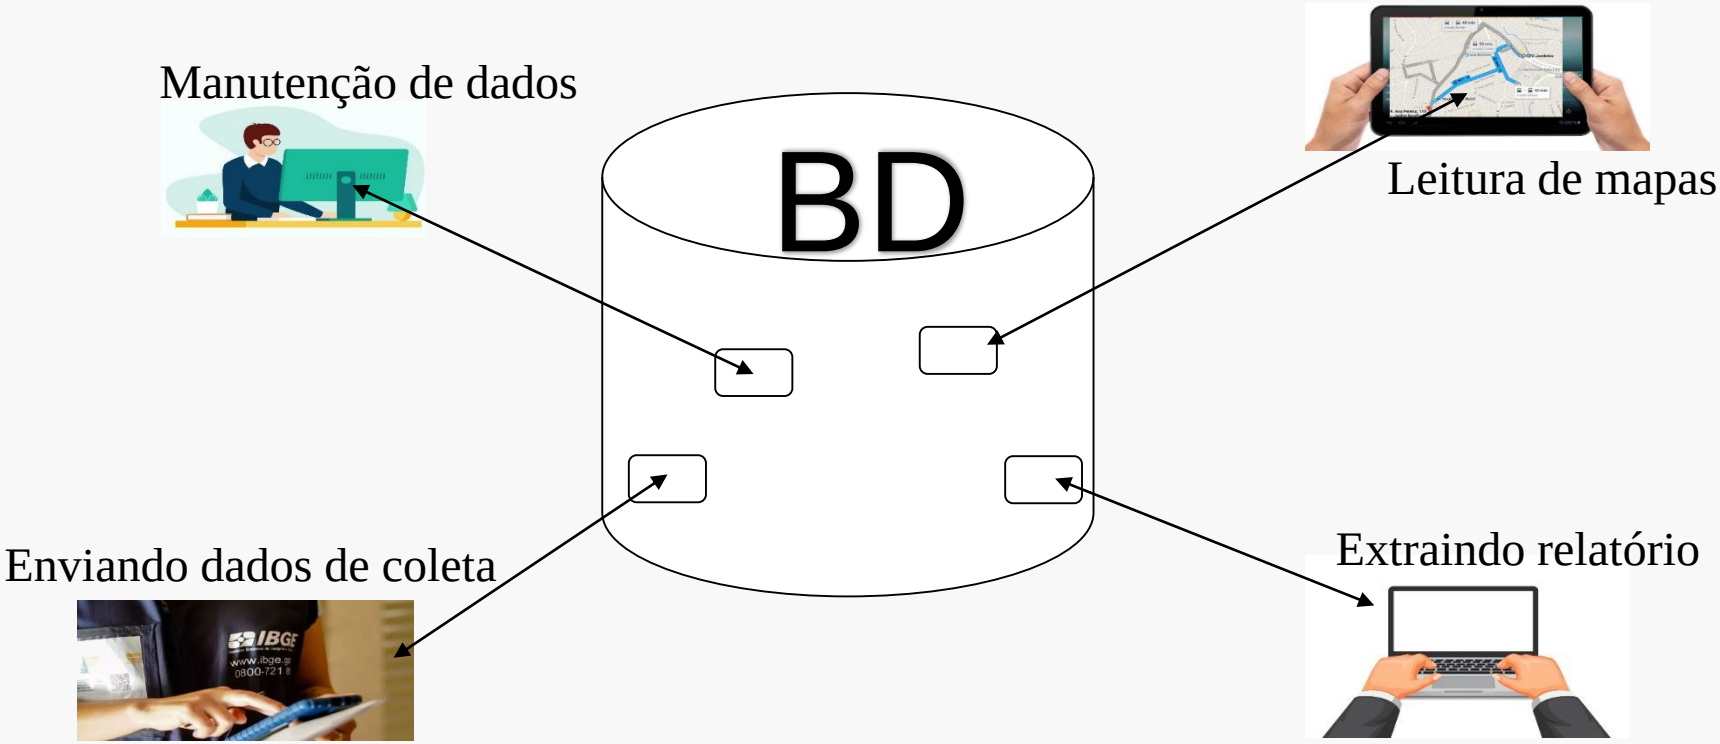

O Que é um BD? Tem um propósito

- Manter dados e informações.
- O que são informações? São dados tratados e analisados que costumam servir de balizamento no processo de decisão.
  - Exemplo: Pesquisa Nacional de Saúde do Escolar. Coleta dados de adolescentes em escolas públicas e privadas. **A análise dos dados trouxe a seguinte informação**: Dobrou o percentual de escolares que faltaram ao menos um dia às aulas por não se sentirem seguros no trajeto ou na escola: de 8,6% em 2009 subiu para 17,3% em 2019. (Fonte: https://agenciadenoticias.ibge.gov.br/agencia-noticias/2012-agencia-de-noticias/noticias/34340-ibge-divulga-uma-decada-de-informacoes-sobre-a-saude-dos-escolares)

Como BD são usados?

- As interações com os BD ocorrem de diversas maneiras no mundo atual.

Página de busca

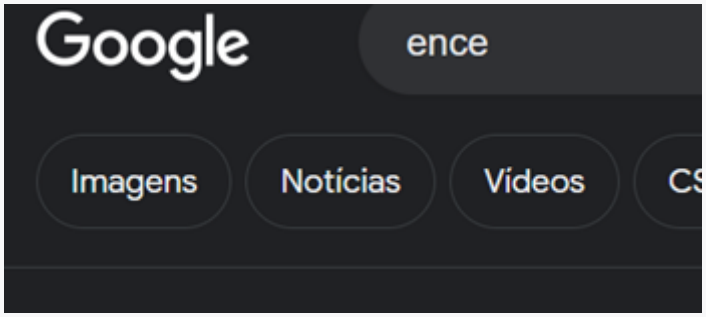

Rede social

Repositório de vídeos

Como BD são usados?

- A utilização de página de busca na internet faz uso de informações mantidas em banco de dados. A Google usa informações de sites para montar suas bases de dados.
- Por exemplo: O Youtube, criado em 2005, é uma solução que permitir os usuários criarem, compartilharem e assistirem vídeos (Fonte: https://brasilescola.uol.com.br/informatica/youtube.htm).

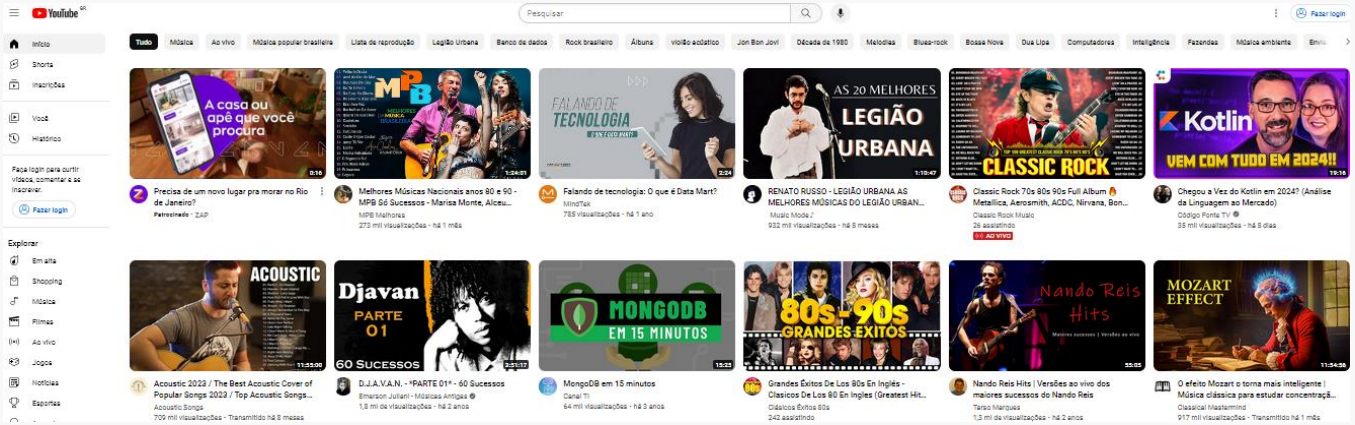

Como BD são usados?

- A realização de transações bancárias seja pela internet, no caixa eletrônico ou através do atendente são mantidas em banco de dados para controle e análises.
  - Por exemplo: Em 2021 a cada 10 operações realizadas, 7 são feitas através de Internet bank ou aplicativo (Fonte: https://www.poder360.com.br/economia/7-em-cada-10-transacoes-nos-bancos-sao-feitas-de-forma-digital/#:~:text=A%20cada%2010%20opera%C3%A7%C3%B5es%20realizadas,Representam%2056%25%20do%20total).

Como BD são usados?

- Quase todo site de internet visitado por você usa um banco de dados seja para manter a informações exibidas ou para coletar dados de seus usuários.

Para que serve Banco de dados?

- Um banco de dados serve, justamente, para que as informações possam ser registradas e armazenadas de maneira segura, organizada e padronizada.

Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados?

- Imagine um hospital que possuía **todos os seus registros de pacientes** armazenados em uma imensa sala repleta de papéis e formulários guardados em arquivos. O acesso aos documentos exige presença física.

INFORMAÇÕES DOS PACIENTES

Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados?

- Com o advento dos computadores, **todos estes documentos dos pacientes foram digitalizados e armazenados em HD**, seja em formato de planilhas ou em registros de imagens.

DADOS DO MUNDO REAL

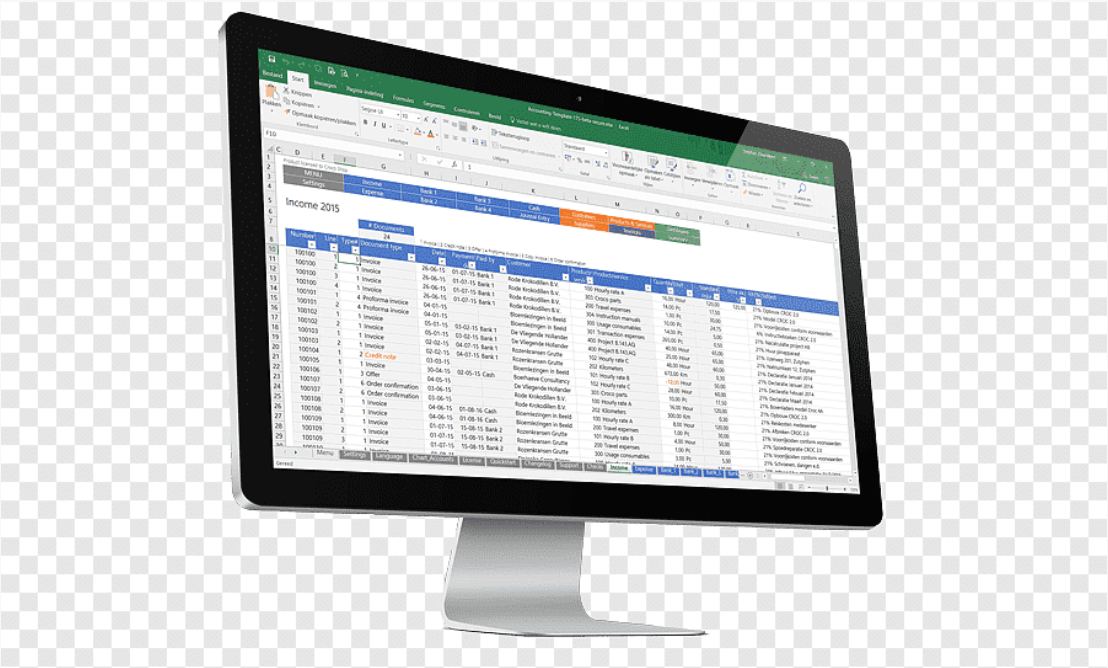

- Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados ?

- Conforme o número de pacientes e dados a serem armazenados crescia, a administração destes dados em computadores com arquivos (planilhas) e pastas (diretórios) se tornou difícil, pois manipular estes arquivos dava cada vez mais trabalho.

INTERESSE NOS DADOS

Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados ?

- Os arquivos foram migrados para um modelo de banco de dados tradicional com linhas e colunas, as imagens foram organizadas em pastas e foi construído uma solução de *software* para atender cada setor: setor de triagem, marcação de consultas, exames e diagnóstico, etc.

ABORDAGEM CLÁSSICA

Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados?

- Houve uma época que as informações eram mantidas em arquivos espalhados na forma de tabelas, banco de dados simples (DBF, MDB).

DADOS DO MUNDO REAL

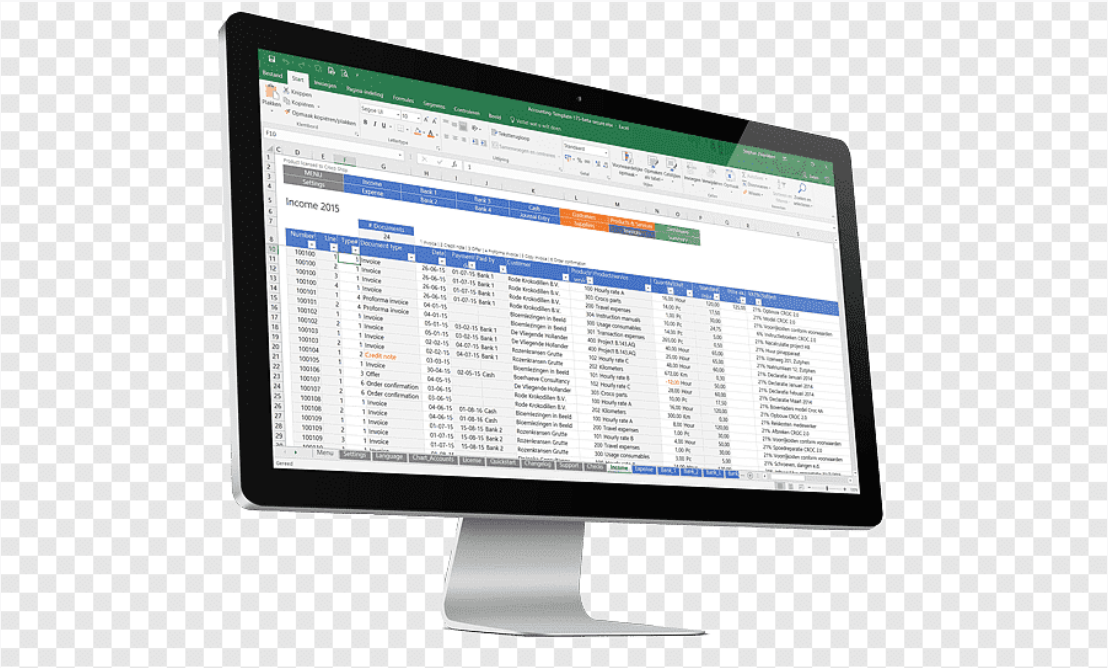

- Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados ?

- Cada setor mantinha um conjunto de dados de acordo com a sua necessidade e todos tinham os dados pessoais dos clientes (redundância). Só que com o tempo manter este cadastro dos clientes atualizado e seguro em todos os computadores passou a ser um problema.

EVOLUÇÃO

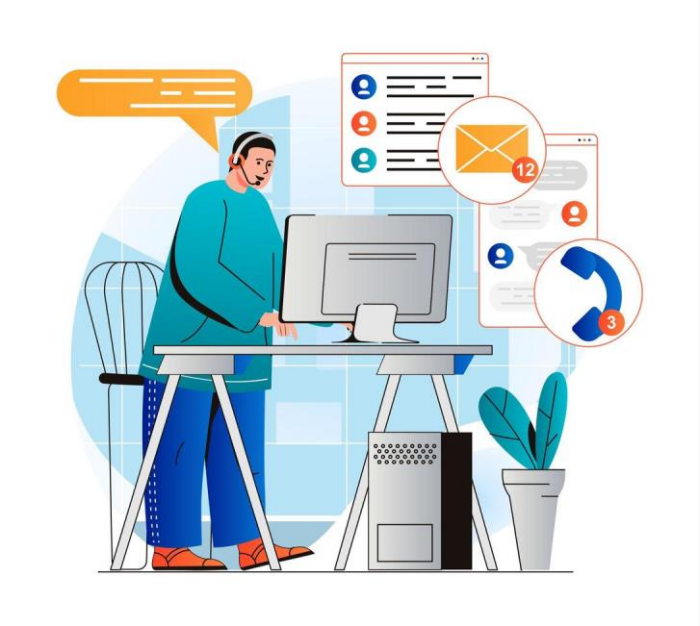

Fonte: https://kenzie.com.br/blog/banco-de-dados/

Para que serve Banco de dados ?

- Os programadores precisavam implementar técnicas complicadas para otimizar as buscas e resolver as atualizações em diversos computadores. Além disso, os dados da triagem de pacientes ficavam no setor de recepção ou num local próximo sem segurança adequada.

ÁRVORE B+

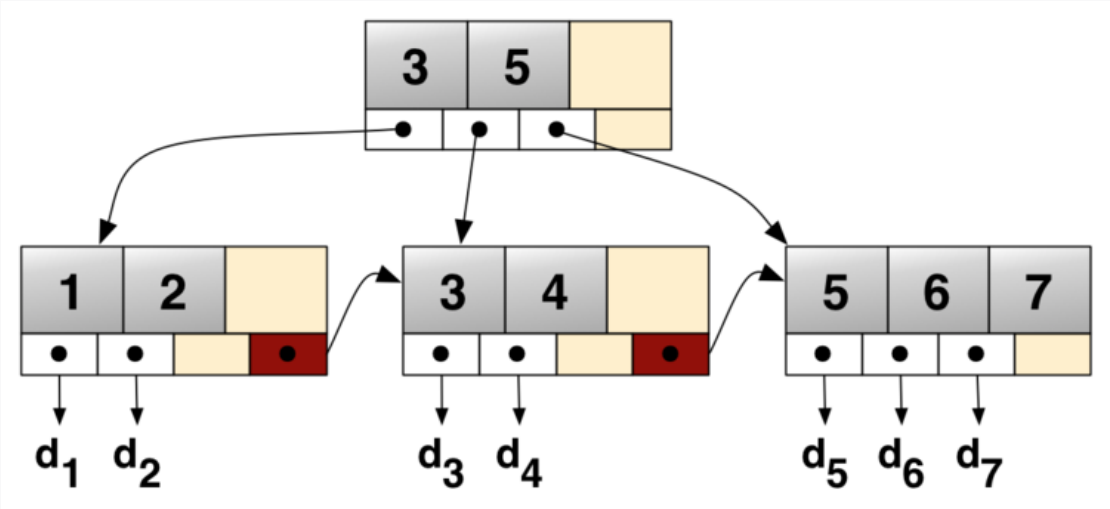

Para que serve Banco de dados ?

- Houve a necessidade de incluir uma nova variável referente ao paciente e aumento do tamanho da variável para descrever sobre o histórico de saúde do paciente. Isso exigiu mexer no código dos programas que gerenciava os bancos de dados e replicar estas mudanças em outros computadores.

ABORDAGEM CLÁSSICA

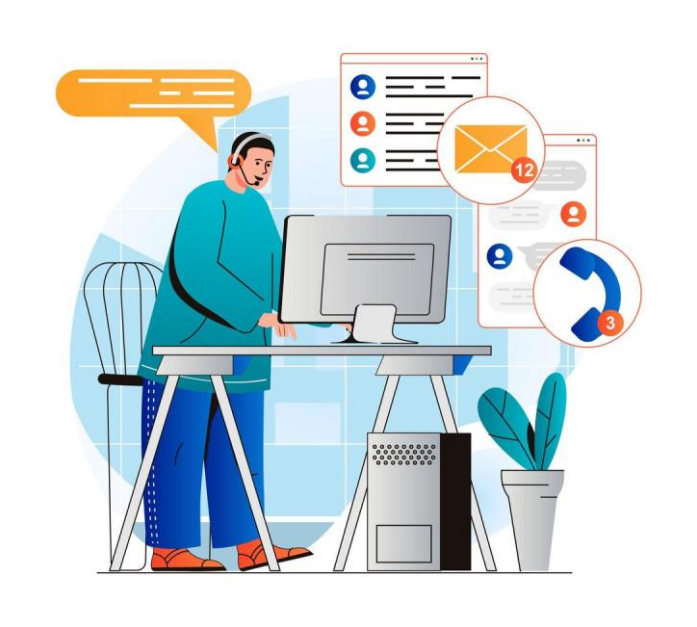

Para que serve Banco de dados ?

- Houve uma curto-circuito no hospital e um dos computadores queimou, justamente o computador que mantinha o banco de dados de exames e o sistema de exames. Sem um recurso automatizado para recuperar o backup e restaurar o funcionamento do sistema houve um transtorno maior.

Para que serve um SGBD?

- A solução para mitigar este tipo de problema foi a adoção de um sistema gerenciador de banco de dados (**SGBD**), pois ele permite gerenciar vários BD de modo centralizado.

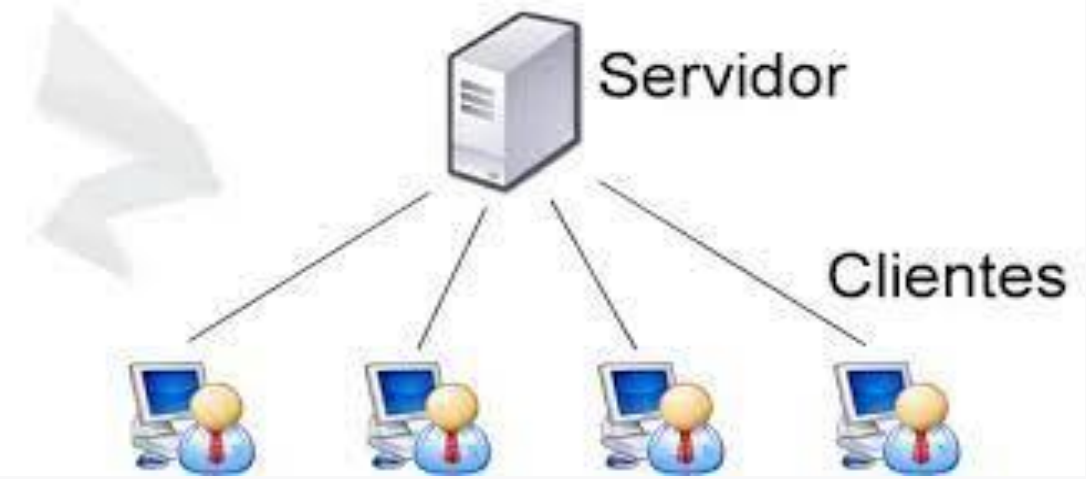

Médico Paciente Enfermeiro Atendente

Médico – atualizando o diagnóstico
Paciente – acessando resultado de exames
Enfermeiro – Atualizando situação dos pacientes
Atendente – Agenda consultas e exames

O QUE É UM SGBD ?

- ***Database Management System*** **-** Sistema gerenciador de banco de dados.
- É um sistema de *software* (coleção de programas) de uso geral que facilita o processo de definir, construir, manipular e compartilhar BD com múltiplos usuários e aplicativos (SIMPLIFICA AS INTERAÇÕES).

Para que serve um SGBD?

- A implantação do Sistema gerenciador de banco de dados (**SGBD**) trouxa algumas **facilidades**:
  - As informações agora podem ser manuseadas (consultadas e atualizadas) por diferentes profissionais de saúde de acordo com a regras de acesso;
  - Há aumentando da segurança com acessos controlados por perfis;
  - Os SGBD combinados com a tecnologia de rede permitiram que os BD fiquem em locais seguros. O sistema cliente servidor possibilitou uma separação entre camadas, o usuário usa um sistema e busca as informações sem que o usuário se preocupe como isso será feito.

Para que serve um SGBD?

- A implantação do Sistema gerenciador de banco de dados (**SGBD**) trouxa algumas **facilidades**:
  - Proporcionou aumento do volume de informações e as técnicas de busca deixaram de ser responsabilidade dos programas;
  - Eliminou as redundância e reduziu-se o risco de inconsistências (as informações comuns dos pacientes em diversos programas são as mesmas, pois o acesso é centralizado).
  - As mudanças nas variáveis ficaram centralizadas, eliminando o risco de ter um campo do histórico do paciente que aceita até 500 caracteres e em outro computador aceita até 5 mil;
  - A capacidade de fazer backup e restaurar as informações melhorou;

Tecnologia para manter e explorar dados

- O hospital fez uma parceira com uma universidade. Os dados dos exames dos pacientes desidentificados passaram a ser importados para um solução tecnológica de **BD relacional** com a finalidade de analisar e encontrar padrões que pudessem ajudar no diagnóstico dos pacientes (tomada).

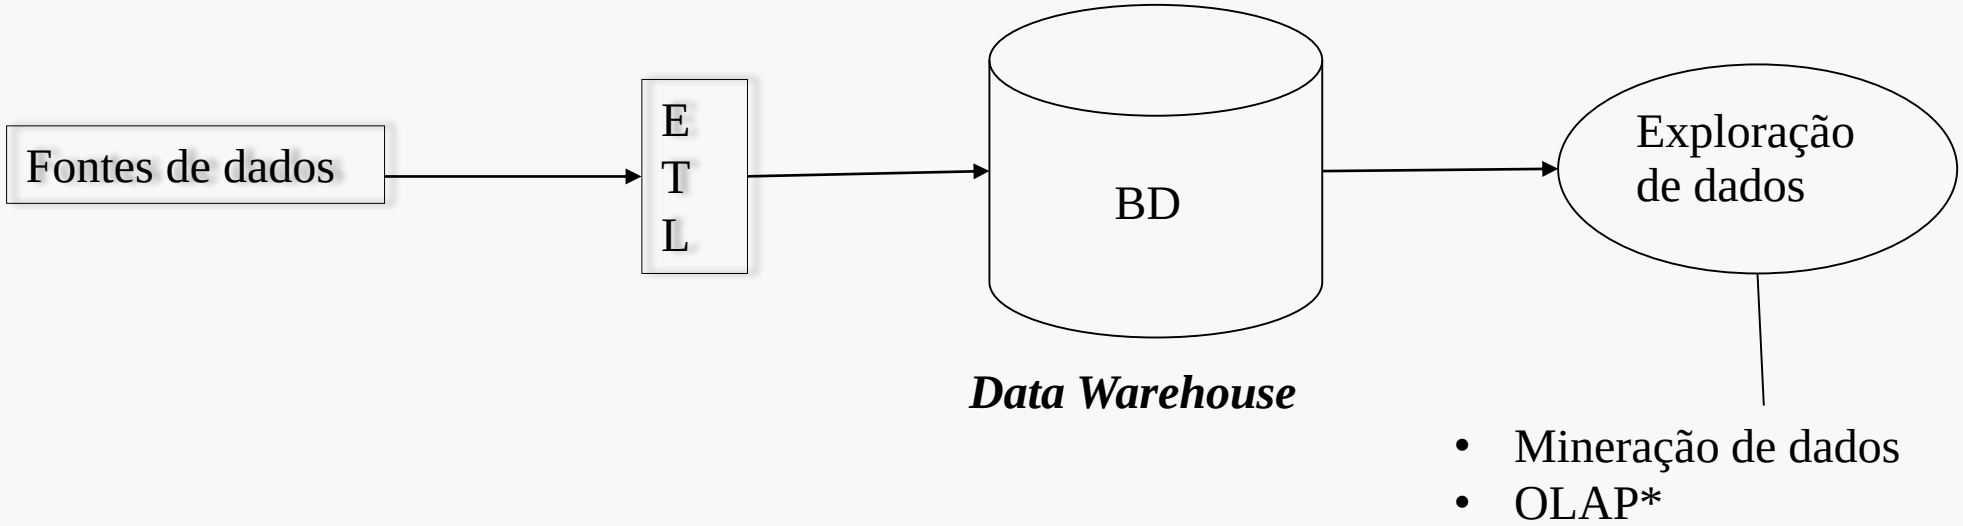

Tecnologia para manter e explorar dados

- A universidade com a finalidade de avaliar diversas informações de pacientes de uma forma otimizada adotou uma solução analítica onde os dados passam por uma etapa de extração (**E**xtract), transformação (**T**ransform) e carga (**L**oad) (ETL) até serem sumarizados no BD relacional adotado.

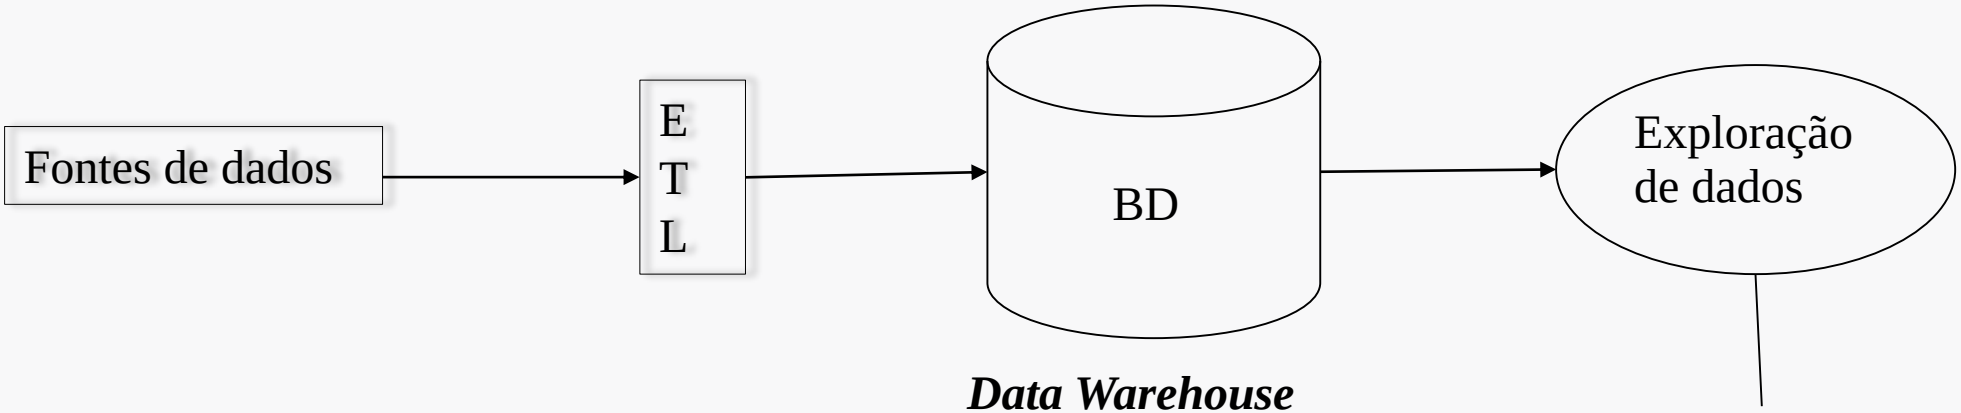

Data Warehouse

- Mineração de dados
- OLAP*

Tecnologia para manter e explorar dados

- Uma equipe de alunos modelou a estrutura de armazenamento do BD como uma espécie de armazém de dados organizadas por assuntos (*Data Warehouse*) como doenças infecciosas, neoplasias, digestivas, etc. Cada um destes assuntos é conhecido como *Data Mart*.

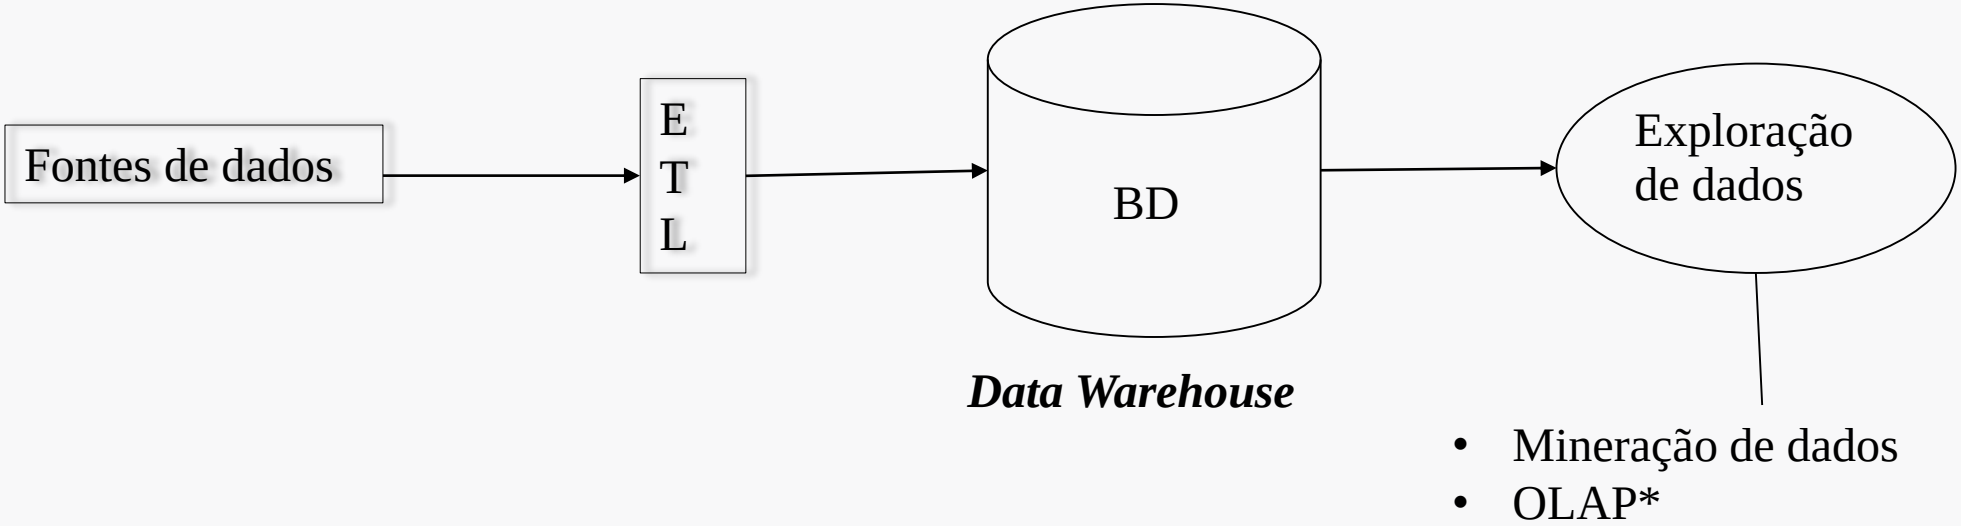

Tecnologia para manter e explorar dados

- Uma segunda equipe de alunos ficou responsável pela exploração dos dados para detectar padrões associados às doenças ou ao nível de saúde, adotando para isso técnicas de mineração de dados (*Data mining*).

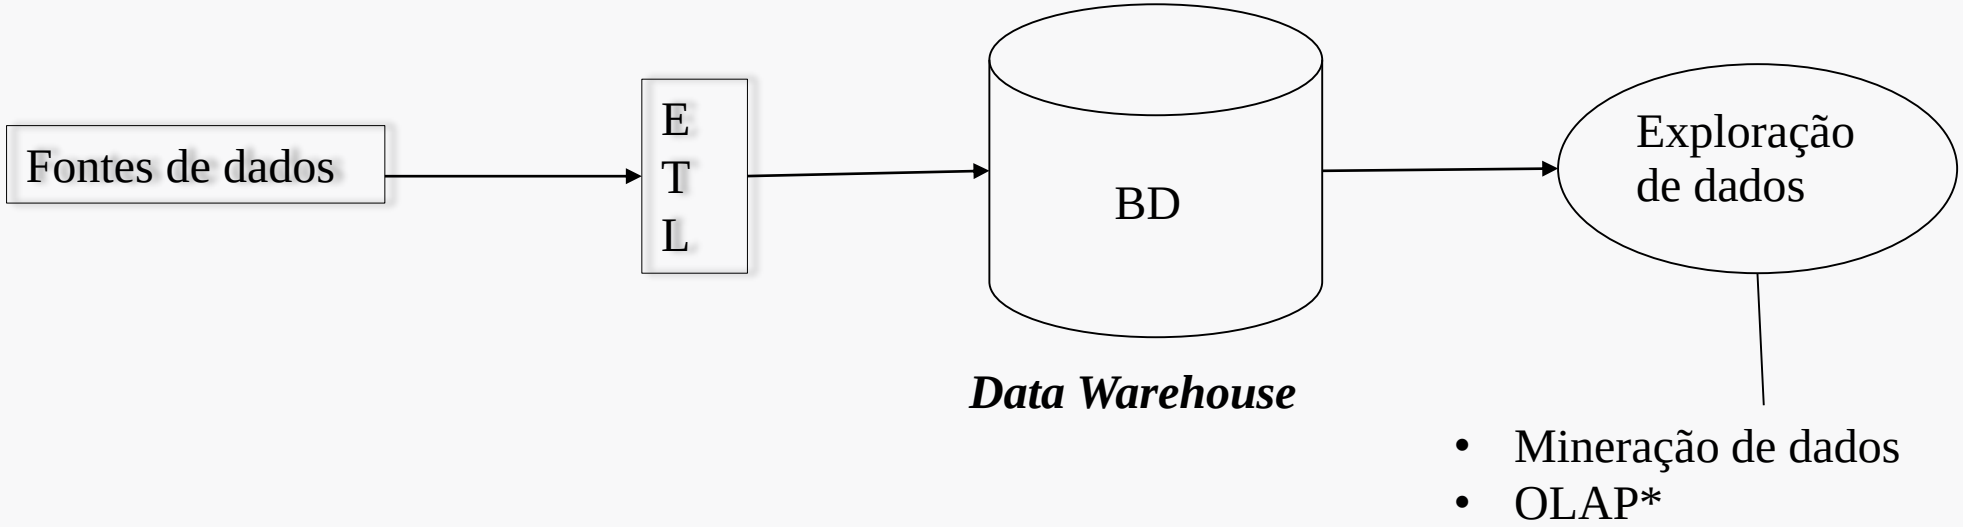

Tecnologia para manter e explorar dados

- Uma terceira equipe utilizou uma ferramenta *OLAP* (*Online Analytical Processing*) proprietária com a capacidade de extrair um grande volume de informações sob múltiplas perspectivas para aplicar análises descritivas (gráficos e tabelas) na busca de padrões com a finalidade de descrever o perfil dos pacientes que tem risco aumento para por grupo de enfermidades.

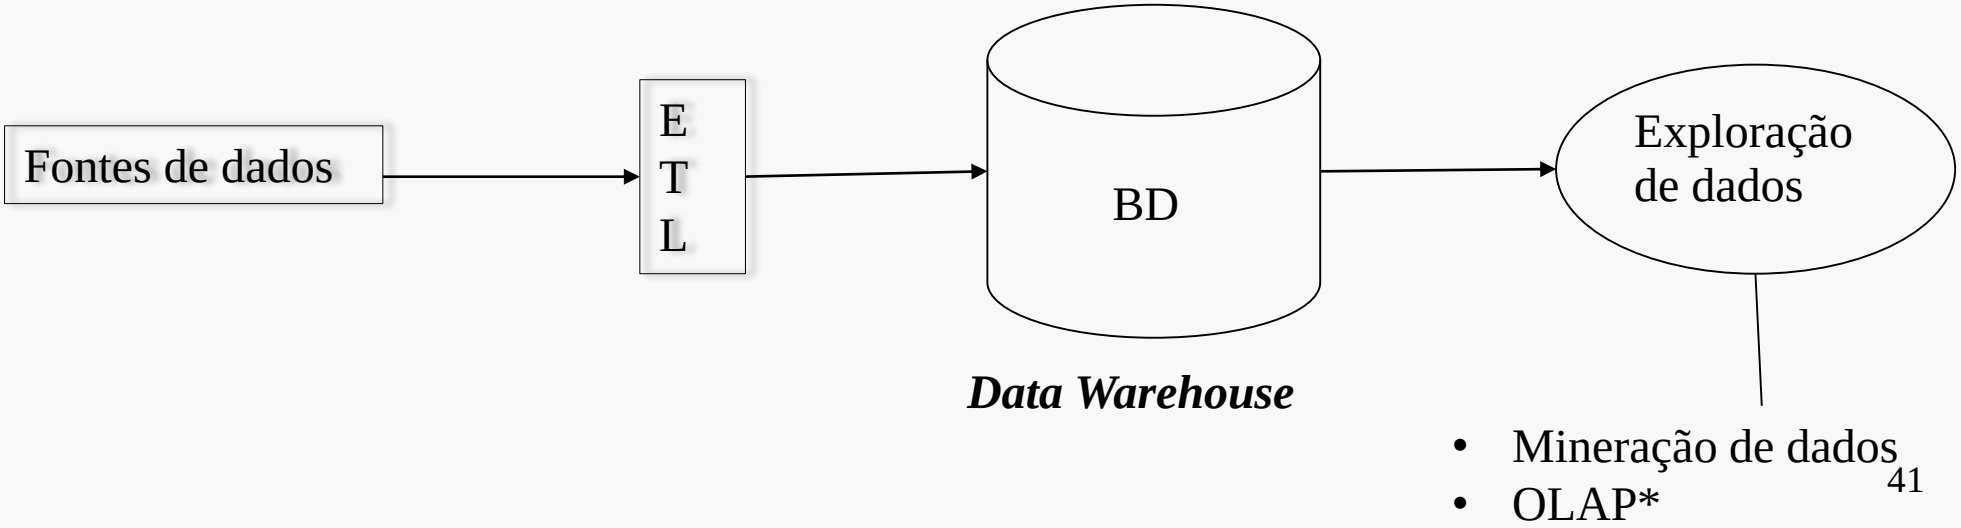

Quem são os usuários do BD ?

- **DBA** (*database administrator*): é o responsável pela administração geral do SBGD.
- **Projetista de Banco de Dados**: Usuário responsável pelo projeto (conceitual e lógico) e criação do banco de dados de um determinado sistema da empresa. Ele depende que o DBA cadastre a autorização para realizar a criação dos elementos que compõem o banco de dados.
- **Usuário Final**: São aquelas pessoas que vão acessar os dados através das aplicações desenvolvidas.

O que é um Cientista de dados ?

- Mais recentemente surgiu um novo perfil, o cientista de dados.
- Este é um profissional analítico e a sua principal função é extrair informações valiosas de dados armazenados para avaliar a situação e traçar estratégias mais assertivas para o futuro.

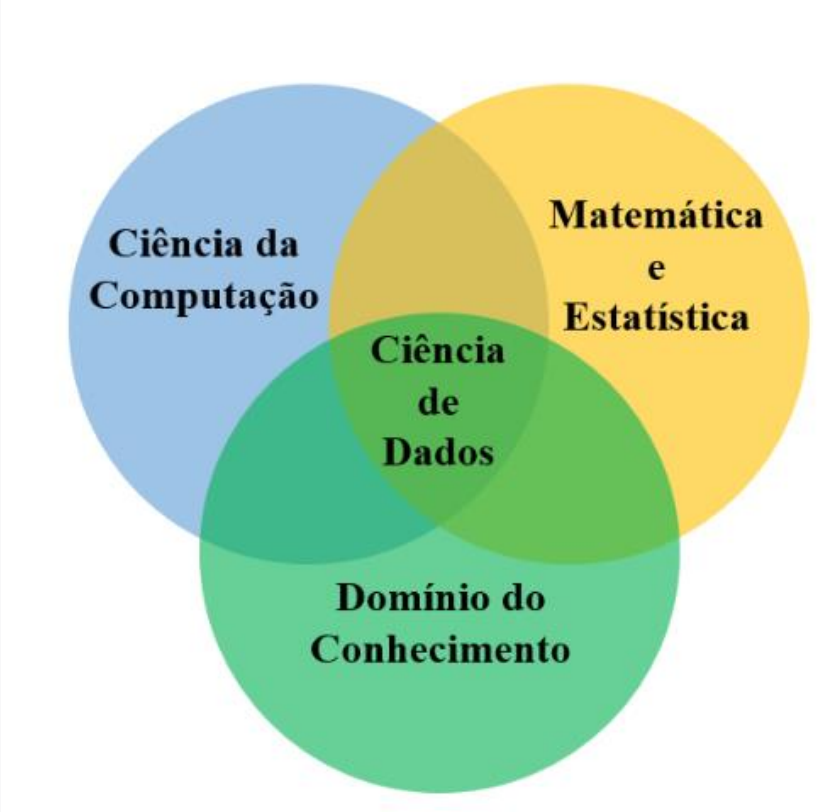

Cientista de dados e Projetista de BD

A atuação neta disciplina envolve dois papéis:

- Cientista de Dados
- Projetista de Banco de Dados

SGBD NoSQL

- O hospital cresceu virou uma rede nacional de exames, consultas e tratamento, com isso necessitou melhorar sua capacidade de guardar seus documentos e imagens e melhorar o tempo de resposta ao seu site de consulta aos resultados de exames.
- A universidade vinha estudando tipo de BD mais contemporâneo que não fica restrito ao formato de linhas e colunas. O SGBD NoSQL trabalha com dados não estruturados ou semiestruturados e muitas vezes em pares chave-valor. Assim, não há uma forma pré-definida é possível adaptar para um tipo de dado mais aderente ao negócio (**flexibilidade**), o que favorece um maior desempenho de armazenamento e busca.

SGBD NoSQL

- A universidade propões implantar uma solução de BD NoSQL para manter os exames dos pacientes e servir de repositória de consultas para o **Site da Internet** sobre resultados de exames (**Hadoop Cluster**).
- A solução possibilitou adicionar mais computadores servidores (**Escalabilidade horizontal**) para reduzir o tempo de resposta das buscas (**alta disponibilidade**) e reduzir o risco de falhas.

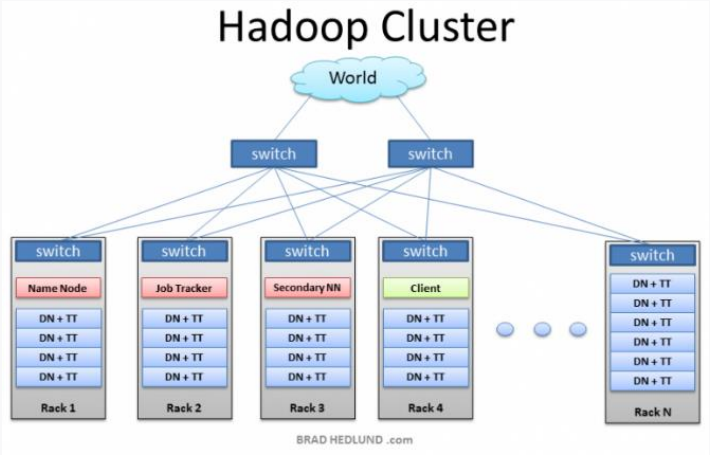

Focado em arquivos

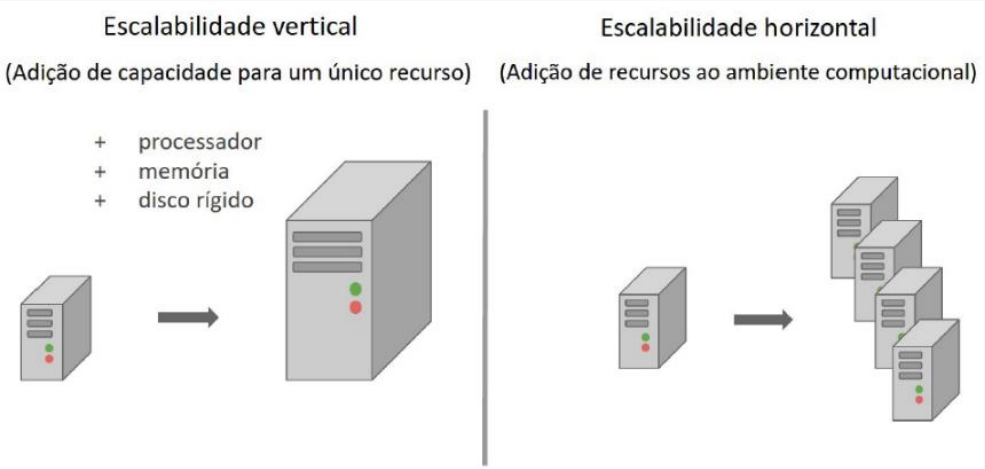

SGBD NoSQL

- O software Apache Hadoop é um framework de código aberto baseado em Java que permite o armazenamento e processamento distribuídos de grandes conjuntos de dados em clusters de computadores usando modelos de programação simples.

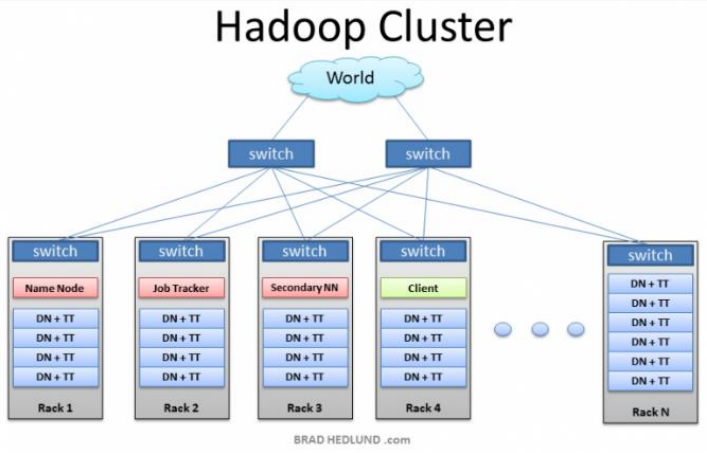

Focado em arquivos

SGBD NoSQL

- A universidade adotou em paralelo para seu trabalho uma outra abordagem mais flexível para receber as informações dos hospitais com um tempo de carga menor, o *Data Lake* (aceita SQL, R e Python).
- A solução de *Data Lake* aceita dados brutos reduzindo o tempo de carga diferentemente do *Data Warehouse*, que tem a etapa de ETL com a transformação dos dados.

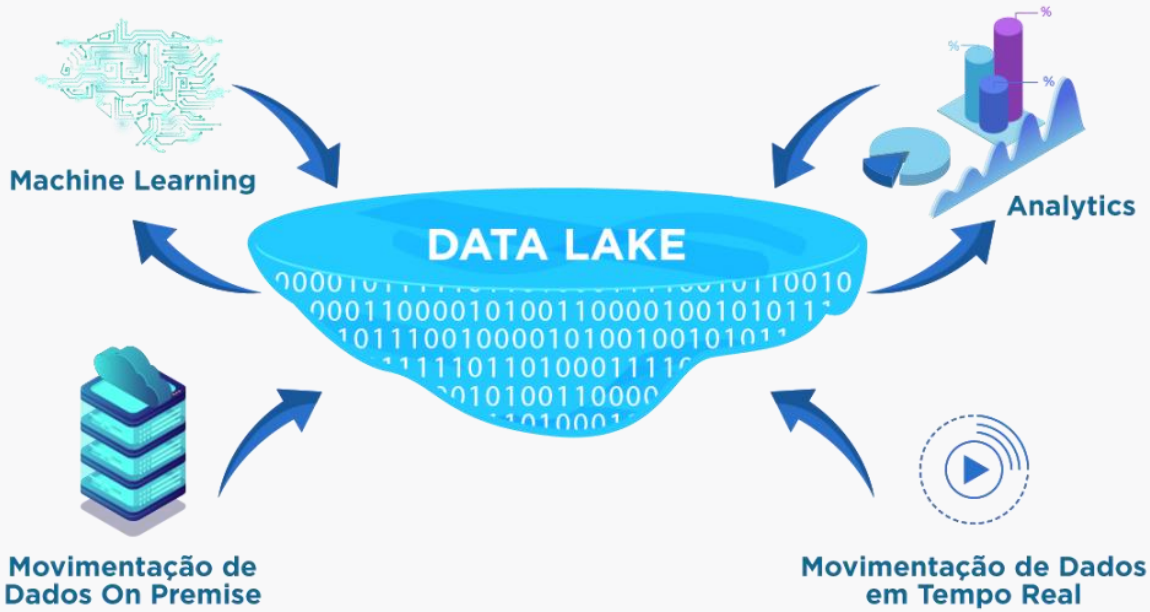

Propriedades do BD

- Do que foi visto até agora podemos ressaltar algumas características do BD. BD Possui:
    - Alguma fonte da qual o dado é proveniente
    - Algum grau de interação com eventos no mundo real
    - Um público que está ativamente interessado em seu conteúdo.
    - Pessoas que acessam (usuários)
    - Centraliza as informações
    - Permite o acesso de múltiplas transações (busca e atualização de assuntos variados)
    - Escalabilidade para tamanho (suporta o aumento da volume de dados)

Nível de importância do SQL

Pesquisa com 87.585 Respostas

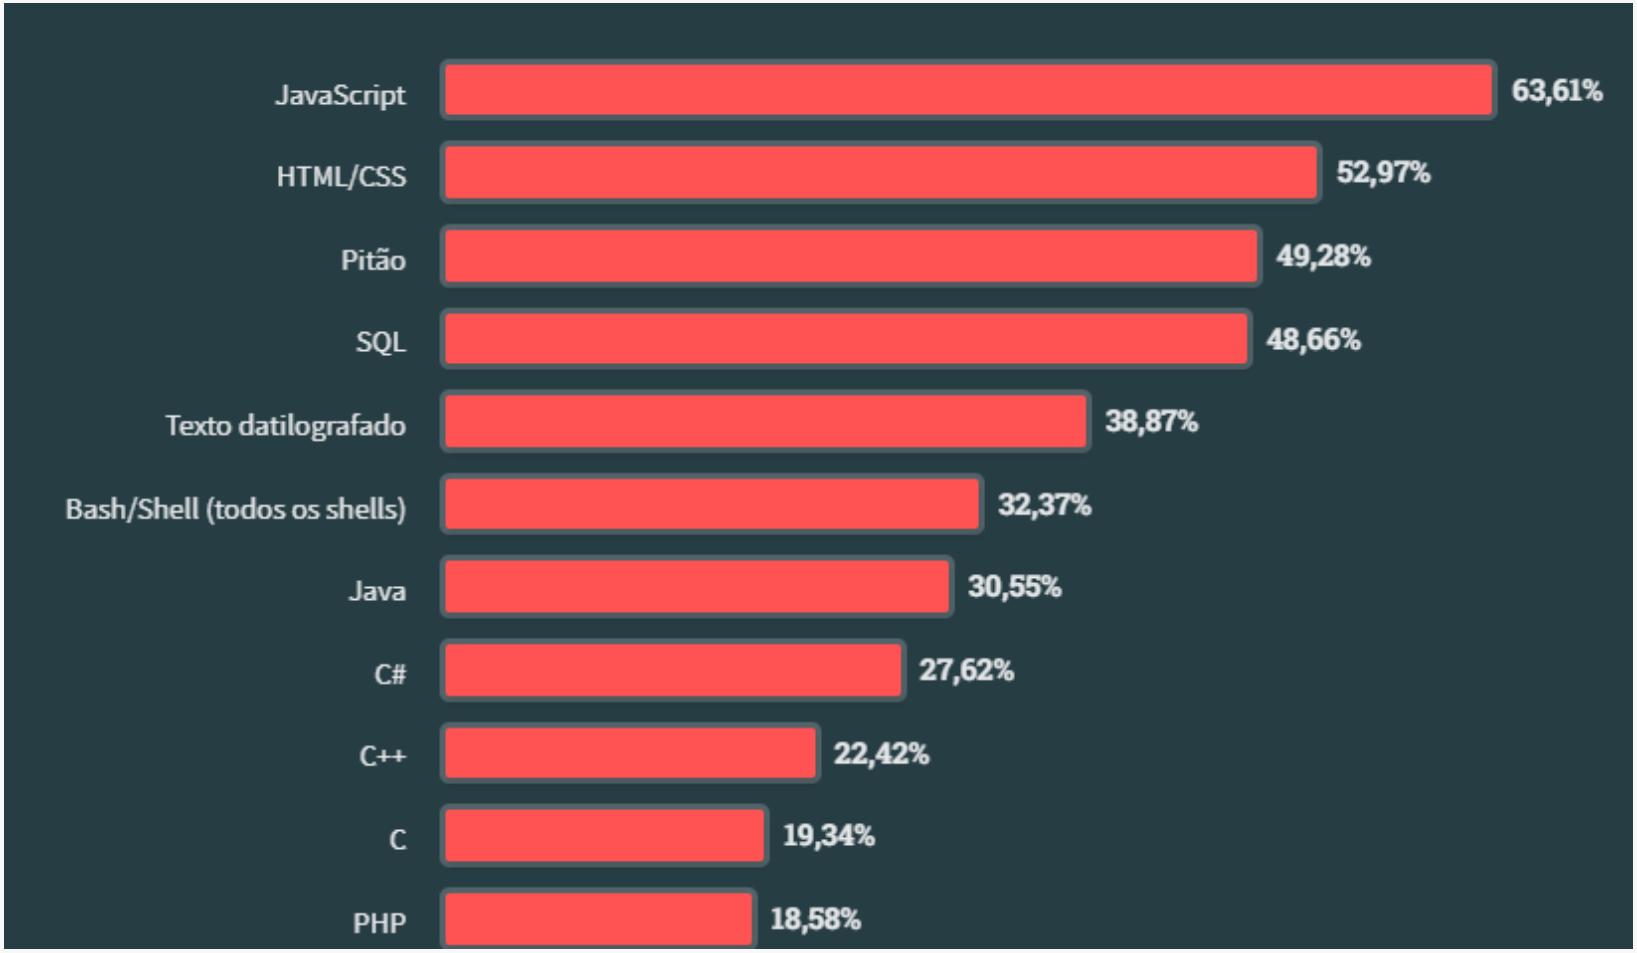

Fonte: https://survey.stackoverflow.co/2023/#most-popular-technologies-language

Nível de importância do SQL

- Segundo uma avaliação feita sobre habilidades mais procuradas para cientistas de dados em 2021, o SQL está em segundo lugar. Os números foram obtidos com base em mais de 15.000 ofertas de emprego no exterior.

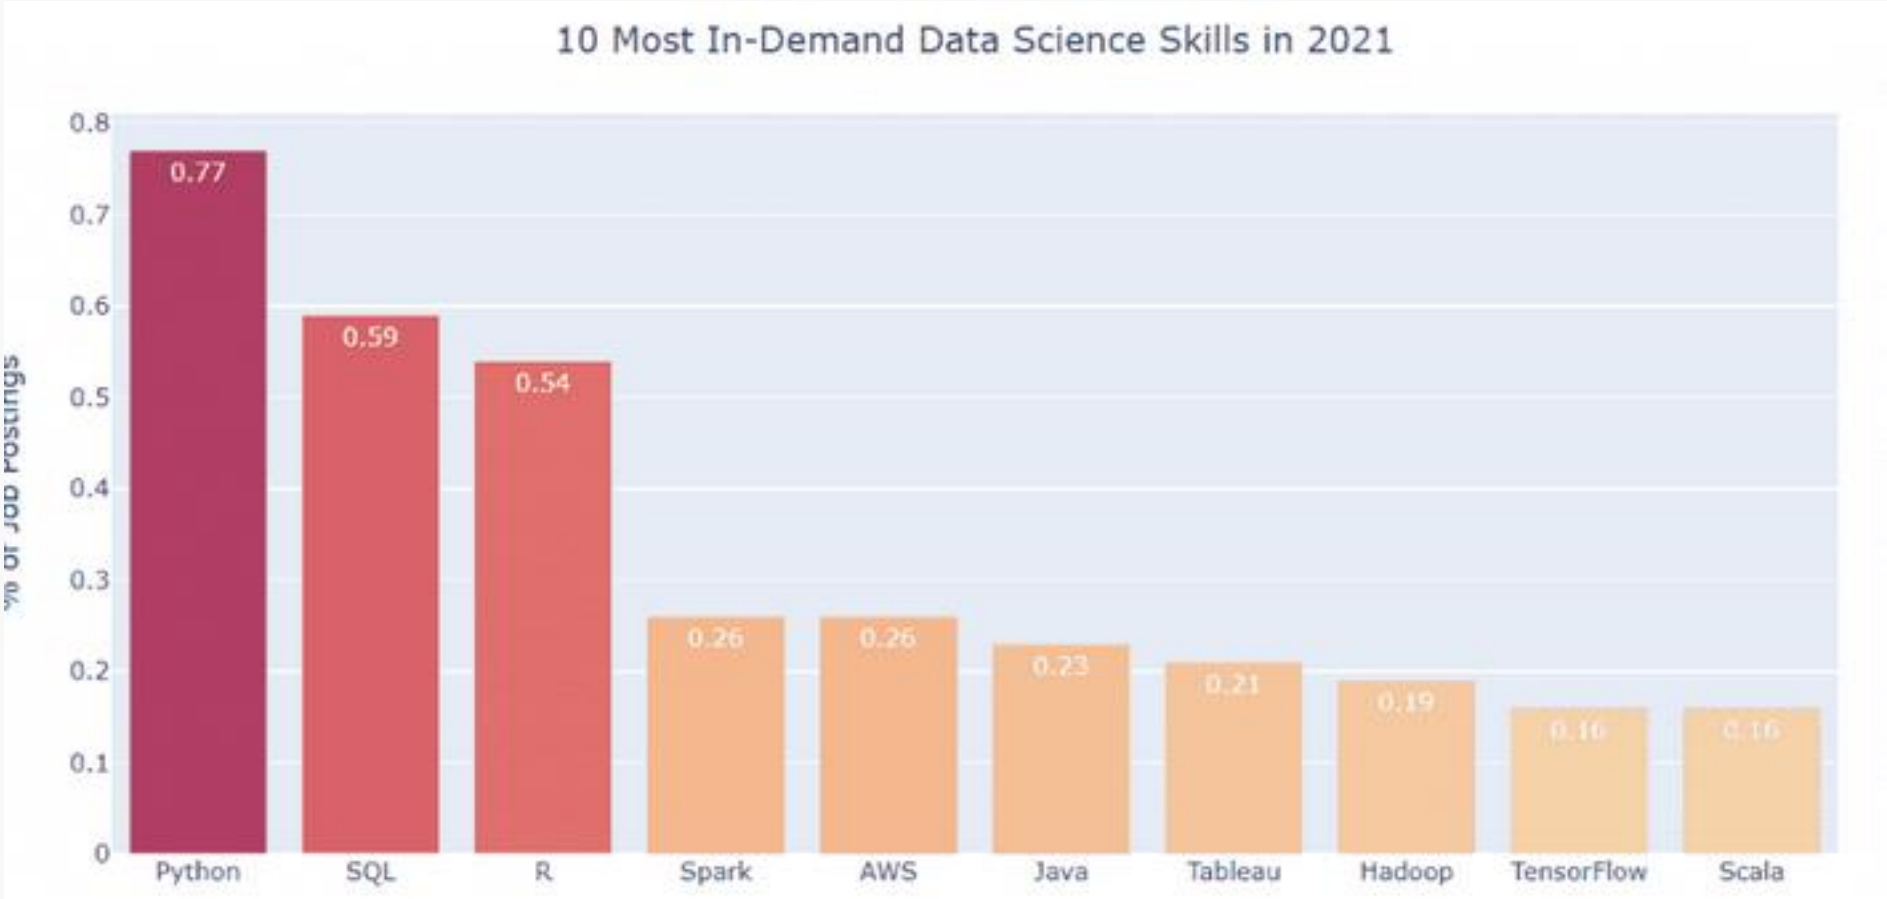

Fonte: https://www.kdnuggets.com/2021/04/most-demand-skills-data-scientists.html

Exemplos de SGBD populares

Oracle – Lançado no final do anos 70. (Relacional)
IBM DB2 – Lançado no início dos anos 80. (Relacional)
PostgreSQL – Lançado em julho de 1996. (Relacional)
MySQL – Lançado em maio de 1995. (Relacional)
MS SQL Server – Lançado em abril de 1989. (Relacional)
SQLite – Lançado em agosto de 2000. (Relacional)
mongoDB - Lançado em fevereiro de 2009 – noSQL para Documentos.

Exercício proposto

(1) Uma empresa na área logística oferece serviços de entregas e deseja manter seu sistema de consulta com alta disponibilidade 24 horas por dias, com robusta arquitetura contra falhas de modo que o cliente tenha acesso aos dados da sua entrega com baixo atraso. O sistema precisa atender um vasto número de clientes com processamento de 100 mil encomendas por minuto.

O Cliente precisa se sentir seguro e conseguir solicitar informações de rastreio de suas entregas com tempo de resposta baixo sem que seja impactado pelas consultas dos outros clientes e dos relatórios da área de gestão e planejamento assim como atualização dos documentos devem ser rápidas com baixa necessidade de transformação dos dados, evitando deste modo insatisfação dos clientes.

Por questões de escalabilidade a solução precisa oferecer uma arquitetura que seja possível aumentar o poder de processamento, aumentando o conjunto de computadores para processamento em paralelo e recursos substituição de computadores com falhas automatizado.

Que tipo de banco de dados pode ser sugerido para atender esta empresa?

Exercício proposto

(2) Uma empresa na área operações de bolsa de valores necessita de uma sistema eficiente que permita controlar os pedidos de compra e vendas de ações de modo que uma operação financeira de venda somente pode ser concretizada se o cliente oferecer uma saldo ou crédito que o permita realizar as transações com sucesso. Não pode haver inconsistências.

O sistema precisa estar atento as diversas solicitações de consulta e ao mesmo tempo deve oferecer dados históricos de outras operações financeiras que permitam realizar simulações de investimentos. A solução precisa oferecer um mecanismo que mantenha o gerenciamento dos dados centralizado e que os mecanismos para otimizar o desempenho das consultas seja independente da aplicação. É fundamental manter uma organização rígidas dos dados financeiros dos clientes de modo que facilite a execução de consultas complexas e que os dados exibidos sejam fidedignos.

Que tipo de banco de dados pode ser sugerido para atender esta empresa?

Exercício proposto

(3) Qual modelo de SGBD é mais indicado para aplicações similares aos de sistemas administrativos que se comportam bem com dados estruturados em várias tabelas com linhas e colunas e necessitam garantir que os dados gravados nas tabelas sejam consistentes todo o tempo?

Exercício proposto

(4) Qual modelo de SBGD é mais recomendados para sites de relacionamentos que incluem recursos de envio de mensagens formatadas, imagens, possibilidade de importação de documentos e vídeos.

Neste tipo de Site com consultas simples através de cliques de mouse deseja-se obter um conjunto de informações complexas na forma de documentos formatados e imagens.

Lista (1) de exercício proposto

Fazer resumo deste módulo de no máximo 1 página, destacando os tópicos principais. A estrutura do resumo deve conter introdução, descrição resumida dos tópicos importantes e conclusão descrevendo seu entendimento.

Entregar na próxima segunda feira.

Ranking dos SGBD mais usados

- Dos 11 primeiros SGBD mais populares, 8 são relacionais.

417 systems in ranking, December 2023

Rank			DBMS	Database Model	Score		
Dec 2023	Nov 2023	Dec 2022			Dec 2023	Nov 2023	Dec 2022
1.	1.	1.	Oracle	Relational, Multi-model	1257.41	-19.62	+7.10
2.	2.	2.	MySQL	Relational, Multi-model	1126.64	+11.40	-72.76
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model	903.83	-7.59	-20.52
4.	4.	4.	PostgreSQL	Relational, Multi-model	650.90	+14.05	+32.93
5.	5.	5.	MongoDB	Document, Multi-model	419.15	-9.40	-50.18
6.	6.	6.	Redis	Key-value, Multi-model	158.35	-1.66	-24.22
7.	7.	↑ 8.	Elasticsearch	Search engine, Multi-model	137.75	-1.87	-7.18
8.	8.	↓ 7.	IBM Db2	Relational, Multi-model	134.60	-1.40	-12.02
9.	↑ 10.	9.	Microsoft Access	Relational	121.75	-2.74	-12.08
10.	↑ 11.	↑ 11.	Snowflake	Relational	119.88	-1.12	+5.11
11.	↓ 9.	↓ 10.	SQLite	Relational	117.95	-6.63	-14.49

Fonte: https://db-engines.com/en/ranking

Ranking de uso de BD por modelo

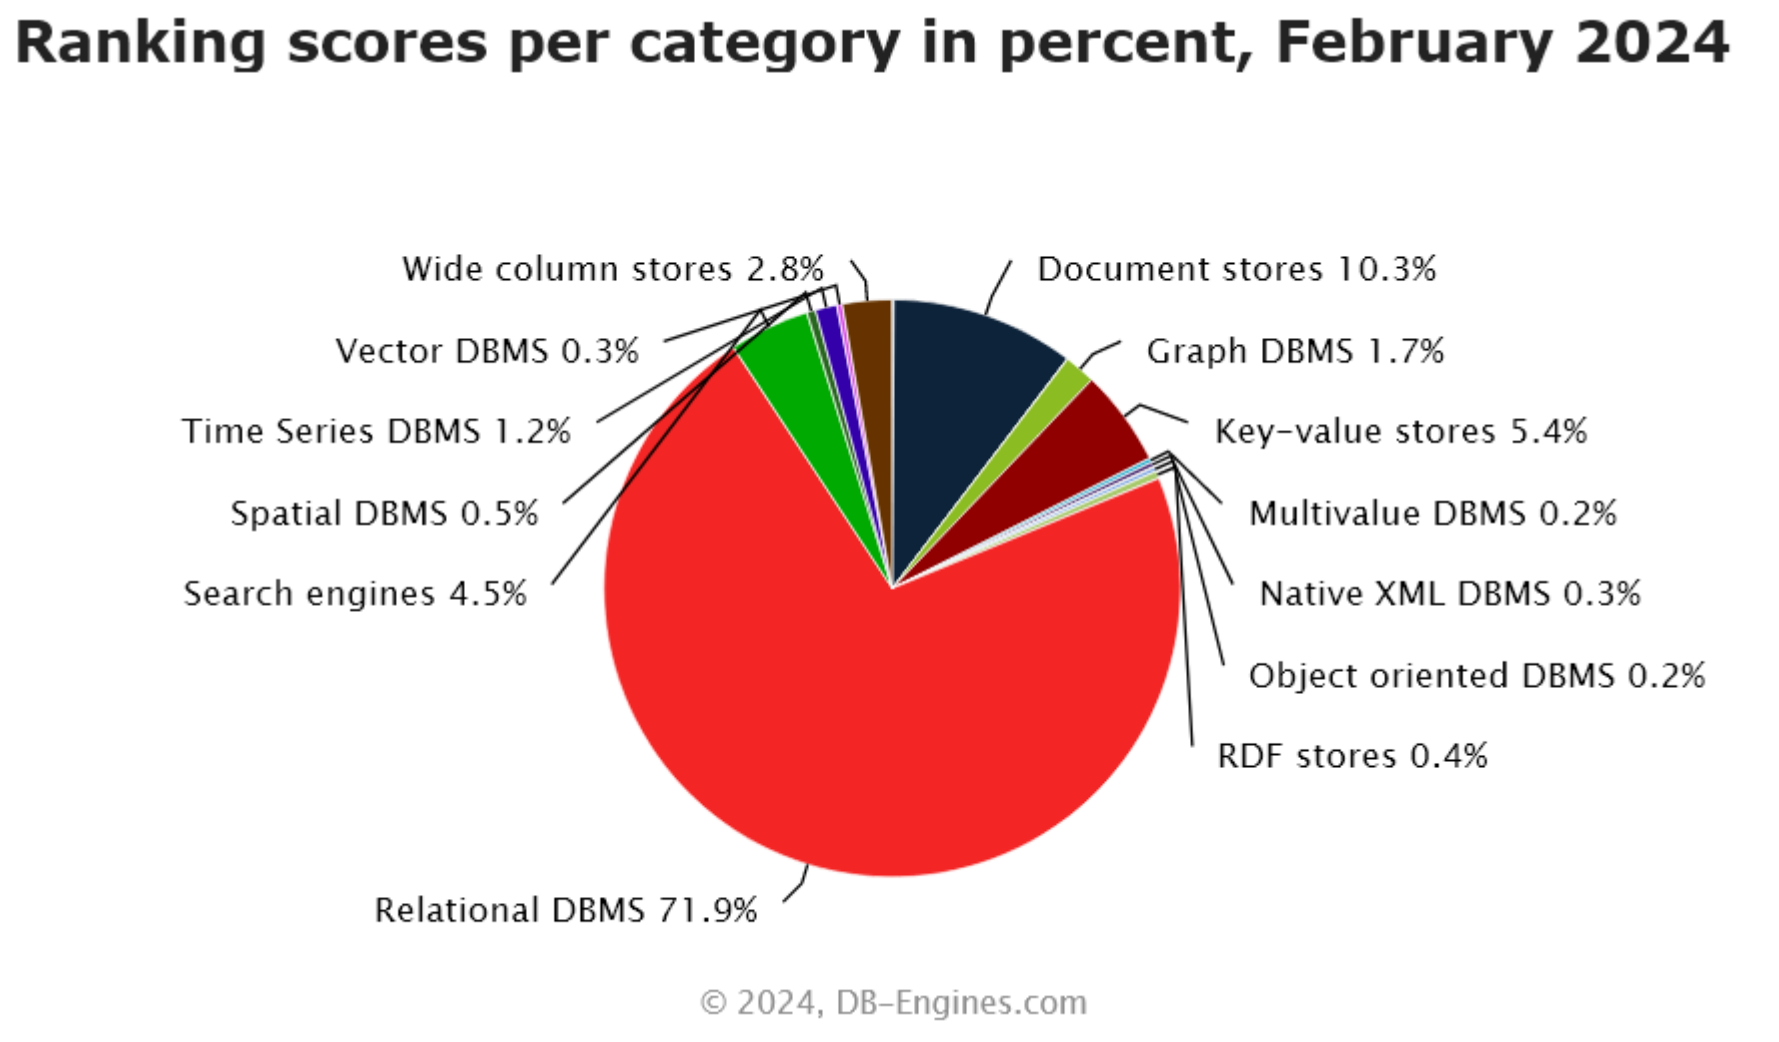

Tendência de uso desde de 2013

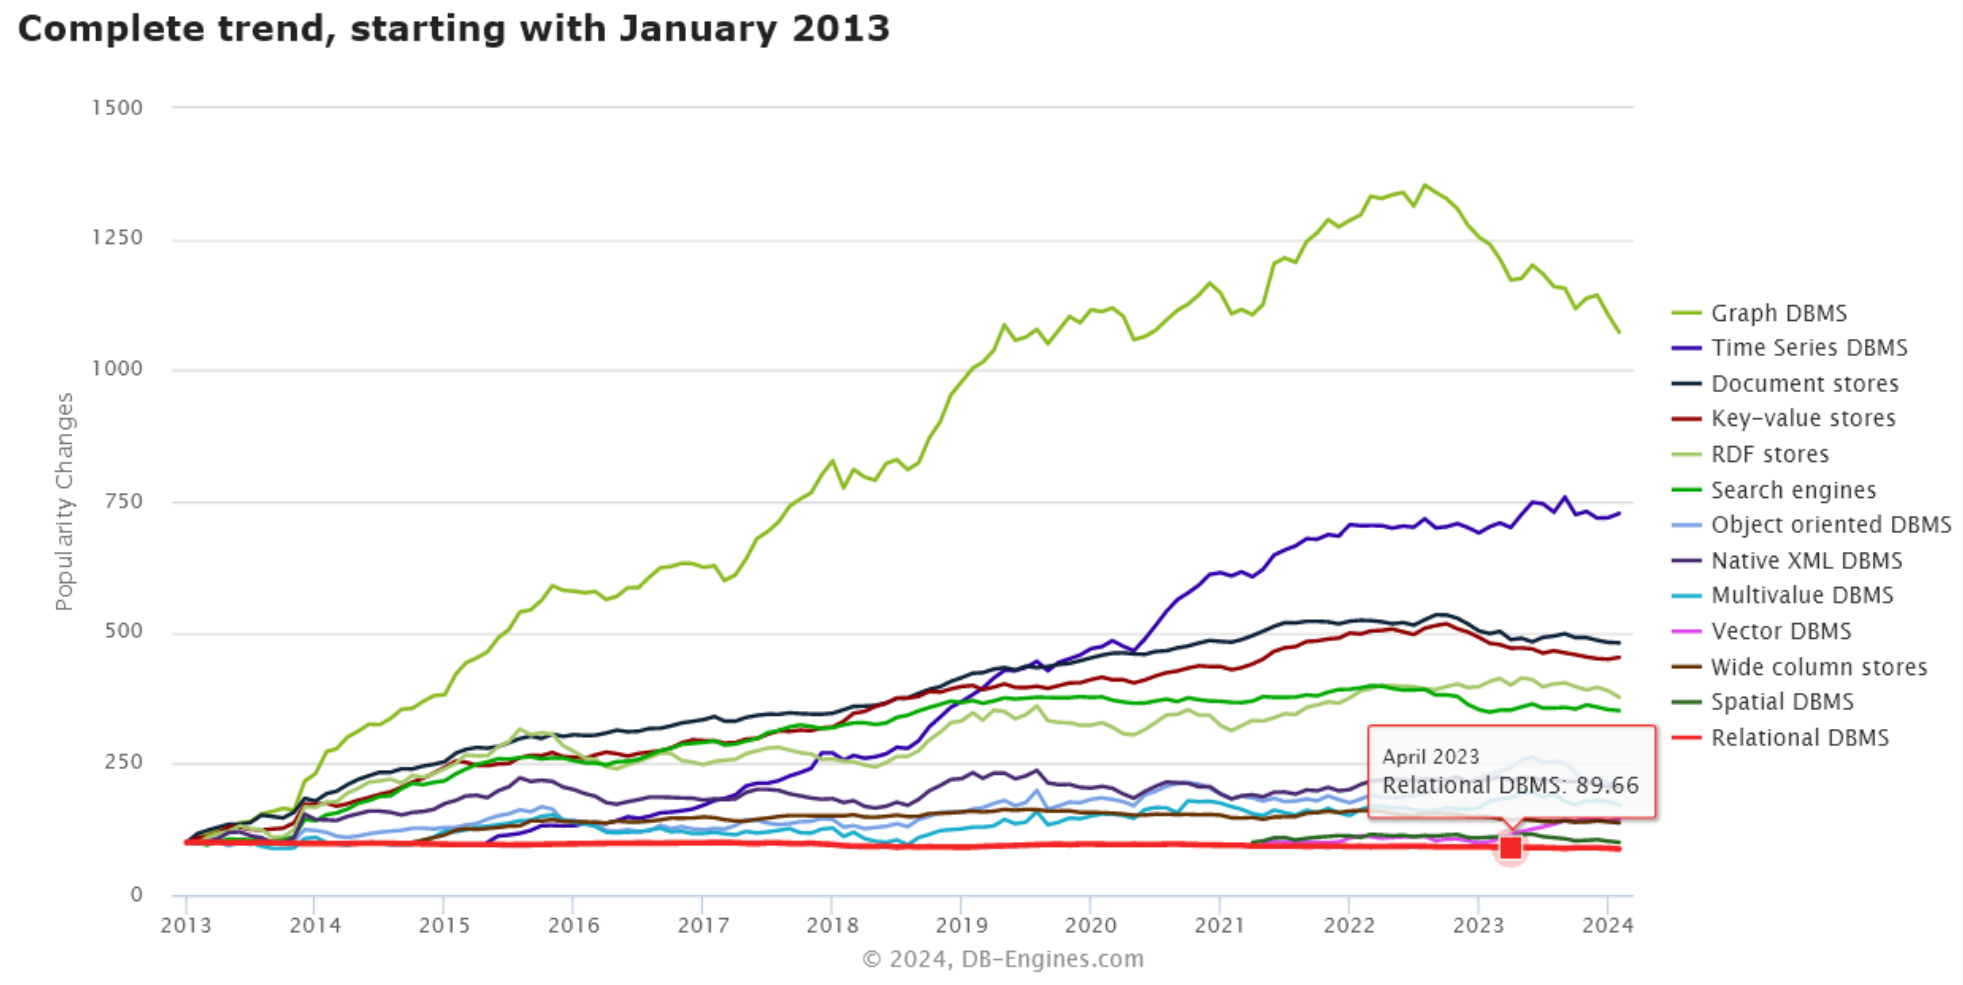

Softwares Utilizados no Curso

- Os seguintes softwares serão utilizados no curso:
  - **SQLite**: utilizaremos este software como um "emulador" de SGBD.
  - **SQLiteStudio**: permite manipular o SQLite através de uma interface gráfica.
  - **https://sqliteonline.com/:** Um emulador dos banco de dados SQLite, MariaDB, PostgreSQL, MS SQL que permite construir e manipular dados.

Download do SQLite

Acesse o endereço: https://www.sqlite.org/download.html

Precompiled Binaries for Windows

sqlite-dll-win-x86-3440200.zip (1016.88 KiB)	32-bit DLL (x86) for SQLite version 3.44.2. (SHA3-256: 5c5a41cb2727b94d38479c98cef06391aae3bd18952eed4c45df345aa9e5baca)
sqlite-dll-win-x64-3440200.zip (1.24 MiB)	64-bit DLL (x64) for SQLite version 3.44.2. (SHA3-256: bf2b78a7f610cabd1046ee2587640b0ecc01bf8916381e7e6cdaa0be70eeee70)

- Baixe os arquivos indicados em "**PrecompiledBinariesfor Windows**". A versão mais recente na data em que esta aula foi elaborada é a 3.44.2.
- "sqlite-dll-win32" **ou**"sqlite-dll-win64" (*dependendo do seu tipo de processador, 32 ou 64 bits –versão para Windows*).
- *Preferencialmente,* ***descompacte*** *ambos para a pasta "**C:\bd**" do seu computador.*

Download do SQLite Studio

- Acesse o endereço: **https://sqlitestudio.pl/**
- Basta clicar no botão Download.
- Preferencialmente, descompacte a pasta SQLiteStudio para “C:\bd”

Estrutura de Pastas

- Sugestão, utilize a seguinte estrutura de pastas para armazenar os softwares do curso e os bancos de dados que serão criados em cada aula:

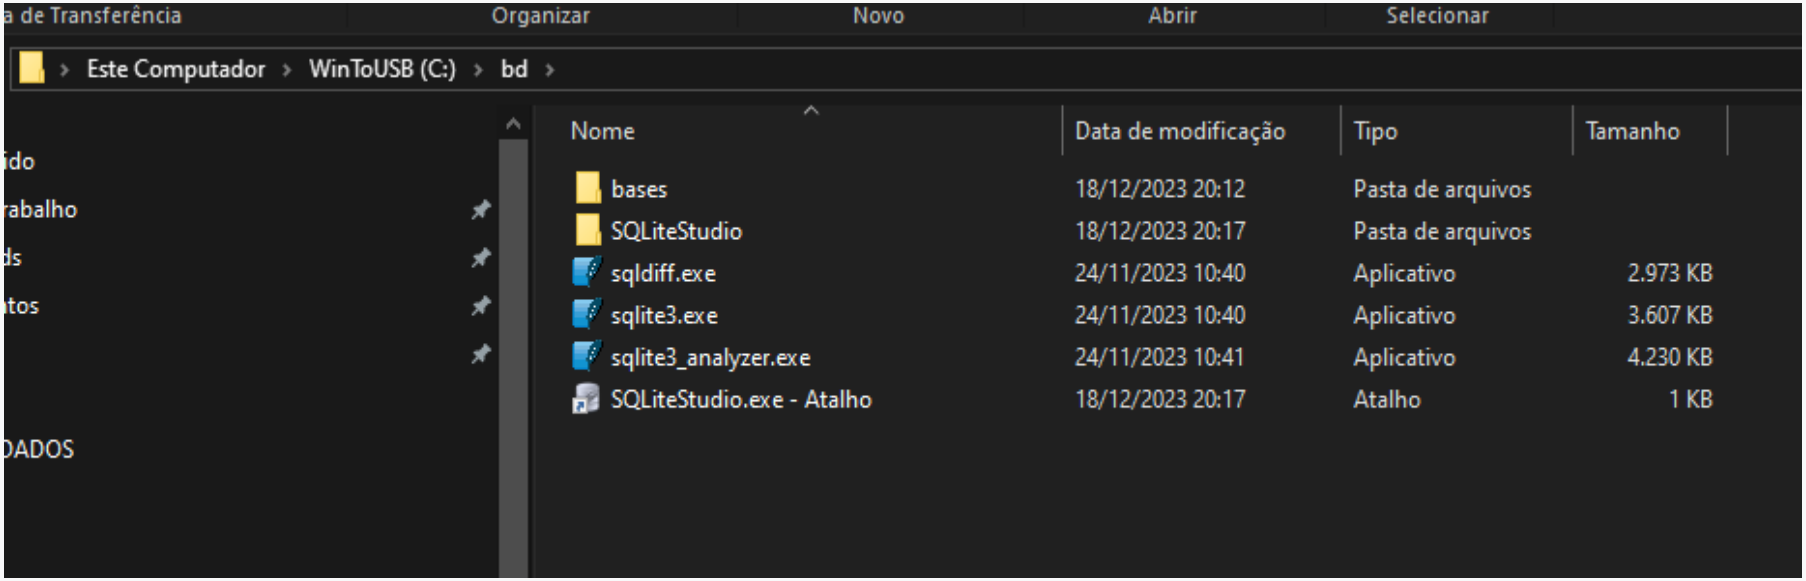

- A pasta **bases** vai conter os bancos de dados criados em nossas aulas (bancos que serão criados com o uso do SQLite).