Bases de Dados

Módulo 13b: Explorando banco de dados da Pense com JOIN E VIEW

Prof. André Bruno de Oliveira

04/04/2024 22:05

Explorando banco de dados da Pense

- A Pesquisa Nacional de Saúde do Escolar – PeNSE é constituída do questionário da escola e do aluno, tem periodicidade anual, sua abrangência geográfica é nacional. A pesquisa fornece informações sobre as características básicas da população de estudo, incluindo aspectos socioeconômicos.

Explorando banco de dados da Pense

- Este BD SQLite (Pense.db) inclui uma versão simplificada da Pense com 18 variáveis na tabela *Quest_aluno*. A versão original do questionário do Aluno está em *Questionario_aluno* com 306 variáveis e 165.838 ocorrências.
- O banco de dados está disponível na pasta do professor. A fonte de dados original juntamente com a documentação está disponível em https://www.ibge.gov.br/estatisticas/downloads-estatisticas.html?caminho=pense/2019/microdados/. Os dados foram importados para o Sqlite com uso do Sqlite Studio.

Explorando banco de dados da Pense

- O BD Pense.bd inclui 165.838 linhas com 15 tabelas apresentadas no diagrama da figura 1. A tabela central Quest_aluno possui 14 FK com 1 FK para cada tabela auxiliar.
- As tabelas auxiliares estão dispostas na ordem das variáveis da tabela Quest_aluno começando à esquerda com *Regiao* e terminando à direita com *TomouBebida*.

Figura 1 – Diagrama do BD da Pense 2019

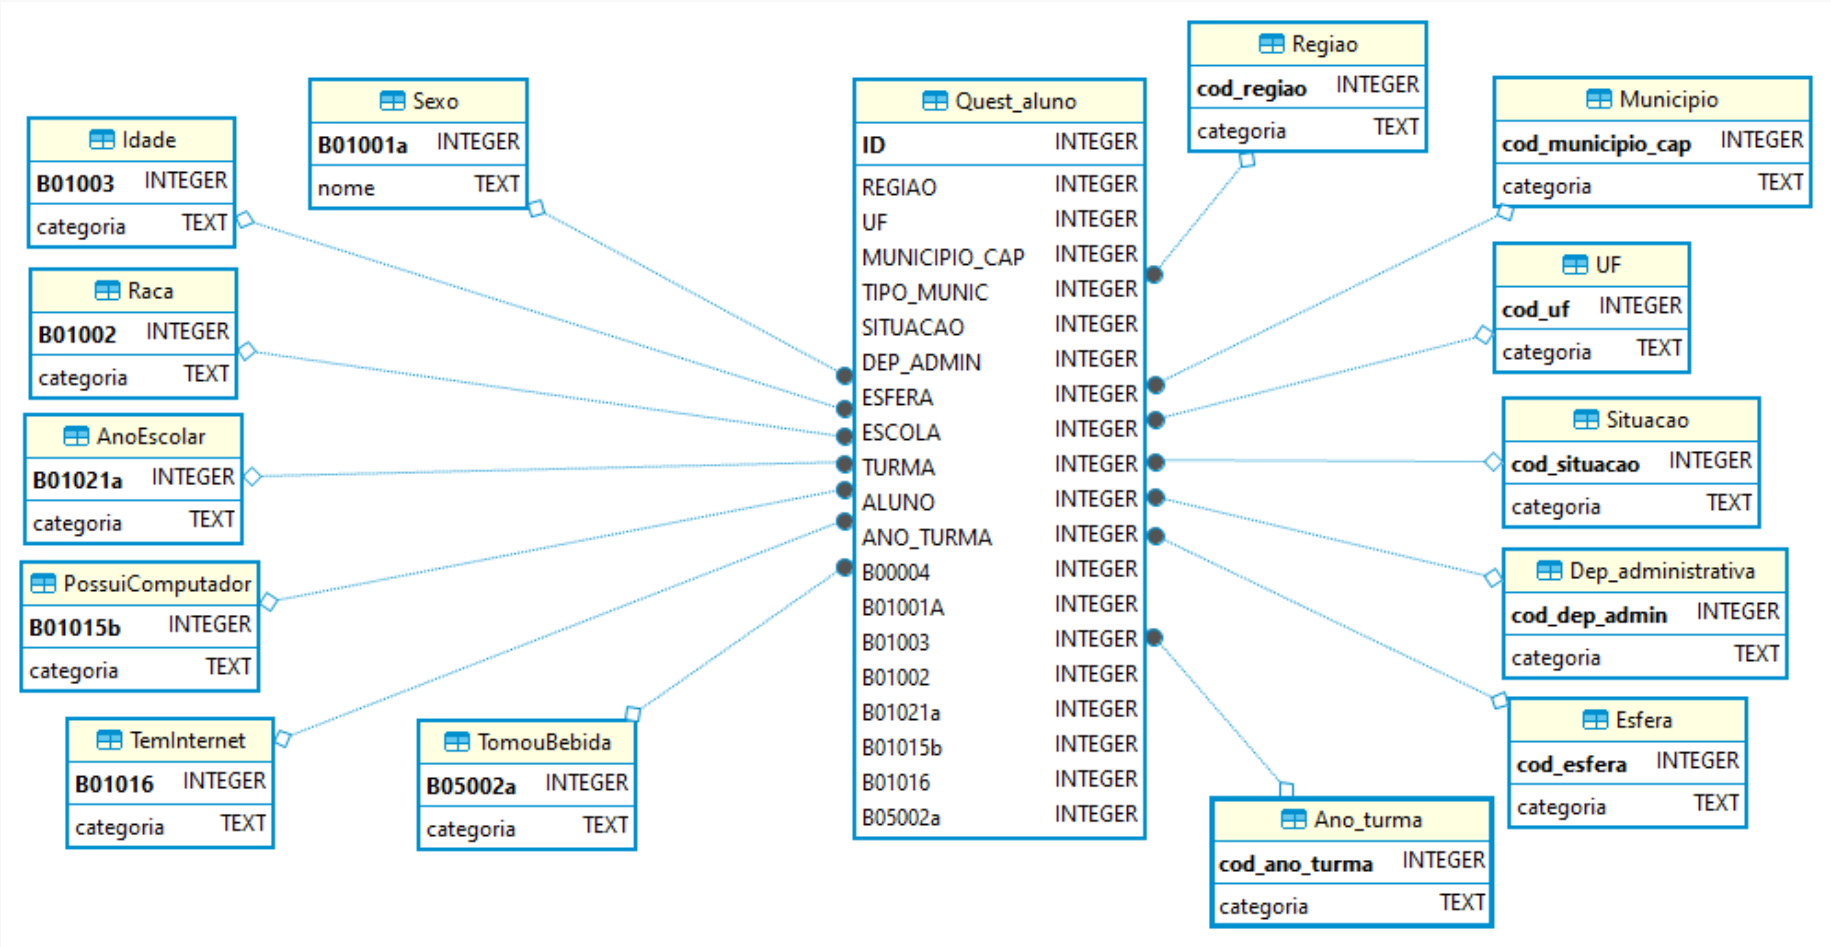

Descrição das variáveis em Quest_aluno

Variável	Descrição
ID	Identificador único
regiao e cod_regiao	São códigos da região
uf e cod_uf	São códigos da unidade federativa
municipio_cap e cod_municipio_cap	São códigos do município
situacao e cod_situacao	Define a situação da escola como Rural ou Urbano
dep_adimin e cod_dep_adimin	Pública ou Privada
esfera ou cod_esfera	Federal, estadual, Municipal pu Privada
ano_tuma	Categoriza ano série e tipo de curso
B00004	1 - aceitou responder o questionário; 0 - não
B01001A	Sexo Homem ou Mulher
B01003	Grupos de idade
B01002	Raça
B01021a	Ano escolar
B01015b	Possui computador em casa?
B01016	Tem internet em casa?
B05002a	Tomou bebida alcoólica?
PESO_ALUNO_FREQ	Peso do aluno com pós-estratificação pelos totais de matriculados do Censo Escolar.

Explorando banco de dados da Pense

- A partir da documentação da Pense 2019 criou-se as tabelas auxiliares da figura 1 para ajudar na avaliação da base de dados. Cada tabela auxiliar possui um atributo PK e um atributo categoria que descreve a variável PK. O atributo ID de Quest_aluno foi criado como número sequencial para definir cada questionário.
- A figura 2 abaixo exemplifica como é o dicionário original de variáveis da pesquisa: código da variável (ou nome do atributo); descrição; código (valor numérico inteiro categórico); categoria no formato alfanumérico.

Exemplo do dicionário da Pense 2019

VARIÁVEIS CADASTRAIS E DA AMOSTRA			
Código da Variável	Descrição da Variável	Categorias	
		Código	Descrição
		5300108	Distrito Federal
TIPO_MUNIC	Indicadora de município da capital	1	Capital
		2	Não capital
SITUACAO	Situação	1	Urbana
		2	Rural
DEP_ADMIN	Dependência administrativa	1	Pública
		2	Privada
ESFERA	Esfera administrativa	1	Federal
		2	Estadual
		3	Municipal
		4	Privada

Criação da tabela principal

- A chave primária ID da tabela Quest_aluno segue a seguinte sintaxe de criação: nome do atributo, definição do tipo de variável como inteiro; definição da restrição como PK e a cláusula **AUTOINCREMENT** para definir que o atributo incrementa uma numeração sequencial (1,2,3...,n).

```
CREATE TABLE Quest_aluno (
  ID          INTEGER PRIMARY KEY AUTOINCREMENT,
  REGIAO      INTEGER REFERENCES Regiao (cod_regiao),
  UF          INTEGER REFERENCES UF (cod_uf),
  MUNICIPIO_CAP INTEGER REFERENCES Municipio (cod_municipio_cap),
  TIPO_MUNIC  INTEGER,
  SITUACAO    INTEGER REFERENCES Situacao (cod_situacao),
  DEP_ADMIN   INTEGER REFERENCES Dep_administrativa (cod_dep_admin),
  ESFERA      INTEGER REFERENCES Esfera (cod_esfera),
  ESCOLA      INTEGER,
  TURMA       INTEGER,
  ALUNO       INTEGER,
  ANO_TURMA   INTEGER REFERENCES Ano_turma (cod_ano_turma),
  B00004      INTEGER,
  B01001A     INTEGER REFERENCES Sexo (B01001a),
  B01003      INTEGER REFERENCES Idade (B01003),
  B01002      INTEGER REFERENCES Raca (B01002),
  B01021a     INTEGER REFERENCES AnoEscolar (B01021a),
  B01015b     INTEGER REFERENCES PossuiComputador (B01015b),
  B01016      INTEGER REFERENCES TemInternet (B01016),
  B05002a     INTEGER REFERENCES TomouBebida (B05002a) );
```

Criação da tabela principal

- Os dados da Pense estão no formato de arquivo CSV. SQLite Studio permite importar um arquivo csv para o BD Pense.db através da tabela Quest_aluno, conforme os passos a seguir.

Passo 1

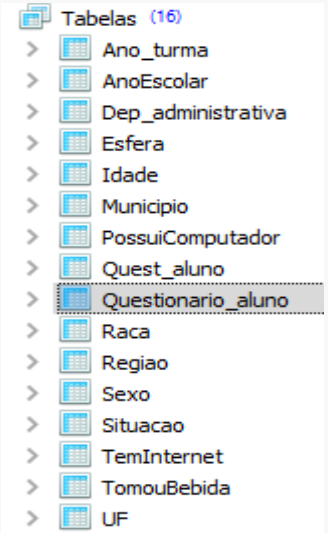

Passo 2

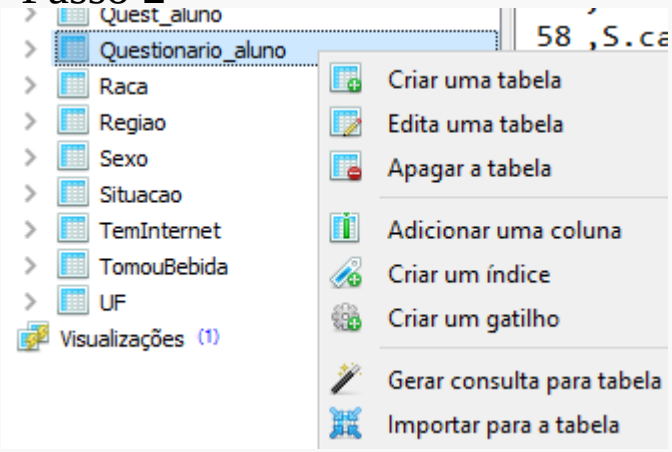

Passo 3

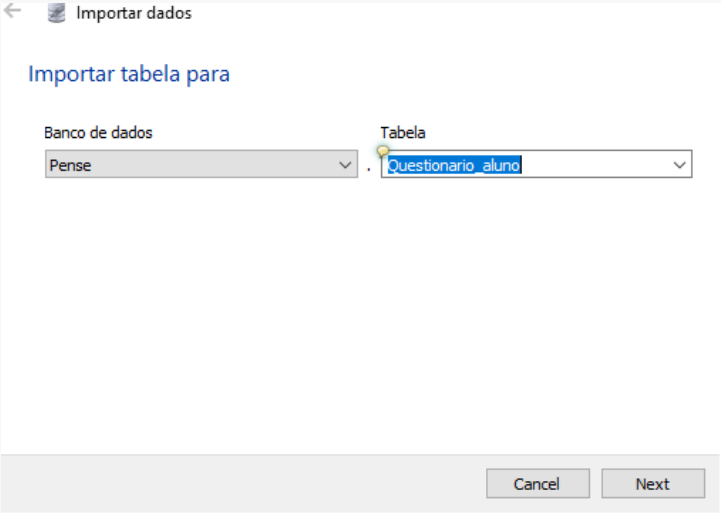

Passo 4

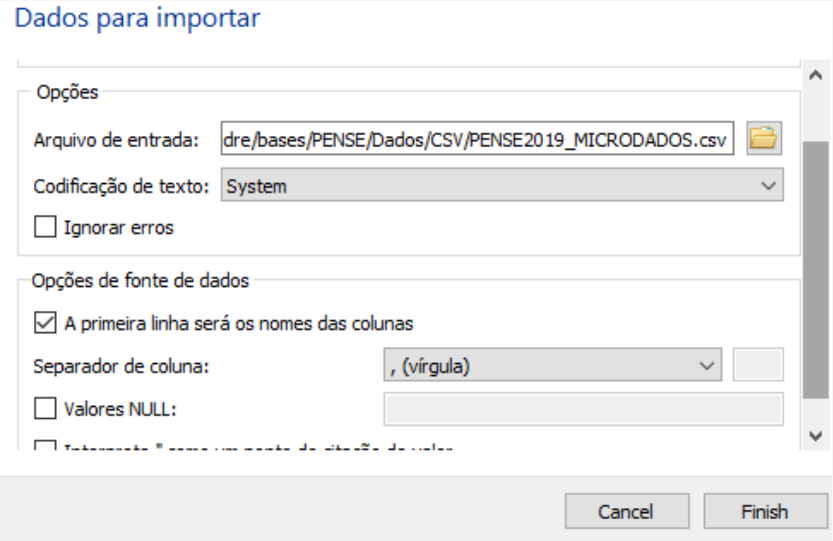

Atenção:

Os exercícios a seguir são estritamente para a prática de SQL, não vamos nos preocupar em fazer o uso do peso amostral, com exceção do exercício 5.

Dep_administrativa

	cod_dep_admin	categoria
1	1	Pública
2	2	Privada

Esfera

	cod_esfera	categoria
1	1	Federal
2	2	Estadual
3	3	Municipal
4	4	Privada

Idade

	B01003	categoria
1	1	Menos de 13 anos
2	2	13 a 15 anos
3	3	16 ou 17 anos
4	4	18 anos ou mais
5	9	Sem resposta

Raca

	B01002	categoria
1	-2	Abandono de questionário
2	1	Branca
3	2	Preta
4	3	Amarela
5	4	Parda
6	5	Indígena

Ano_turma

	cod_ano_turma	categoria
1	1	7º ano / 6ª série
2	2	8º ano / 7ª série
3	3	9º ano / 8ª série
4	4	1ª Série
5	5	2ª Série
6	6	3ª Série
7	7	Curso Técnico Integrado 1ª Série
8	8	Curso Técnico Integrado 2ª Série
9	9	Curso Técnico Integrado 3ª Série
10	10	Normal/Magistério 1ª Série
11	11	Normal/Magistério 2ª Série
12	12	Normal/Magistério 3ª Série

AnoEscolar

	B01021a	categoria
1	-2	Abandono de questionário
2	1	6º ano do Ensino Fundamental
3	2	7º ano do Ensino Fundamental
4	3	8º ano do Ensino Fundamental
5	4	9º ano do Ensino Fundamental
6	5	1º ano do Ensino Médio
7	6	2º ano do Ensino Médio
8	7	3º ano do Ensino Médio
9	9	Sem resposta

Possui Computador

	B01015b	categoria
1	-2	Abandono de questionário
2	1	Sim
3	2	Não
4	9	Sem resposta

Municipio

	cod_municipio_cap	categoria
1	0	Não é capital
2	1100205	Porto Velho
3	1200401	Rio Branco
4	1302603	Manaus
5	1400100	Boa Vista
6	1501402	Belém
7	1600303	Macapá
8	1721000	Palmas
9	2111300	São Luís
10	2211001	Teresina
11	2304400	Fortaleza
12	2408102	Natal
13	2507507	João Pessoa
14	2611606	Recife
15	2704302	Maceió
16	2800308	Aracaju
17	2927408	Salvador
18	3106200	Belo Horizonte
19	3205309	Vitória
20	3304557	Rio de Janeiro
21	3550308	São Paulo
22	4106902	Curitiba
23	4205407	Florianópolis
24	4314902	Porto Alegre
25	5002704	Campo Grande
26	5103403	Cuiabá
27	5208707	Goiânia
28	5300108	Distrito Federal

Regiao

	cod_regiao	categoria
1	1	Norte
2	2	Nordeste
3	3	Sudeste
4	4	Sul
5	5	Centro-Oeste

Sexo

	B01001a	nome
1	1	Homem
2	2	Mulher

Situacao

	cod_situacao	categoria
1	1	Urbana
2	2	Rural

TemInternet

	B01016	categoria
1	-2	Abandono de questionário
2	1	Sim
3	2	Não
4	9	Sem resposta

Tomoubebida

	B05002a	categoria
1	-2	Abandono de questionário
2	-1	Pulo do questionário
3	1	Sim
4	2	Não

Exercícios:

(1) Construa uma view que forneça o total alunos pelas categorias região e raça que responderam a pergunta se tomou bebida alcoólica?

- Com a view criada faça um select * from e identifique qual raça tem maior frequência de resposta Sim.
- Como deveria ser a query para identificar o percentual de Sim em cada região e raça ?

B00004=1 são os alunos que aceitaram responder o questionário.
B01002 representação cor/raça.
B05002A resposta se tomou bebida alcoólica (1 Sim 2 Não são as válidas)
regiao - codigo da regiao.

Exercícios:

(1) Construa uma view que forneça o total alunos pelas categorias região e raça que responderam a pergunta se tomou bebida alcoólica?

- Veja que no GROUP BY foram usados os atributos que se deseja agrupar os totais, RG.categoria,R.categoria. O INNER JOIN entre Quest_aluno e Raca seleciona os atributos correspondentes com valores iguais entre estas duas tabelas e limita para que use somente as raças de código 1 a 5 (ou seja as linhas válidas, eliminando o abandono de questionário).
- Na tabela TomouBebida a lógica é bem semelhante a adota para raça.
- Na cláusula WHERE seleciona-se as linhas que o aluno concordou em responder o questionário.

```
CREATE VIEW V_RegiaoRacaBebida as
SELECT RG.categoria Regiao,R.categoria Raca , COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A AND A.B05002A BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004=1
GROUP BY RG.categoria,R.categoria;
```

Exercícios:

(1) Construa uma view V_RegiaoRacaBebida que forneça o total alunos pelas categorias região e raça que responderam a pergunta se já tomou bebida alcoólica?

- **Com a view criada faça um select * from e identifique qual raça tem maior frequência de resposta Sim.**
- Como deveria ser query para exibir o percentual de

Select * from V_RegiaoRacaBebida

	Regiao	Raca	TOTAL
1	Centro-Oeste	Amarela	749
2	Centro-Oeste	Branca	7207
3	Centro-Oeste	Indígena	476
4	Centro-Oeste	Parda	7830
5	Centro-Oeste	Preta	1802
6	Nordeste	Amarela	1935
7	Nordeste	Branca	13781
8	Nordeste	Indígena	1376
9	Nordeste	Parda	22140
10	Nordeste	Preta	6275
11	Norte	Amarela	997
12	Norte	Branca	8067
13	Norte	Indígena	1127
14	Norte	Parda	16130
15	Norte	Preta	2934
16	Sudeste	Amarela	681
17	Sudeste	Branca	10793
18	Sudeste	Indígena	581
19	Sudeste	Parda	8456
20	Sudeste	Preta	2937
21	Sul	Amarela	330
22	Sul	Branca	9834
23	Sul	Indígena	254
24	Sul	Parda	2709
25	Sul	Preta	946

Exercícios:

(2) Encontre a *query* que forneça o total de alunos que responderam a pergunta se tem internet em casa agrupados por região e raça (exiba as categorias de região e raça).

(2.1) Com a *query* anterior criada use-a para construir outra *query* e assim, encontrar a diferença entre o valor o maior e menor por região. (Use as variáveis B01002, 05002A e Regiao e na condição do INNER JOIN use somente os valores válidos entre 1 e 5 para Raça e entre 1 e 2 para Sim que tem internet em casa).

B00004=1 são os alunos que aceitaram responder o questionário.
B01002 representação cor/raça (de 1 a 5).
B05002A representa a resposta se tomou bebida alcoólica (1 Sim; 2 Não).
regiao e cod_região são códigos da região.

Primeira query pergunta (2) – A lógica é bem parecida com a query da pergunta 1, diferenciado pelo tipo de atributo analisado, se tem internet em casa.

```
SELECT RG.categoria Regiao,R.categoria Raca , COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TemInternet T ON T.B01016 = A.B01016 AND A.B01016 BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0
GROUP BY RG.categoria,R.categoria;
```

Exercícios:

(2) Encontre a *query* que forneça o total de alunos que responderam a pergunta se tem internet em casa agrupados por região e raça?

O SQL final inclui um SELECT sem subconsulta, somente com INNER JOIN para recuperar os respectivos atributos "categoria" de região e raça para exibir o nome ao invés do código. O WHERE é usado para selecionar somente os registros que o aluno concordou em participar da pesquisa, caso contrário haveriam muitas respostas nulas.

Primeira query pergunta (2)

```
SELECT RG.categoria Regiao,R.categoria Raca ,
COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002
BETWEEN 1 AND 5
INNER JOIN TemInternet T ON T.B01016 = A.B01016 AND
A.B01016 BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0
GROUP BY RG.categoria,R.categoria;
```

	Regiao	Raca	TOTAL
1	Centro-Oeste	Amarela	888
2	Centro-Oeste	Branca	8758
3	Centro-Oeste	Indígena	606
4	Centro-Oeste	Parda	9433
5	Centro-Oeste	Preta	2060
6	Nordeste	Amarela	2237
7	Nordeste	Branca	16773
8	Nordeste	Indígena	1780
9	Nordeste	Parda	26531
10	Nordeste	Preta	7066
11	Norte	Amarela	1148
12	Norte	Branca	9766
13	Norte	Indígena	1294
14	Norte	Parda	19091
15	Norte	Preta	3279
16	Sudeste	Amarela	838
17	Sudeste	Branca	13063
18	Sudeste	Indígena	749
19	Sudeste	Parda	10187
20	Sudeste	Preta	3278
21	Sul	Amarela	403
22	Sul	Branca	11912
23	Sul	Indígena	328
24	Sul	Parda	3237
25	Sul	Preta	1048

Exercícios:

(2.1) Com a query anterior criada use-a para construir outra query e assim, encontrar a diferença entre o valor o maior e menor por região.

B00004=1 são os alunos que aceitaram responder o questionário.
B01002 representação cor/raça.
B05002A representa a resposta se tomou bebida alcoólica.
Cod_regia e regiao – são códigos da regiao.

View criada

```
CREATE VIEW V_regiaoRacaTemInternet as
SELECT RG.categoria Regiao,R.categoria Raca , COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TemInternet T ON T.B01016 = A.B01016 AND A.B01016 BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0 AND T.categoria IN ('Sim','Não')
GROUP BY RG.categoria,R.categoria
```

Segunda query

```
SELECT  Regiao, (MAX(TOTAL)-MIN(TOTAL)) FROM
(V_regiaoRacaTemInternet)
GROUP BY Regiao
ORDER BY 2
```

	Regiao	(MAX(TOTAL) - MIN(TOTAL))
1	Centro-Oeste	8827
2	Sul	11584
3	Sudeste	12314
4	Norte	17943
5	Nordeste	24751

Exercícios:

(3) Encontre a *query* que forneça o total de alunos por região e raça que responderam 'Sim' ou 'Não' a seguinte pergunta: tem computador em casa.

Responda a pergunta: (3.1) Pode-se dizer que quem tem computador em casa dificilmente não terá internet?

B00004=1 são os alunos que aceitaram responder o questionário.

B01002 representação cor/raça.

B01015b – 1 Sim 2 Não tem computador em casa

regiao código da região.

(3)

Primeiro, verifique as tabelas relacionadas através das informações envolvidas: região, raça e Tem Computador em casa

Segundo, deve-se fazer o **INNER JOIN** entre as tabelas;

Terceiro, selecionar somente os alunos as respostas 'Sim' ou 'Não‘ pelo **WHERE**

Quarto, use o **Group by** para agrupar as variáveis que se deseja obter os totais: região e raça

(3.1)

Quinto, para responder a pergunta feita pode-se fazer um INNER JOIN entre a query resposta da pergunta (2) e a query resultado desta pergunta.

Sexto, crie uma view da pergunta (2) e uma view da pergunta (3);

Sétimo, faça o INNER JOIN entre estas duas views por região e raça

Oitivo, faça a diferença entre os totais das duas perguntas para cada grupo de região e raça

Nono, análise o resultado para responder a pergunta

Exercícios:

(3) Encontre a *query* que forneça o total de alunos por região e raça que responderam 'Sim' ou 'Não' a pergunta: tem computador em casa.

Primeiro, verifique as tabelas relacionadas através das informações envolvidas: região, raça e Tem Computador em casa
Segundo, deve-se fazer o **INNER JOIN** entre as tabelas;
Terceiro, selecionar somente os alunos que responderam o questionário com a resposta 'Sim' ou 'Não'
Quarto, use o **Group by** para agrupar as variáveis que se deseja obter os totais: região e raça

Query solicitada

```
SELECT RG.categoria Regiao,R.categoria Raca , COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b AND A.B01015b BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0 AND T.categoria IN ('Sim','Não')
GROUP BY RG.categoria,R.categoria;
```

Exercícios:

(3) Encontre a *query* que forneça o total de alunos por região e raça que responderam 'Sim' ou 'Não' a pergunta: tem computador em casa.

Query solicitada

```
SELECT RG.categoria Regiao
, R.categoria Raca
, COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b AND A.B01015b BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0
GROUP BY RG.categoria,R.categoria;
```

	Regiao	Raca	TOTAL
1	Centro-Oeste	Amarela	888
2	Centro-Oeste	Branca	8759
3	Centro-Oeste	Indígena	606
4	Centro-Oeste	Parda	9435
5	Centro-Oeste	Preta	2060
6	Nordeste	Amarela	2236
7	Nordeste	Branca	16774
8	Nordeste	Indígena	1780
9	Nordeste	Parda	26530
10	Nordeste	Preta	7061
11	Norte	Amarela	1148
12	Norte	Branca	9765
13	Norte	Indígena	1294
14	Norte	Parda	19090
15	Norte	Preta	3279
16	Sudeste	Amarela	838
17	Sudeste	Branca	13064
18	Sudeste	Indígena	749
19	Sudeste	Parda	10185
20	Sudeste	Preta	3279
21	Sul	Amarela	403
22	Sul	Branca	11912
23	Sul	Indígena	328
24	Sul	Parda	3237
25	Sul	Preta	1047

Exercícios:

(3) Encontre a *query* que forneça o total de alunos por região e raça que responderam 'Sim' ou 'Não' a pergunta: se tem computador em casa.

<u>Responda a pergunta: Pode-se dizer que quem tem computador em casa dificilmente não terá internet?</u>

Quinto, para responder a pergunta feita pode-se fazer um INNER JOIN entre a query resposta da pergunta 2 e a query resultado desta pergunta.

Sexto, crie uma view da pergunta2 e uma view da pergunta3;

```
CREATE VIEW Pergunta2 as
SELECT RG.categoria Regiao,R.categoria Raca , COUNT(R.categoria) TOTAL
   FROM Quest_aluno A
   INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
   INNER JOIN TemInternet T ON T.B01016 = A.B01016 AND A.B01016 BETWEEN 1 AND 2
   INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
   WHERE B00004<>0 AND T.categoria IN ('Sim','Não')
   GROUP BY RG.categoria,R.categoria;
CREATE VIEW Pergunta3 as
SELECT RG.categoria Regiao,R.categoria Raca , COUNT(R.categoria) TOTAL
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b AND A.B01015b BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0 AND T.categoria IN ('Sim','Não')
GROUP BY RG.categoria,R.categoria;
```

Exercícios:

(3) Encontre a *query* que forneça o total de alunos por região e raça que responderam 'Sim' ou 'Não' a pergunta: se tem computador em casa.

Responda a pergunta: Pode-se dizer que quem tem computador em casa dificilmente não terá internet?

Sétimo, faça o INNER JOIN entre estas duas views por região e raça

Oitivo, faça a diferença entre os totais das duas perguntas para cada grupo de região e raça

Query para responder a pergunta feita

```
SELECT PC.regiao,PC.raca, PC.TOTAL-TI.TOTAL
FROM
   (Pergunta3) PC
INNER JOIN
   (Pergunta2) TI
   ON TI.regiao=PC.regiao and TI.raca=PC.raca;
```

Exercícios:

(3) Encontre a *query* que forneça o total de alunos por região e raça que responderam 'Sim' ou 'Não' a pergunta se tem computador em casa.

Responda a pergunta: Pode-se dizer que quem tem computador em casa dificilmente não terá internet? **Sim.**

Nono, análise o resultado para responder a pergunta

	regiao	raca	PC.TOTAL-TI.TOTAL
1	Centro-Oeste	Amarela	0
2	Centro-Oeste	Branca	1
3	Centro-Oeste	Indígena	0
4	Centro-Oeste	Parda	2
5	Centro-Oeste	Preta	0
6	Nordeste	Amarela	-1
7	Nordeste	Branca	1
8	Nordeste	Indígena	0
9	Nordeste	Parda	-1
10	Nordeste	Preta	-5
11	Norte	Amarela	0
12	Norte	Branca	-1
13	Norte	Indígena	0
14	Norte	Parda	-1
15	Norte	Preta	0
16	Sudeste	Amarela	0
17	Sudeste	Branca	1
18	Sudeste	Indígena	0
19	Sudeste	Parda	-2
20	Sudeste	Preta	1
21	Sul	Amarela	0
22	Sul	Branca	0
23	Sul	Indígena	0
24	Sul	Parda	0
25	Sul	Preta	-1

Exercícios:

(4) Construa a *query* que retorne o percentual de alunos que respondeu 'Sim' ter tomado bebida alcoólica em cada raça e agrupe por região. (Use a view V_RegiaoRacaBebida criada na pergunta 1 para calcular este percentual por região e raça: total de respostas Sim por raça dividido pelo total de respostas Sim ou Não).

B00004=1 são os alunos que aceitaram responder o questionário.
B01002 representação cor/raça.
B05002A representa a resposta se tomou bebida alcoólica
regiao - codigo da regiao.

- (4.1) Qual raça, em cada região, tem o maior percentual de respostas 'Sim' ter tomado bebida alcoólica?
- (4.2) Forneça a query que retorne uma linha com a região e a raça de maior percentual de alunos com resposta 'Sim' para ter tomado bebida alcoólica.

Exercícios:

(4) (Explicação passo 1)

- A query a seguir usa a view V_RegiaoRacaBebida para fazer INNER JOIN com a Tabela Quest_aluno. A view V_RegiaoRacaBebida contém os totais de respostas que são usados como denominadores para encontrar o percentual por região e raça.

INNER JOIN V_RegiaoRacaBebida V ON V.regiao=RG.categoria AND V.raca=R.categoria

- Assim, com as respectivas colunas pareadas é possível calcular o total de Sim em cada região e raça sobre o total de **V_RegiaoRacaBebida (Sim Toumou bebida / (Total de respostas com Sim ou Não))**.

```
SELECT RG.categoria Regiao,R.categoria Raca, 100.0*COUNT(R.categoria) /V.total  as Percentual
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
INNER JOIN V_RegiaoRacaBebida V ON V.regiao=RG.categoria AND V.raca=R.categoria
WHERE B00004=1 AND T.categoria IN ('Sim')
GROUP BY RG.categoria,R.categoria
ORDER BY RG.categoria, PERCENTUAL DESC;
```

Exercícios:

(4) (Explicação passo 2)

- A condição no INNER JOIN seleciona somente os valores pareados (iguais entre as tabelas Quest_aluno e TomouBebida)
- Na condição do WHERE é feito uma restrição para selecionar somente os casos de Sim tomou bebida alcoólica.

```
SELECT RG.categoria Regiao,R.categoria Raca, 100.0*COUNT(R.categoria) /V.total  as Percentual
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
INNER JOIN V_RegiaoRacaBebida V ON V.regiao=RG.categoria AND V.raca=R.categoria
WHERE B00004=1 AND T.categoria IN ('Sim')
GROUP BY RG.categoria,R.categoria
ORDER BY RG.categoria, PERCENTUAL DESC;
```

Exercícios:

(4) (Explicação passo 3)

- B00004=1 seleciona os casos que os alunos aceitaram participar da pesquisa
- O ORDER BY usa a classificação ascendente por regiao e descendente por percentual para exibir os maiores percentuais por região primeiro, assim fica mais fácil de identificar por raça o maior percentual em cada região.

```
SELECT RG.categoria Regiao,R.categoria Raca, 100.0*COUNT(R.categoria) /V.total  as Percentual
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
INNER JOIN V_RegiaoRacaBebida V ON V.regiao=RG.categoria AND V.raca=R.categoria
WHERE B00004=1 AND T.categoria IN ('Sim')
GROUP BY RG.categoria,R.categoria
ORDER BY RG.categoria, PERCENTUAL DESC;
```

Exercícios:

(4) Resultado

```
SELECT RG.categoria Regiao,R.categoria Raca, 100.0*COUNT(R.categoria) /V.total  as Percentual
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A AND A.B05002A BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
INNER JOIN V_RegiaoRacaBebida V ON V.regiao=RG.categoria AND V.raca=R.categoria
WHERE B00004<>0 AND T.categoria IN ('Sim')
GROUP BY RG.categoria,R.categoria
ORDER BY RG.categoria,PERCENTUAL DESC;
```

(4.1) Qual raça, em cada região, tem o maior percentual de respostas 'Sim' ter tomado bebida alcoólica?

	Regiao	Raca	Percentual
1	Centro-Oeste	Preta	67
2	Centro-Oeste	Parda	66
3	Centro-Oeste	Branca	65
4	Centro-Oeste	Amarela	63
5	Centro-Oeste	Indígena	59
6	Nordeste	Preta	64
7	Nordeste	Parda	61
8	Nordeste	Amarela	61
9	Nordeste	Indígena	59
10	Nordeste	Branca	57
11	Norte	Preta	62
12	Norte	Amarela	61
13	Norte	Parda	59
14	Norte	Branca	58
15	Norte	Indígena	47
16	Sudeste	Preta	71
17	Sudeste	Amarela	67
18	Sudeste	Parda	66
19	Sudeste	Indígena	66
20	Sudeste	Branca	65
21	Sul	Preta	77
22	Sul	Parda	74
23	Sul	Indígena	71
24	Sul	Branca	70
25	Sul	Amarela	68

Exercícios:

(4.2) Forneça a query que retorne uma linha com a Região e a raça de maior percentual de alunos com resposta 'Sim' para ter tomado bebida alcoólica.

- **Explicação passo 1**
- Com o Resultado da query anterior cria-se uma visão para ser usada no FROM do SELECT. O uso da view é uma forma mais limpa de exibir a query final é esconder a complexidade.

- CREATE VIEW V_RegioaRacaBebidaPercentaul AS

```
SELECT RG.categoria Regiao,R.categoria Raca, 100.0*COUNT(R.categoria) /V.total  as Percentual
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A AND A.B05002A BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
INNER JOIN V_RegiaoRacaBebida V ON V.regiao=RG.categoria AND V.raca=R.categoria
WHERE B00004<>0 AND T.categoria IN ('Sim')
GROUP BY RG.categoria,R.categoria
```

Exercícios:

(4.2) **Resultado**

```
SELECT Regiao, raca, max(percentual) from (
SELECT  * from  V_RegioaRacaBebidaPercentual
);
```

	Regiao	raca	max(percentual)
1	Sul	Preta	77

Exercícios:

(4) Forneça a query com o percentual de alunos por região em cada raça que respondeu 'Sim' ter tomado bebida alcoólica. **(SOLUÇÃO ALTERNATIVA)**

Primeiro deve-se preparar a query com os totais que responderam Sim, ter tomado bebida agrupados por região e raça.

- A *query* é muito parecida com a anterior, com a diferença de uma subquery atuando como um denominador para calcular o percentual.
- Note que a subquery calcula o somatório de cada total de respostas válidas de acordo com a região e raça. Este tipo de script só é possível se o resultado da subquery for uma resposta única para cada par região e raça (retornar uma única linha e coluna). Veremos mais detalhes deste tipo de query nas próximas aulas.

```
SELECT RG.categoria Regiao,R.categoria Raca, 100.0*COUNT(R.categoria) / (SELECT  sum(total) FROM
V_RegiaoRacaBebida V WHERE V.regiao=RG.categoria AND V.raca=R.categoria) as Percentual
FROM Quest_aluno A
INNER JOIN Raca R ON A.B01002=R.B01002 AND A.B01002 BETWEEN 1 AND 5
INNER JOIN TomouBebida T ON T.B05002A = A.B05002A AND A.B05002A BETWEEN 1 AND 2
INNER JOIN Regiao RG ON RG.cod_regiao = A.regiao
WHERE B00004<>0 AND T.categoria IN ('Sim')
GROUP BY RG.categoria,R.categoria
ORDER BY RG.categoria,PERCENTUAL DESC;
```

Exercícios:

(5) Avalie se há diferença socioeconômica importante entre os alunos que estudam na escola de situação Urbana e Rural para a resposta Sim sobre possuir computador em casa. (Para este exercício vamos usar atributo PESO_ALUNO_FREQ referente ao peso amostral do aluno).

B00004=1 são os alunos que aceitaram responder o questionário.

B01015b - contém as categorias sobre possuir computador em casa

Situacao - contém a situação da escola se é Rural ou Urbana

```
SELECT ST.categoria Situacao,SUM(A.PESO_ALUNO_FREQ) TOTAL
FROM Quest_aluno A
INNER JOIN Situacao ST ON ST.cod_situacao=A.situacao
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b AND A.B01015b BETWEEN 1 AND 2
WHERE B00004<>0 AND T.categoria IN ('Sim','Não')
GROUP BY ST.categoria;
```

	Situacao	TOTAL
1	Rural	1164161
2	Urbana	13791515

- O SELECT inclui a situação da localização escola, 1 Rural 2 Urbana, e um somatório do atributo peso_aluno_freq para encontrar uma estimativa do número de alunos. Como há uma agrupamento por categoria Rural ou Urbana o somatório será feito para estes dois casos.
- O INNER JOIN com PossuiComputador neste caso é redundante. É possível retirá-lo, mas para isso é preciso mudar a condição no WHERE T.categoria IN ('Sim','Não') para que seja selecionado somente as respostas de interesse. Para exercitar sua lógica faça esta melhoria na query e veja se o resultado vai mudar.

Exercícios:

(6) Quais municípios capitais que o percentual de alunos com computador em casa está abaixo da média nacional

B00004=1 são os alunos que aceitaram responder o questionário.

B01015b - contém as categorias sobre possuir computador em casa

municipio – contém os códigos dos municípios capitais

Primeiro, deve-se encontrar o **total** de alunos por município com computador e criar uma view para usar este total no denominador do cálculo percentual.

Segundo, deve-se calcular o percentual de alunos com computador por município usando a view criada;

Terceiro, usar as duas views para encontrar a média nacional deste percentual

Primeiro – Veja que foi usado INNER JOIN com a condição de igualdade para encontrar as combinações em que a resposta seja igual e depois usa-se o BETWEEN para selecionar somente as respostas válidas (1=Sim ou 2=Não).

```
CREATE VIEW V_MunicipioPC as
SELECT M.categoria Municipio, count(1) as total
FROM Quest_aluno A
INNER JOIN Municipio M ON M.cod_municipio_cap=A.municipio_cap
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b AND (A.B01015b BETWEEN 1 AND 2)
WHERE B00004<>0
GROUP BY M.categoria;
```

Exercícios:

(6) Quais municípios capitais que o percentual de alunos com computador em casa está abaixo da média nacional

B00004=1 são os alunos que aceitaram responder o questionário.

B01015b - contém as categorias sobre possuir computador em casa

municipio – contém os códigos dos municípios capitais

Primeiro deve-se encontrar o **total** de alunos por município com computador e criar uma view para usar este total no denominador do cálculo percentual.

Segundo deve-se calcular o percentual de alunos com computador por município usando a view criada para criar outra view;

Terceiro, usar as duas views para encontrar a média nacional deste percentual

Primeiro – Veja que foi usado INNER JOIN com condição de igualdade para encontrar as combinações em que a resposta seja igual e depois usa-se o Between para selecionar somente entre as respostas válidas (1=Sim ou 2=Não).

```
CREATE VIEW V_MunicipioPC as
SELECT M.categoria Municipio, count(1) as total
FROM Quest_aluno A
INNER JOIN Municipio M ON M.cod_municipio_cap=A.municipio_cap
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b AND (A.B01015b BETWEEN 1 AND 2)
WHERE B00004<>0
GROUP BY M.categoria;
```

Exercícios:

(6) Quais municípios capitais que o percentual de alunos com computador em casa está abaixo da média nacional

Segundo deve-se calcular o percentual de alunos com computador por município usando a view criada;

Veja que foi usado INNER JOIN com condição de igualdade para concatenar as tabelas Quest_aluno e Municipio e depois no WHERE limita-se somente as Respostas Sim Possui computador em casa.

Um terceiro INNER JOIN é feito entre V_MunicipioPC e Municipio para recuperar o valor total e usá-lo como denominador para calcular o percentual.

```
CREATE VIEW MunicipioPCPercentual as
SELECT M.categoria Municipio, (100.0*count(1)/ (V.TOTAL))  as Percentual
FROM Quest_aluno A
INNER JOIN Municipio M ON M.cod_municipio_cap=A.municipio_cap
INNER JOIN PossuiComputador T ON T.B01015b = A.B01015b
INNER JOIN V_MunicipioPC V ON V.Municipio=M.categoria
WHERE B00004<>0 AND T.categoria IN ('Sim')
GROUP BY M.categoria
```

Exercícios:

(6) Quais municípios capitais que o percentual de alunos com computador em casa está abaixo da média nacional

Terceiro encontrar os **município abaixo da média nacional**

Com a view MunicipioPCPercentual seleciona-se os atributos município e percentual e através da condição do WHERE são feitos testes para encontrar os percentuais abaixo da média nacional. A subquery usada no WHERE retorna um único valor e coluna com a média nacional.

```
SELECT Municipio, Percentual FROM MunicipioPCPercentual
where Percentual <  (SELECT AVG(Percentual) FROM MunicipioPCPercentual)
ORDER BY 2 ;
```

	Municipio	Percentual
1	Belém	59
2	Maceió	60
3	São Luís	60
4	Fortaleza	61
5	Teresina	61
6	Aracaju	63
7	Não é capital	63
8	Rio Branco	63
9	Natal	64
10	Macapá	65
11	Boa Vista	67
12	Cuiabá	70
13	João Pessoa	70
14	Manaus	71

- Agora que você já estou um pouco da base de dados da Pense, você pode tentar aplicar o peso nos exercícios anteriores que não fez uso dele para verificar se o entendimento da resposta observada muda.
- Pratique a construção de consultas, leia o material fornecido. Exercitar a construção de query SQL ajuda no seu aprimoramento.

Obrigado