Bases de Dados

Módulo 20: Baco de dados Analítico

Prof. André Bruno de Oliveira

28/05/24 10:03

Introdução DATA WAREHOUSE

- O que é um Data WareHouse (DW) ?
  - Uma DW pode ser definida como uma coleção de dados orientada a assunto, integrada, não volátil, variável no tempo para o suporte às decisões da gerência.
  - Os DW oferecem acesso a dados para análise complexa, descoberta de conhecimento e tomada de decisão. Eles dão suporte a demandas de alto desempenho sobre os dados e informações de uma organização.

1 Introdução DATA WAREHOUSE

- Entre as aplicações que interagem com o DW pode-se citar: OLAP e DSS e mineração de dados.
- OLAP é a abreviação de processamento analítico on-line, um termo usado para descrever a análise de dados DW. O OLAP exige utilização de computação distribuída, capacidade alta de armazenamento e um bom poder de processamento.
- DSS (Decision Support System - sistemas de apoio à decisão) São sistemas que fazem uso de dados de alto nível para apoiar decisões da liderança nas empresas.
- EIS (Executive Information Systems - Sistemas de Informação Executivos) Permite gerar relatórios com informações gerencias a partir de aplicações de alto nível. É considerada uma forma especializada de DSS voltada para informações de gerenciais.
- A mineração de dados por exemplo é usada para busca de novo conhecimento não detectado nos dados.

1 Introdução DATA WAREHOUSE

- Grosso modo os dados estão divididos em duas abordagens: i) Dados estruturados (relatórios e planilhas) e; ii) e informações sem clareza que precisam de técnicas matemáticas para descoberta da informação.
  - Ex.:
    - Uso de modelos estatísticos para estabelecer relações entre os dados: Use de faixa etária combinado com a renda de uma população para determinar o grupo alvo sobre venda de cursos.
    - Uso de modelos preditivos sobre dados históricos para prever períodos de melhorar investimento. Por exemplo, venda de passagens aéreas.

1.2 Características dos data warehouses

- O DW faz uso do modelo de dados multidimensional que mantem um depósito de dados integrados de múltiplas fontes.
- Em comparação com os bancos de dados transacionais, os DW são não voláteis. Isso significa que as informações no DW mudam com muito menos frequência.
- Diferentemente dos bancos transacionais, DW trabalham com dados históricos. As informações têm um nível de detalhamento menor do que nos BD transacionais e atualizações são incrementais vinculadas a uma política da organização.
  - Exemplo: Novas informações do mesmo produto são inseridas gerando duplicidades e uso de *surrogate* em tabelas para favorecer o poder processamento e a descoberta de informações relevantes.

1.2 Características dos data warehouses

- A abaixo a figura oferece uma visão geral da estrutura conceitual de um DW.
- O processo inteiro inclui limpeza e reformatação dos dados antes que sejam carregados no DW. Este processo é tratado por soluções conhecidas como ferramentas de ETL (extração, transformação e carga).
  - Perceba que no processo de elaboração de uma DW é fundamental reunir *softwares* capazes de transformar a informação para um esquema de linhas e colunas. Isso envolve o trabalho de profissionais capacitados.

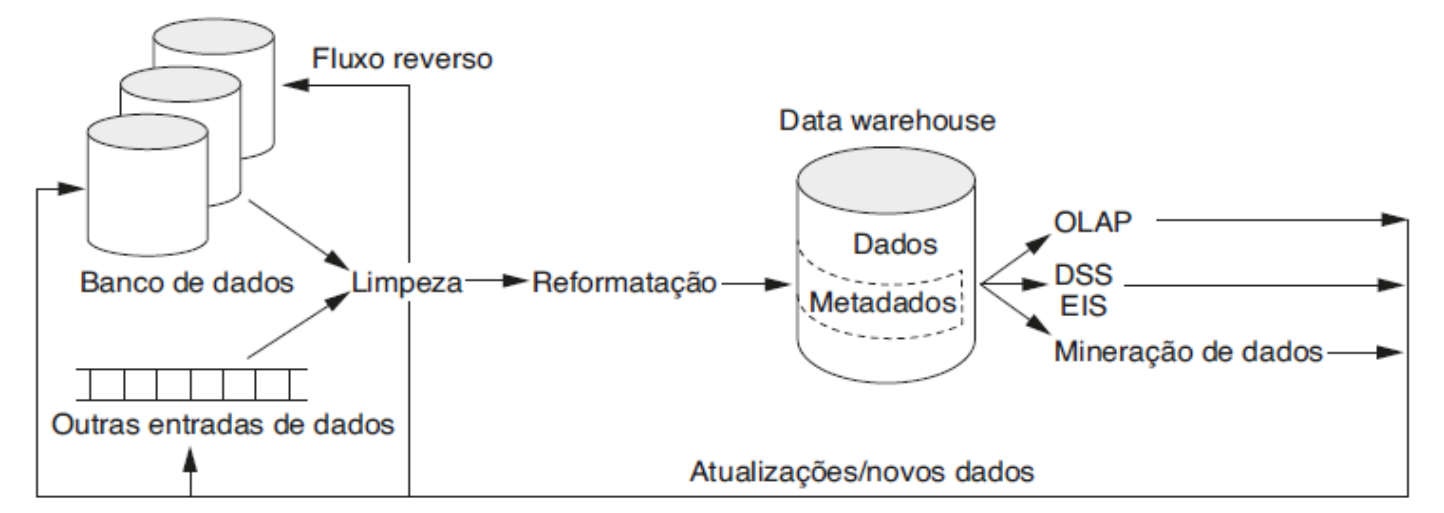

1.2 Características dos data warehouses

- No backend ocorre o processo de descoberta do conhecimento que podem gerar novas informações relevantes, como as regras de agregação envolvendo somatório, média, mínimo e máximo. Essas informações aparecem na figura num processo de retroalimentação (atualização de novos dados)
- O volume de dados chaga na ordem de petabytes (10^{12}).

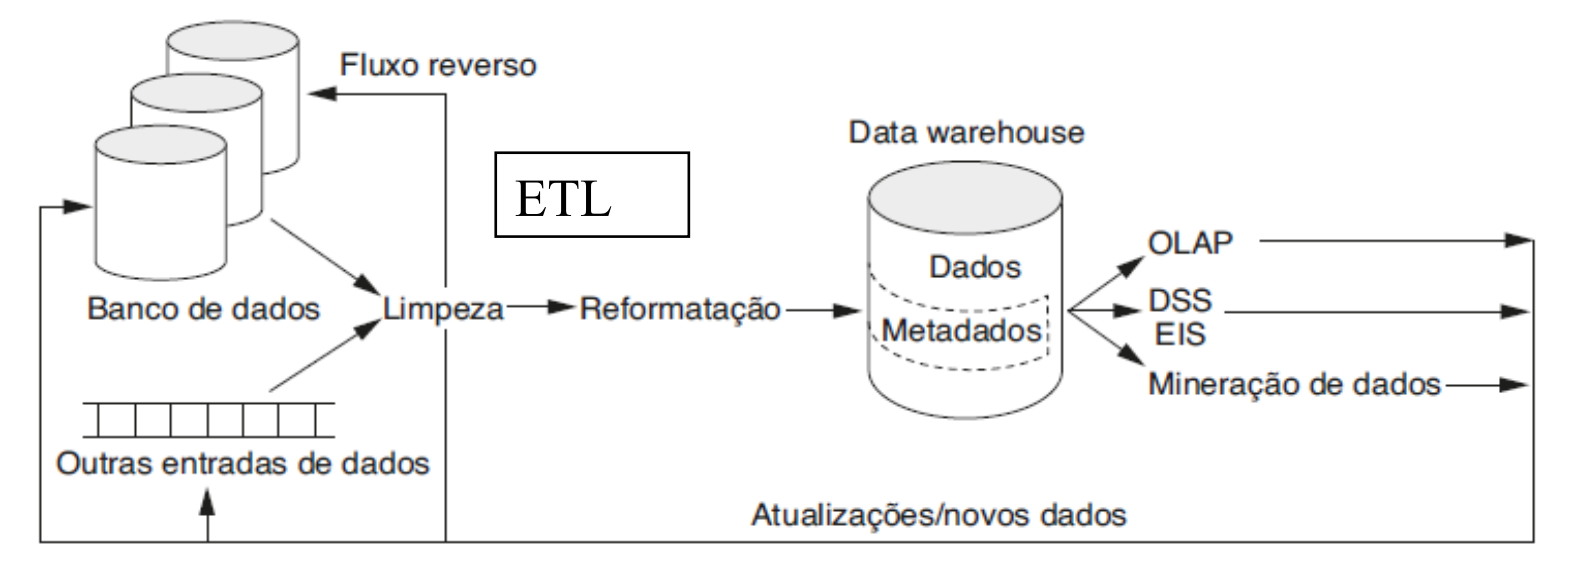

1.3 Modelagem de dados para DW

- Dois esquemas multidimensionais comuns são o esquema estrela e o esquema floco de neve. O esquema estrela consiste em uma tabela de fatos com uma única tabela para cada dimensão. A tabela fatos possui as FK de cada tabela de dimensão, numa relação de 1,N. Assim, uma tabela fatos possui muito mais registros do que a tabela de dimensão.
- Cada linha da tabela fatos contém valores resumos resultado de cruzamentos que consideram as características de cada linha da tabela dimensão, isso é feito na etapa de ETL. A inclusão de linhas nestas tabelas fatos e dimensão demanda estudo e planejamento.

Esquema estrela

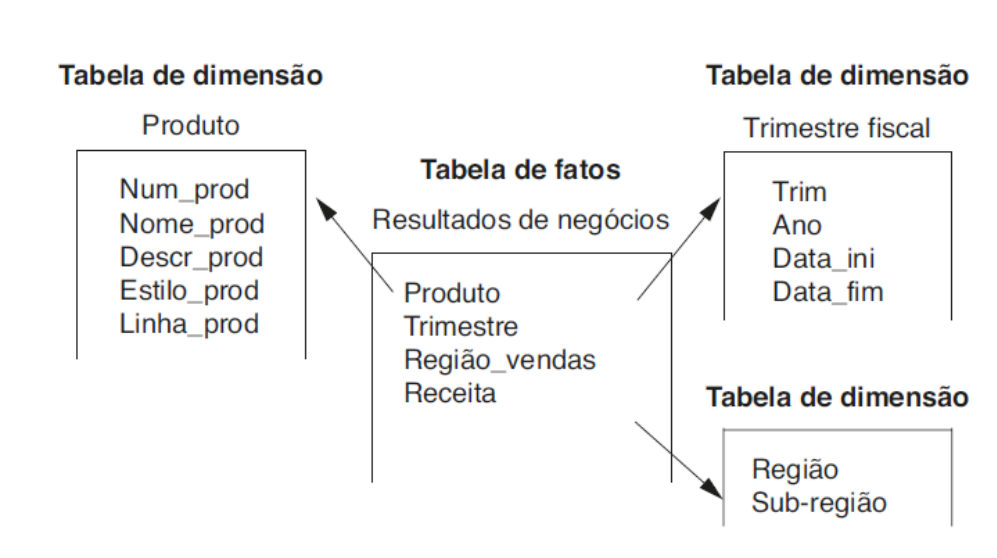

1.3 Modelagem de dados para DW

- O esquema floco de neve é uma variação do esquema estrela em que as tabelas de dimensões de um esquema estrela são organizadas em uma hierarquia para normalizá-las. A normalização visa reduzir as repetições que acabam aumentando o tamanho da tabela dimensão e impactando no espaço ocupado em HD, contudo o aumento de relacionamentos aumenta o custo das *queries* devido aos JOINs.

Esquema floco de neve

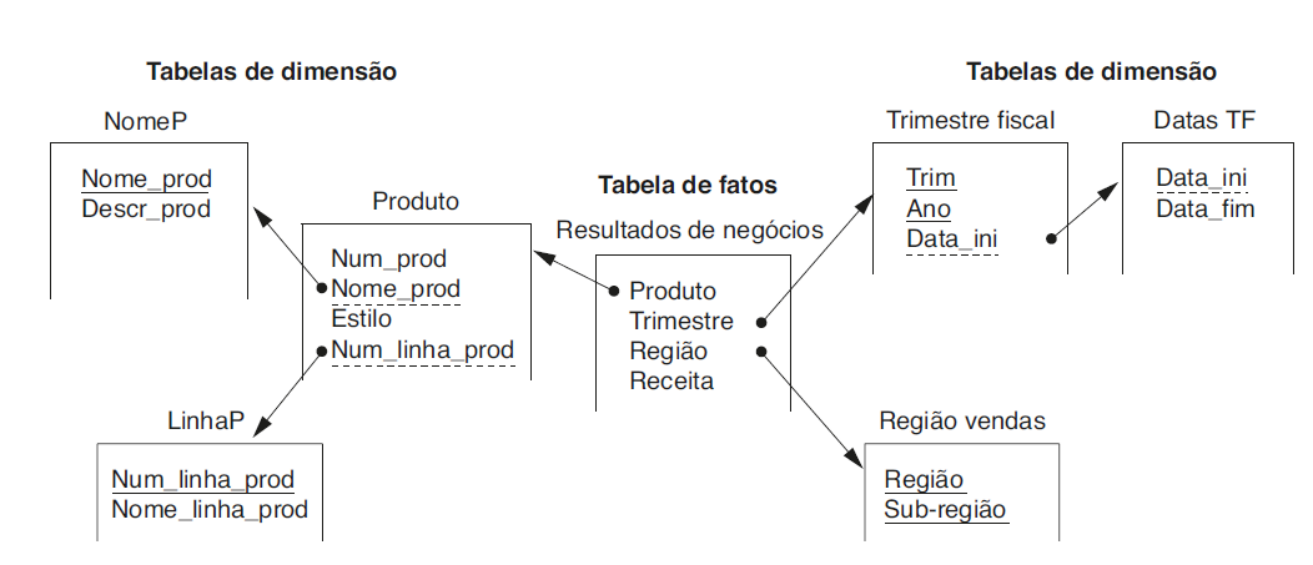

1.3 Modelagem de dados para DW

- O modelo de armazenamento multidimensional envolve dois tipos de tabelas: tabela dimensão e tabela fato.
- Uma tabela de dimensão consiste em tuplas de atributos da dimensão: Costumam usar *surrogate* para manter dados históricos.
- Uma tabela fato pode ser imaginada como tendo tuplas, uma para cada fato registrado. Cada tupla é composto pelo valor agregado e pelas FK de cada tabela dimensão.

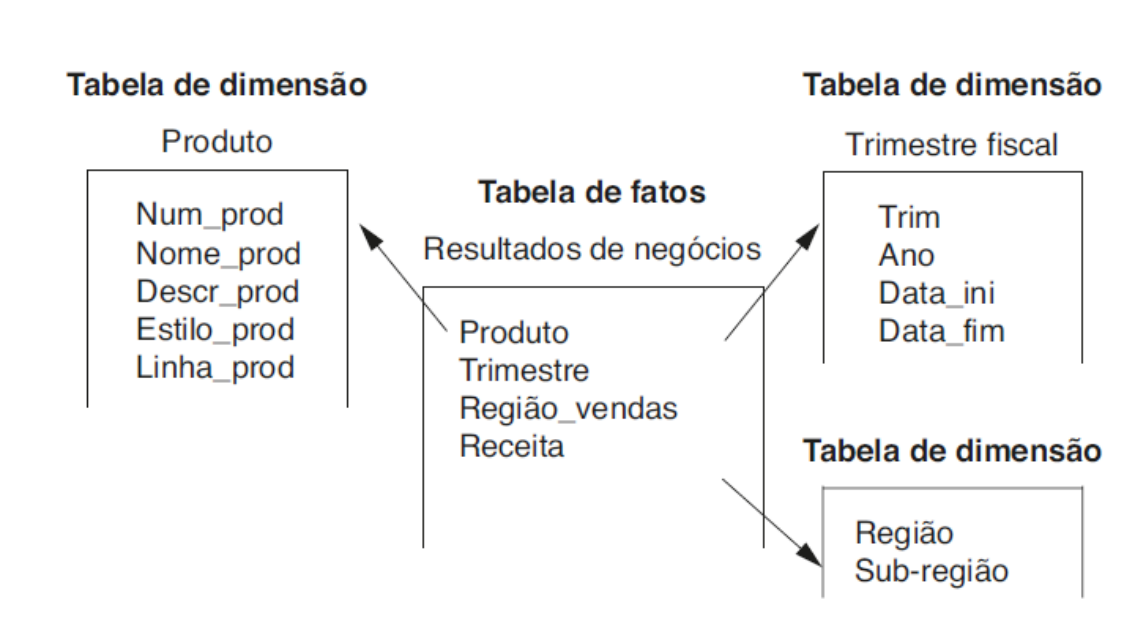

1.3 Modelagem de dados para DW

- O DW faz uso dos relacionamentos inerentes aos dados para gerar matrizes multidimensionais chamadas de cubos de dados quando se tem 3 dimensões. Quando há mais de 3 dimensões denomina-se hipercubos.
  - Exemplo: Imagine uma planilha de vendas regionais por produto e região. Os produtos dispostos como linhas e as receitas de vendas para cada região compreendendo as colunas. O acréscimo de uma dimensão de tempo, como os trimestres fiscais de uma organização, produz uma matriz tridimensional, neste caso é possível representar estas dimensões usando um cubo de dados.

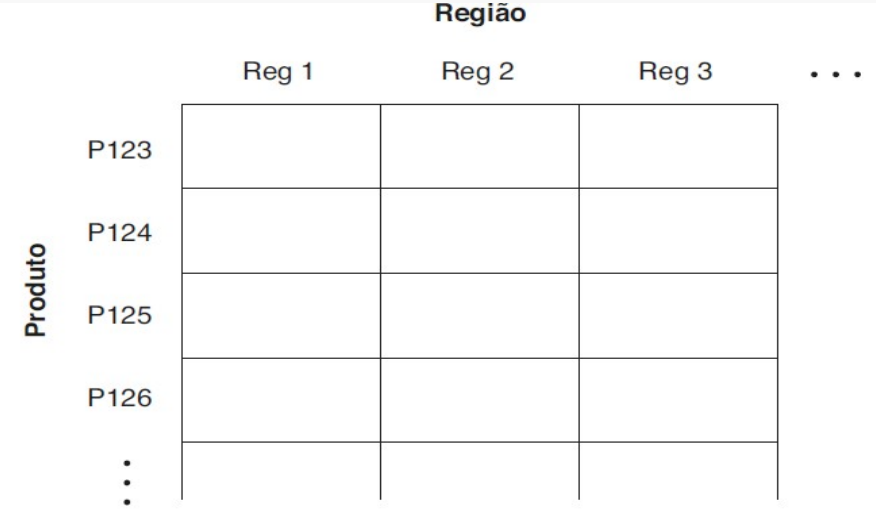

1.3 Modelagem de dados para DW

- Veja a figura abaixo de cubo tridimensional: Um modelo com as dimensões, produto, receita de vendas por região e tempo por trimestre fiscal. Cada célula contém um produto e região específicas. Este tipo de modelo usa uma tecnologia que permite realizar consultas diretamente em qualquer combinação de dimensões, evitando consultas complexas diretamente no banco de dados.

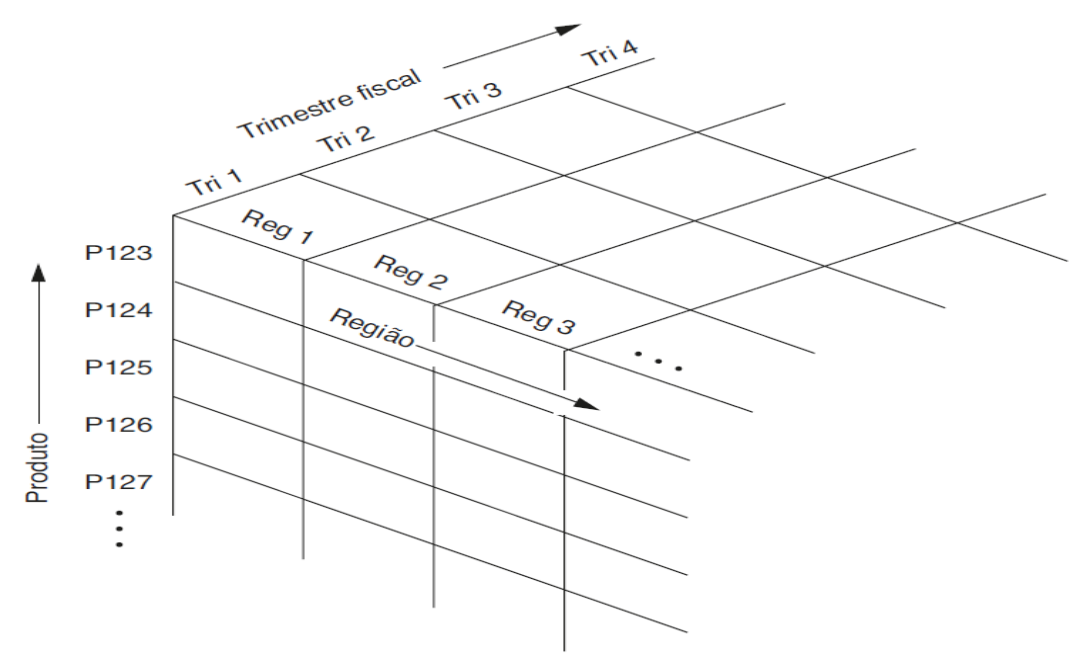

1.4 Funcionalidade típica de um DW

- Os data DW existem para facilitar as consultas complexas, com uso intenso de dados. Neste sentido, precisam oferecer suporte à consulta muito maior e mais eficiente do que é exigido pelos bancos de dados transacionais.
- Entre as ferramentas e técnicas usadas estão no ROLAP, MOLAP:
- ROLAP (Relational On Line Analytical Processing) - Os dados são armazenados no BD relacional em estruturas multidimensionais e o SQL é utilizado para realizar as consultas.
- O MOLAP (Multidimensional On Line Analytical Processing) usa um cubo multidimensional que acessa os dados armazenados por meio de várias combinações. Os dados são pré-calculados, pré-resumidos e armazenados neste cubo, o que garante uma boa eficiência na análise dos dados.

1.4 Funcionalidade típica de um DW

- MOLAP oferece boa performance nas opções de *slicing and dicing* (quebrar um corpo de informações em partes menores ou examiná-lo de diferentes pontos de vista para que você possa compreendê-lo melhor).
- O ROLAP em comparação com o MOLAP é menos eficiente no tempo de resposta, porque ele armazena os dados em linhas e colunas das tabelas do BD e realiza junções, com isso o desempenho não é tão eficiente.

1.4 Funcionalidade típica de um DW

- O MOLAP é limitado na quantidade de dados que consegue guardar/manipular em memória. Além disso, adicionar dimensões nesta solução é mais complicado, ao invés disso costuma-se reconstruir as dimensões de dados.
- Pode-se dizer que os sistemas ROLAP são adequados para guardar grandes quantidades de dados, usando um processamento paralelo e tecnologias separadas, enquanto os sistemas MOLAP são adequados para aplicações departamentais com pequenos volumes de dados.

Exemplo de BI com dados históricos - 2022

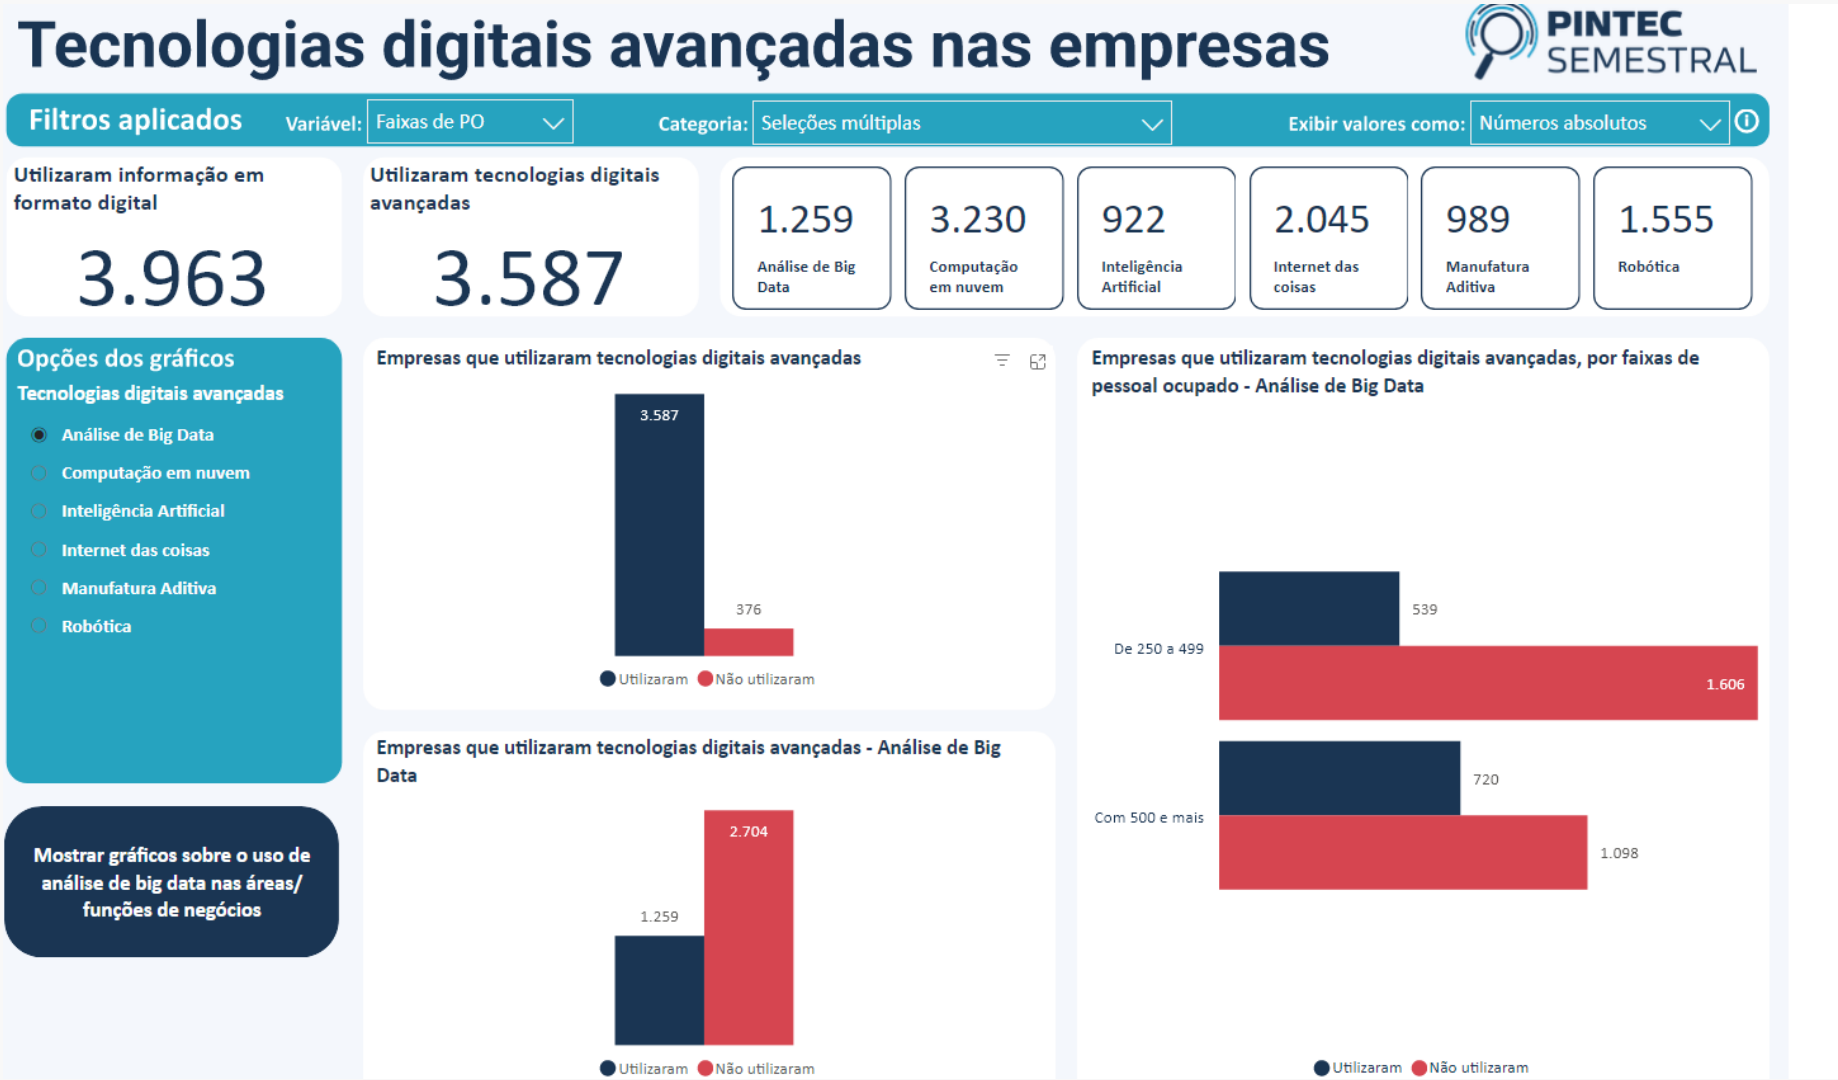

Fonte: https://pintec.ibge.gov.br/PintecSemestral/DadosResultadosPintecSemestral

Exemplo de BI com dados históricos - 2022

2.239	7.055	1.619	4.662	1.843	2.657
Análise de Big Data	Computação em nuvem	Inteligência Artificial	Internet das coisas	Manufatura Aditiva	Robótica

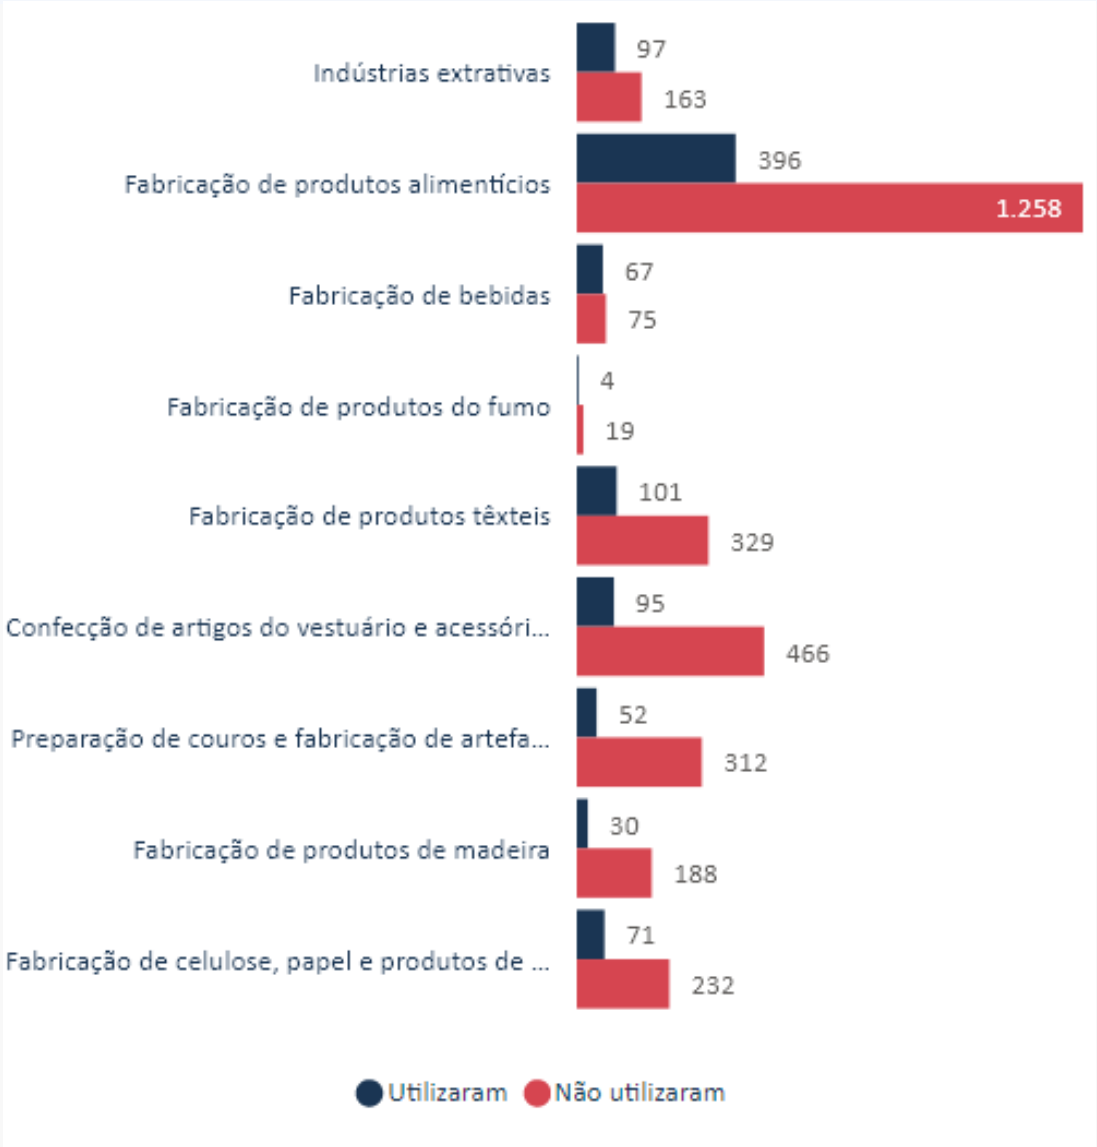

IBGE
Escola Nacional de Ciências Estatísticas ENCE

2 O que é um Data Lake ?

- Um data lake é um repositório de dados estruturados (tabelas de banco de dados, planilhas do Excel), semiestruturados (arquivos XML, páginas da WEB) e não estruturados (imagens, arquivos de áudio, mensagens de texto) em qualquer formato e tamanho e em qualquer escala que possam ser analisados facilmente.
- Tem sido apontado como uma opção mais adequada para empresas que precisam de acesso a dados brutos, não estruturados e em grande volume, que não podem ser facilmente processados em um Data DW.
- É uma tecnologia projetada para armazenar dados em sua forma bruta, sem a necessidade de transformação ou organização prévia. Isso permite que os usuários acessem uma ampla variedade de dados.

2.1 Características do Data Lake

1. Os dados são gravados sem tratamento prévio.
2. Repositório centralizado que permite armazenar todos os dados estruturados e não estruturados em qualquer escala, permitindo que várias pessoas consigam acessar esses dados.
3. Facilidade para capturar dado num tempo menor que o DW.
4. Usa o conceito de ELT (Extrair, carregar e tratar).

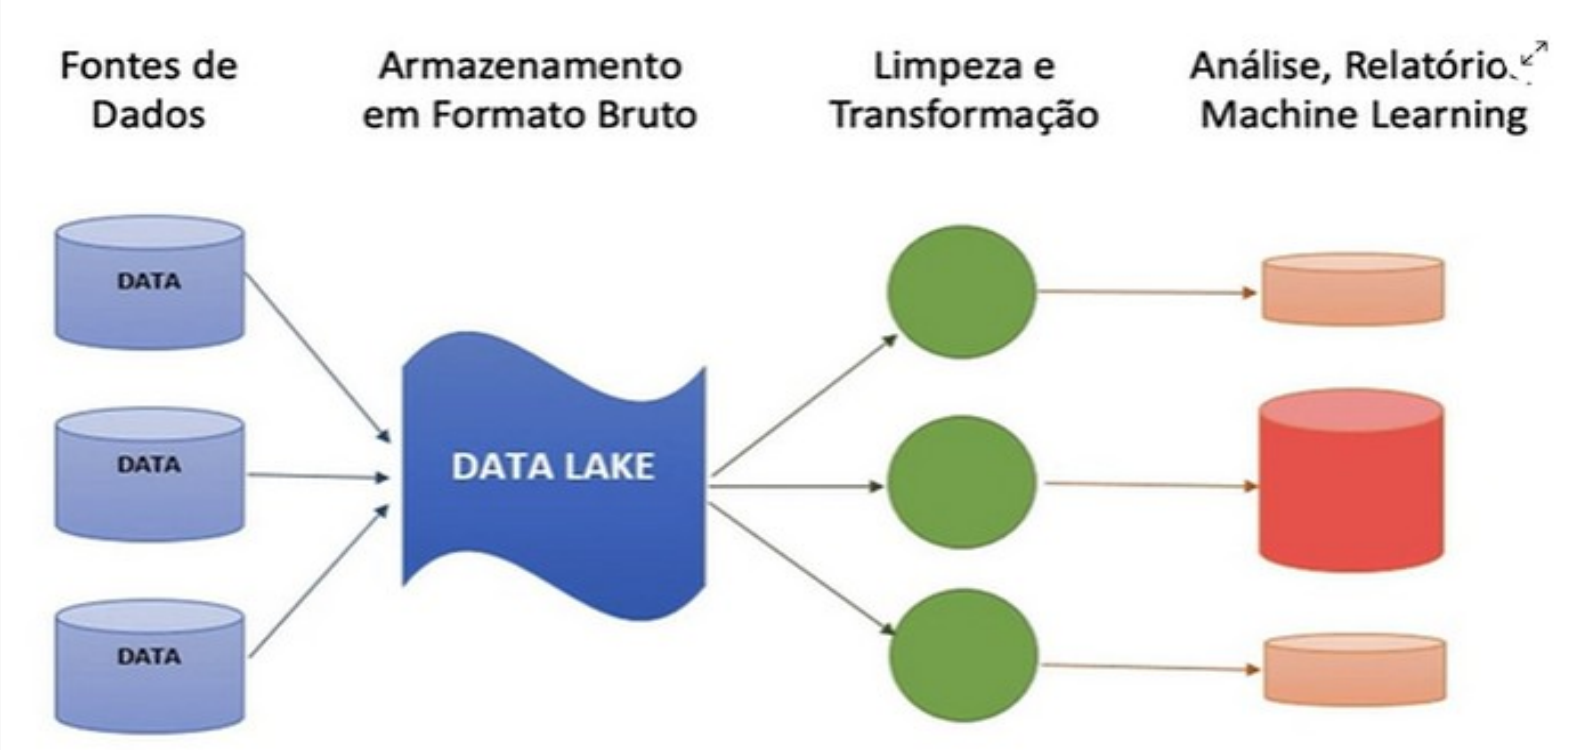

2.2 Data Lake e Data Warehouse

- Atualmente um modelo de arquitetura utilizado é a leitura dos dados de origem sendo gravado em um Data Lake, e posteriormente transformadas e carregadas num DW, com isso soma-se as vantagens de ambas as tecnologias:

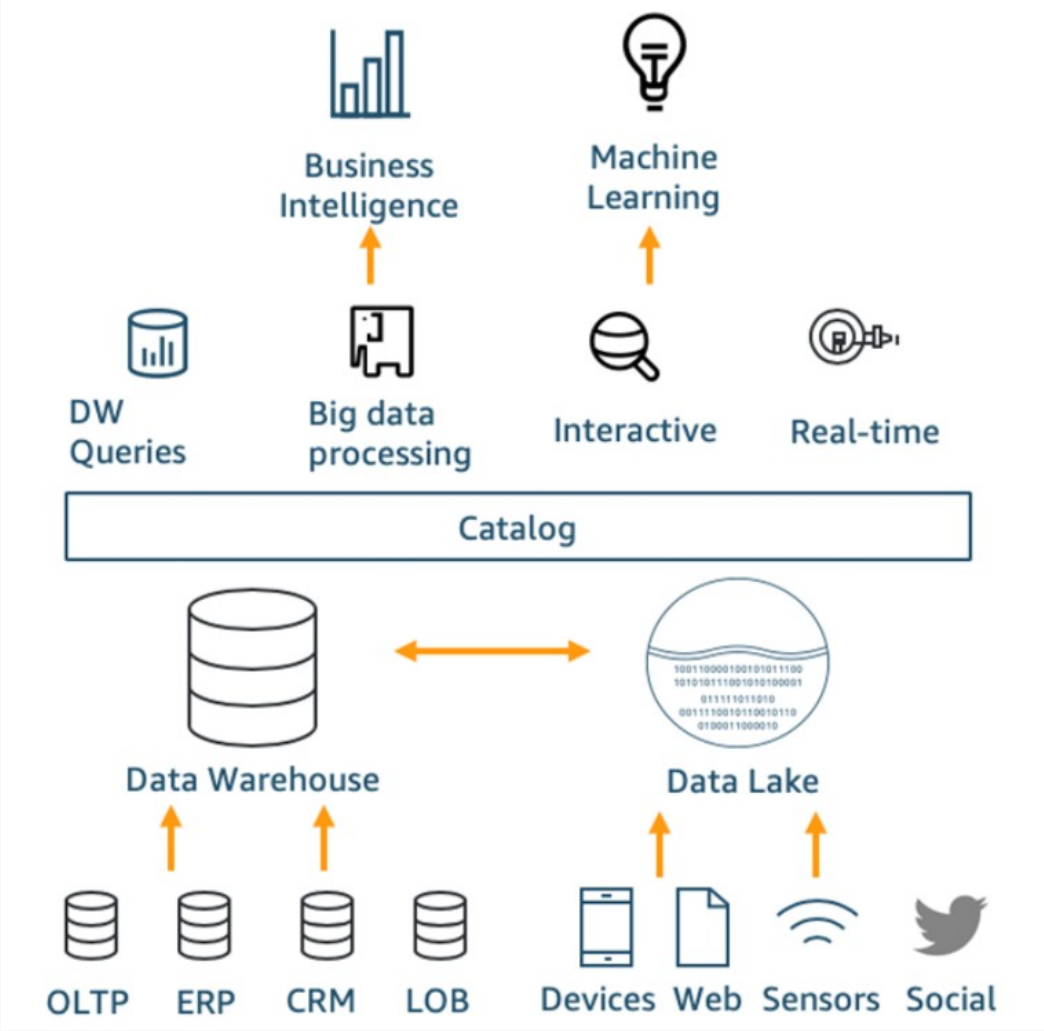

2.2 Data Lake e Data Warehouse

- A União do data lake com o DW traz velocidade na captura e maior flexibilidade na leitura dos dados, confiabilidade e organização. A decisão de migrar os dados para o DW depende da necessidade do negócio, pois os dois ambientes podem servir de fonte para análise dos dados. No caso do data lake, é preciso preparar o esquema de leitura e no DW os dados precisam ser transformadas e carregadas.

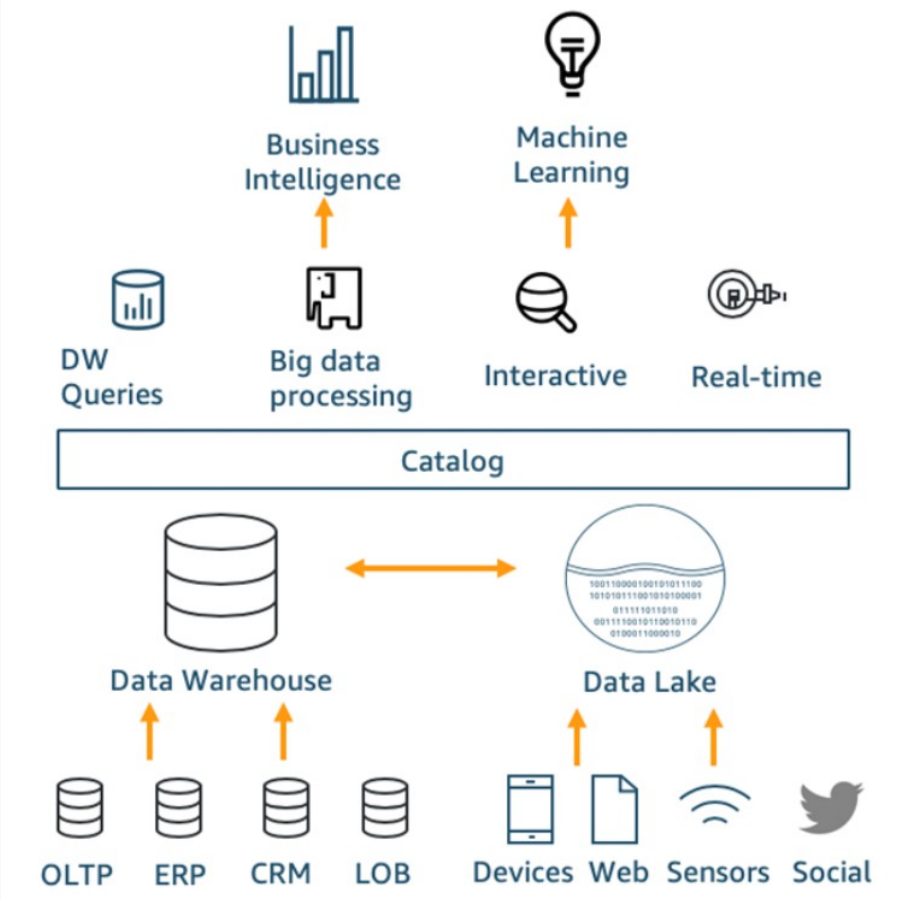

2.2 Data Lake versus Data Warehouse

- O esquema na leitura do data lake garante que qualquer tipo de dados armazenado em sua forma bruta possa ser posteriormente lido. Isso evita a transformação.

	Data lake	Data warehouse
Tipo	Estruturado, semiestruturado, não estruturado	Estruturado
	Relacional, não relacional	Relacional
Esquema	Esquema na leitura	Esquema na gravação
Formato	Brutos, não filtrados	Processado, examinado
Fontes	Big Data, IoT, mídia social, dados de streaming	Aplicativo, negócios, dados transacionais, relatórios em lotes
Escalabilidade	Fácil de escalar a baixo custo	Difícil e caro de escalar
Usuários	Cientistas de dados, engenheiros de dados	Profissionais de data warehouse, analistas de negócios
Casos de uso	Aprendizado de máquina, análise preditiva, análise em tempo real	Relatórios com dados agregados, BI

2.3 Onde é usado o date lake?

- **Streaming de mídia**. As empresas de streaming baseadas em assinatura coletam e processam informações sobre o comportamento do cliente, que podem usar para melhorar o algoritmo de recomendação.
- **Finanças**. Os bancos de investimento usam os dados de mercado mais atualizados, que são coletados e armazenados em tempo real, para gerenciar com eficiência os riscos de portfólio.
- **Serviços de saúde**. As organizações de saúde dependem de Big Data para melhorar a qualidade do atendimento aos pacientes. Os hospitais usam grandes quantidades de dados históricos para simplificar as etapas de atendimento dos pacientes, resultando em melhores resultados e redução do custo do atendimento.
- **Vendas**. Cientistas de dados e engenheiros de vendas geralmente criam modelos preditivos para ajudar a determinar o comportamento do cliente.

2.4 Data lakehouse

- Um data lake mal gerenciado prejudica a integridade dos dados pode levar a problemas de desempenho e riscos de segurança. Podem ocorrer problemas relacionados ao controle de qualidade e inconsistências.
- O data lakehouse inclui os desafios do data lake adicionando uma camada de armazenamento diretamente sobre o data lake com controle de transação ACID (o Delta Lake).
- **Diferença entre data lake e data lakehouse**:
  - O data lakehouse usa esquema para organização dos dados na leitura e na gravação, diferindo do data lake que possui esquema somente na leitura.
  - Inclui os profissionais tradicionais do DW e do Data lake.
  - Inclui a extração de relatórios de BI.
  - A carga de dados no Delta lake ajuda evitar a duplicidade de dados.

2.5 Como é a arquitetura de data lake

- Na sua essência, um data lake é um repositório de armazenamento sem nenhuma arquitetura definida
- O data lake deve possuir um gerenciador de recursos que permita executar tarefas consistentemente alocando a quantidade certa de dados, recursos e poder de computação aos locais certos.

O que é HADOOP ?

- Hadoop é uma estrutura de software open-source (código aberto) para armazenar dados em forma de arquivos e executar aplicações em clusters.
- Fornece armazenamento massivo (memória externa) para qualquer tipo de dado, grande poder de processamento e a capacidade de lidar com imenso número tarefas e trabalhos ocorrendo ao mesmo tempo.
- É constituído de um conjunto de ferramentas, aplicações e frameworks Java (com isso se torna uma solução portável) para o desenvolvimento de sistemas de computação escalável e distribuída.

Características

- As aplicações são codificadas em linguagem de alto nível (Java);
- Os dados, em princípio, são divididos em blocos de 64MB ou 128MB. Por exemplo, se um arquivo tiver 192 megabytes e a configuração de cada cluster (nó slave) está preparada para trabalhar com blocos de 128 MB, uma parte ocupa todos os 128 e outra parte vai ser usada para manter 64 MB e será desperdiçada.

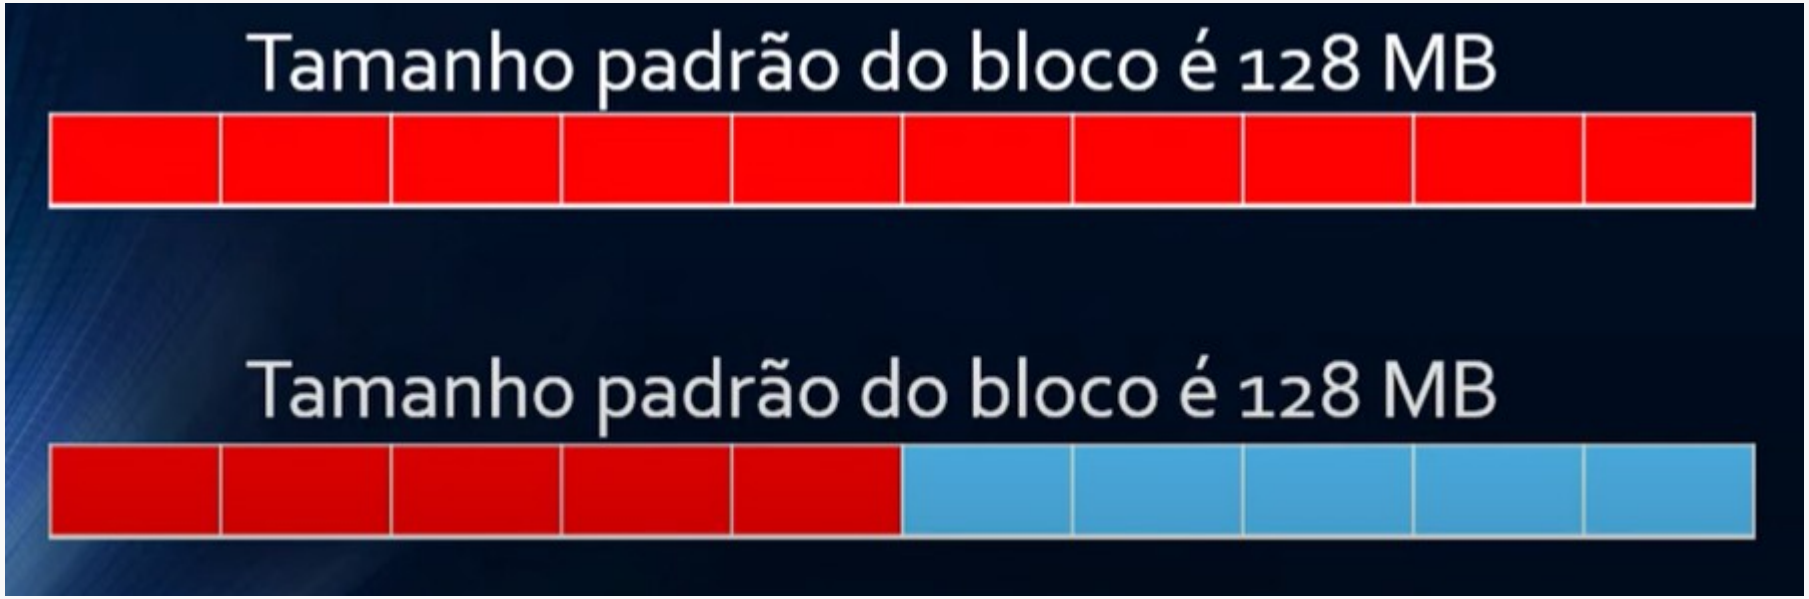

Características

- Possui a capacidade de detecção falhas e transferir o processamento para outro nó (cluster ou uma máquina do *cluster*);
- O nó que apresenta falha, uma vez reinicializado será automaticamente adicionado ao sistema para a realização de tarefas;
- A reinicialização de uma tarefa não afeta as restantes que estiverem sendo executadas em outros nós.
- O Hadoop é visto como um ecossistema, quando os nós individuais apresentam altas taxas de falha, os dados são replicados para outro cluster para que possam ser recuperados caso ocorram falhas mais graves. É um solução que tenta manter um auto equilíbrio para garantir a disponibilidade da informação.
- Está projetado para ser escalonado de um único computador para milhares de computadores em cluster, com cada máquina oferecendo computação e armazenamento locais. Cada nó possui um *master* com um conjunto de *slave*.

Vantagens do processamento distribuído

Exemplo da Google File System.

•i) Processamento distribuído. Cada nó (Chunk Server) recebe uma cópia do dado. Os arquivos são replicados.

•ii) Usa redundância de dados em mais de uma Chunk.

•iii) Como há mais de uma cópia aumenta a segurança contra perdas

•iv) Caso um nó apresente mal funcionamento, o arquivo pode ser recuperado em outro nó.

•v) Favorece a disponibilidade

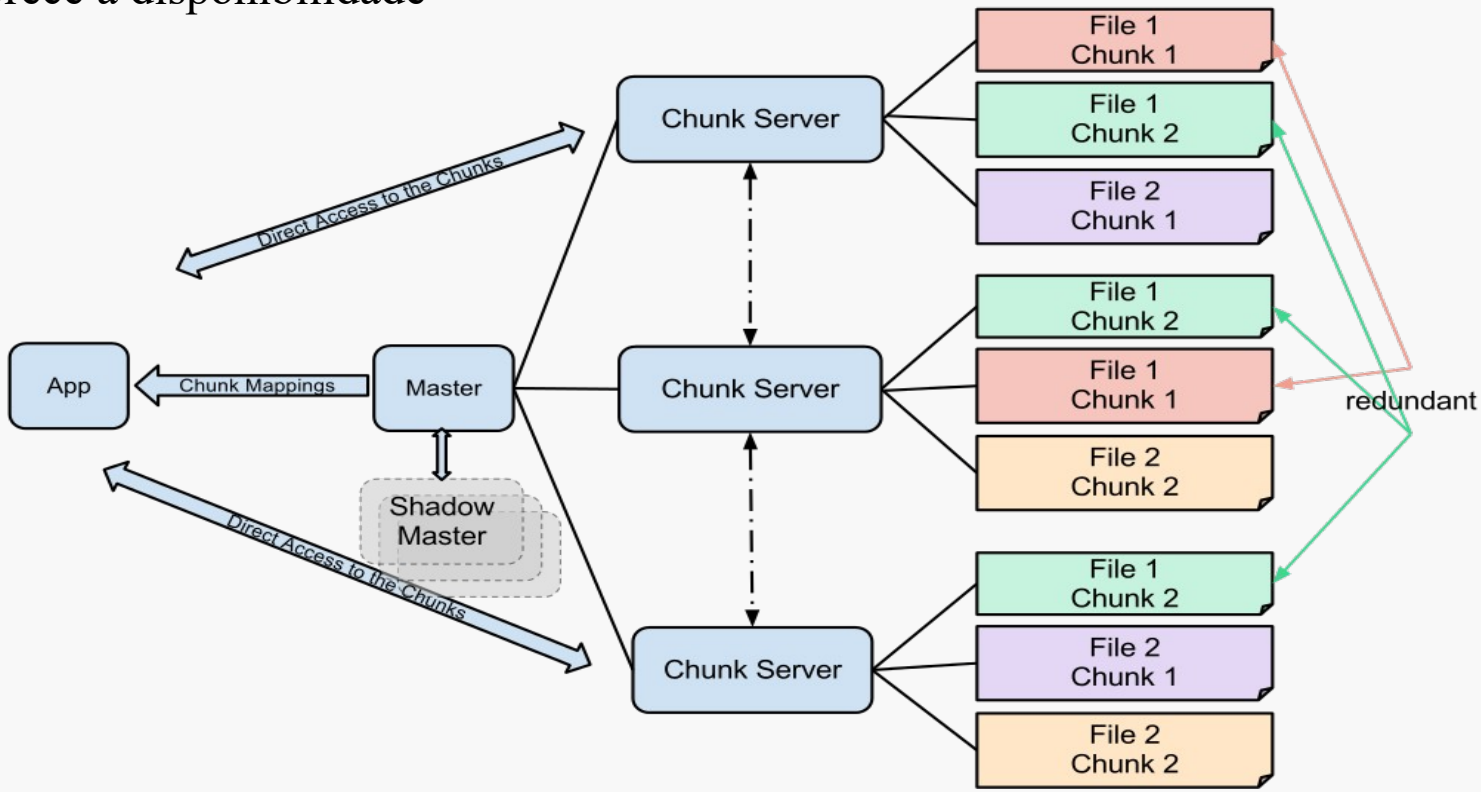

https://en.wikipedia.org/wiki/Google_File_System#Performance

IBGE
Escola Nacional de Ciências Estatísticas ENCE

Arquitetura

- **HDFS** acrônimo de Hadoop File System, é o sistema de arquivos distribuído tolerante a falhas que pode operar com milhares de computadores atuando como servidores, onde cada um pode armazenar uma parte do sistema de arquivos.

- **MapReduce** tem a função de converter grande volume de dados num conjunto de listas ordenadas, reduzindo o tamanho destes conjuntos e gerando listas ordenadas ainda menores. Oferece um modelo de programação paralela e distribuída. Possui duas operações:

I. MAP - No processo de mapeamento (Map), os dados são separados em pares de chave valor, transformados e filtrados. Então os dados são distribuídos para os nodes (clustes) e processados

II. REDUCE - No processo de redução, os dados são agregados em conjuntos de dados menores. Os dados resultantes do processo de redução são transformados em um formato padrão de chave-valor. Chave é a identificação da coleção de dados e o valor é conteúdo identificado pela chave.

Arquitetura do MapReduce

Input – entrada de dados

Splitting – Usa um algoritmo para dividir os dados e organizá-los em grupos segundo alguma característica. Por exemplo, posso pegar o 1º grupo e por no 1º cluster (Range) é uma abordagem boa para fazer buscas por índices.

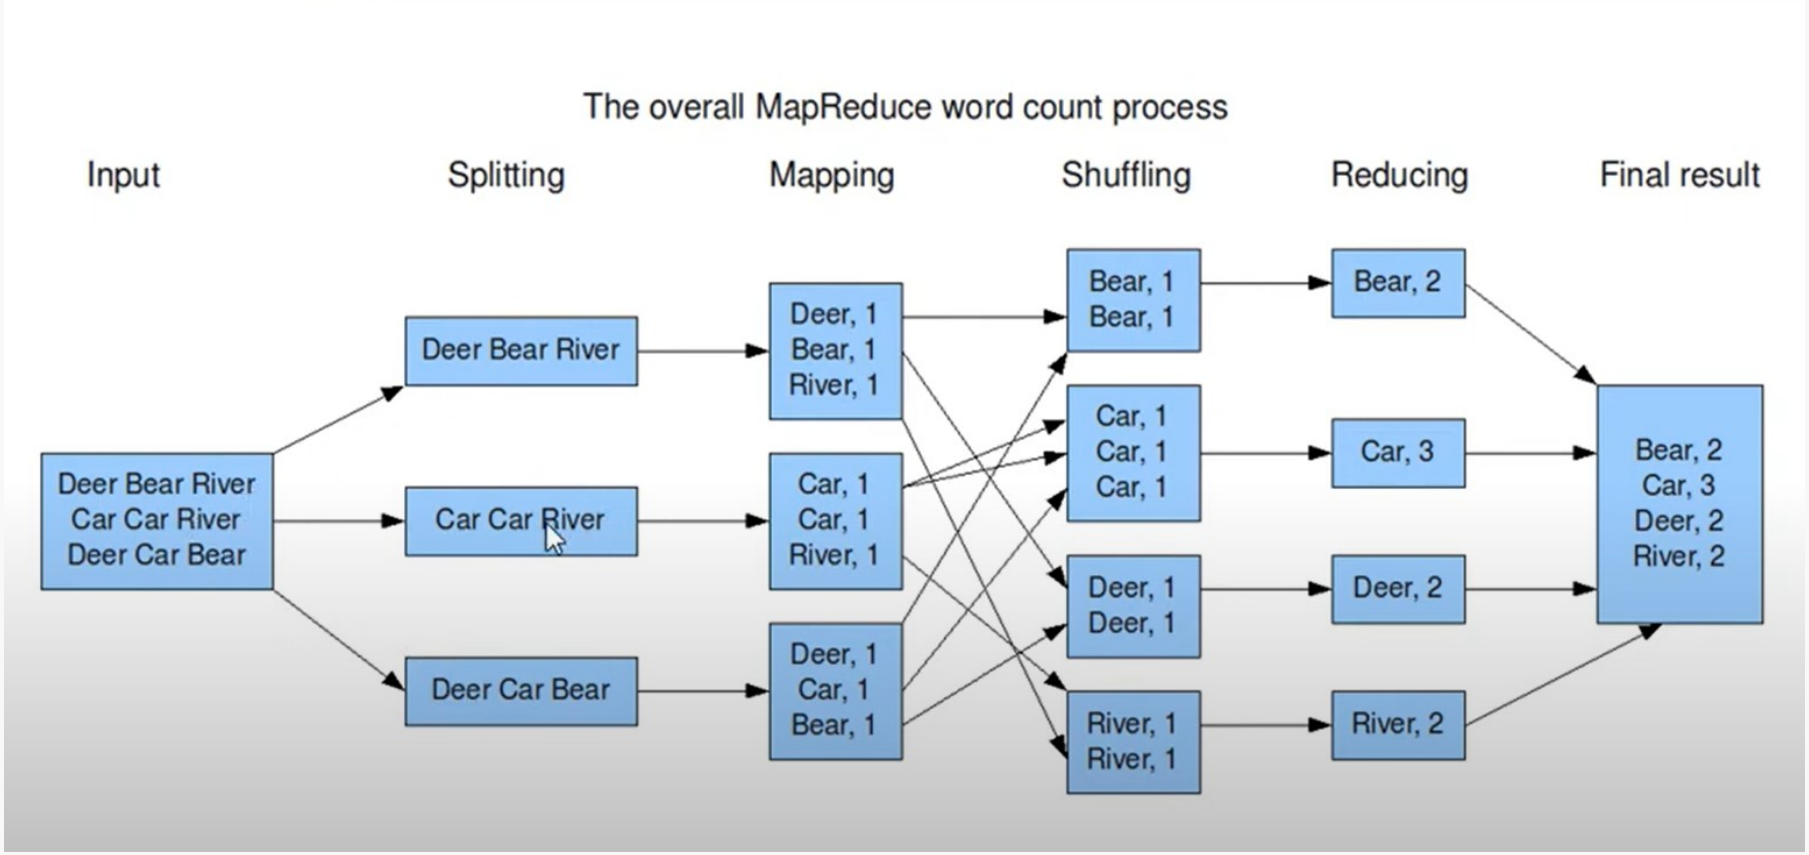

Arquitetura do MapReduce

Mapping – mapeia cada dado fazendo uma contagem do número de ocorrências.

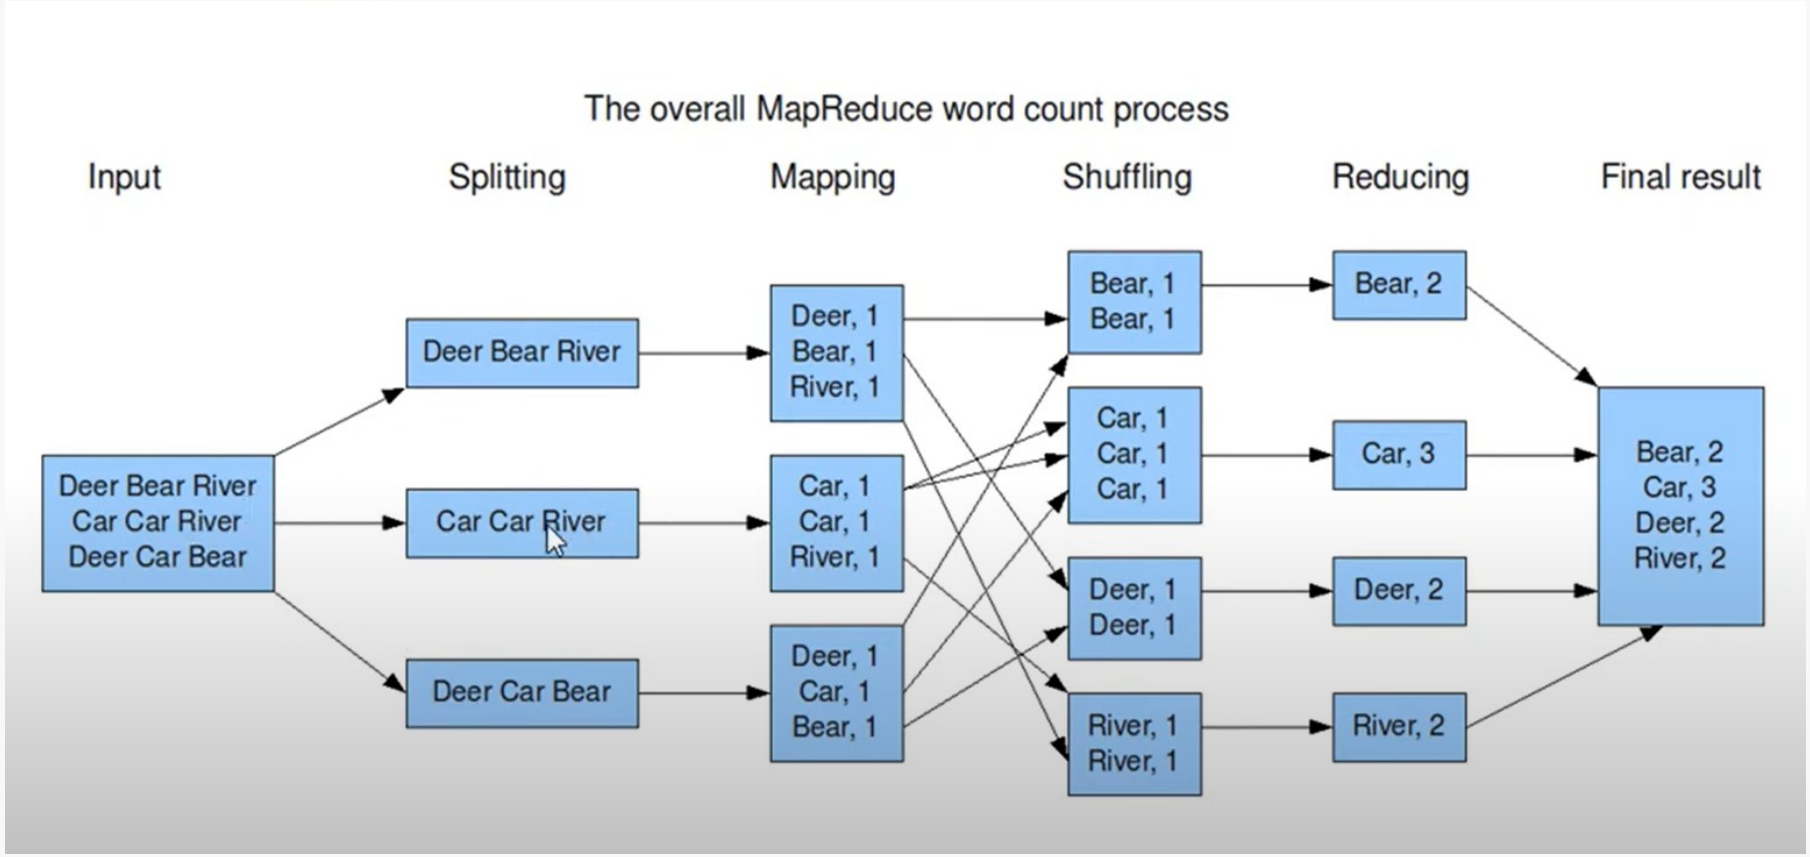

Arquitetura do MapReduce

Shuffling – É uma operação em que os dados são reorganizados em clusters (por afinidade, semelhanças). Veja que o exemplo agrupa as palavras iguais (ou que tenham a menor distância).

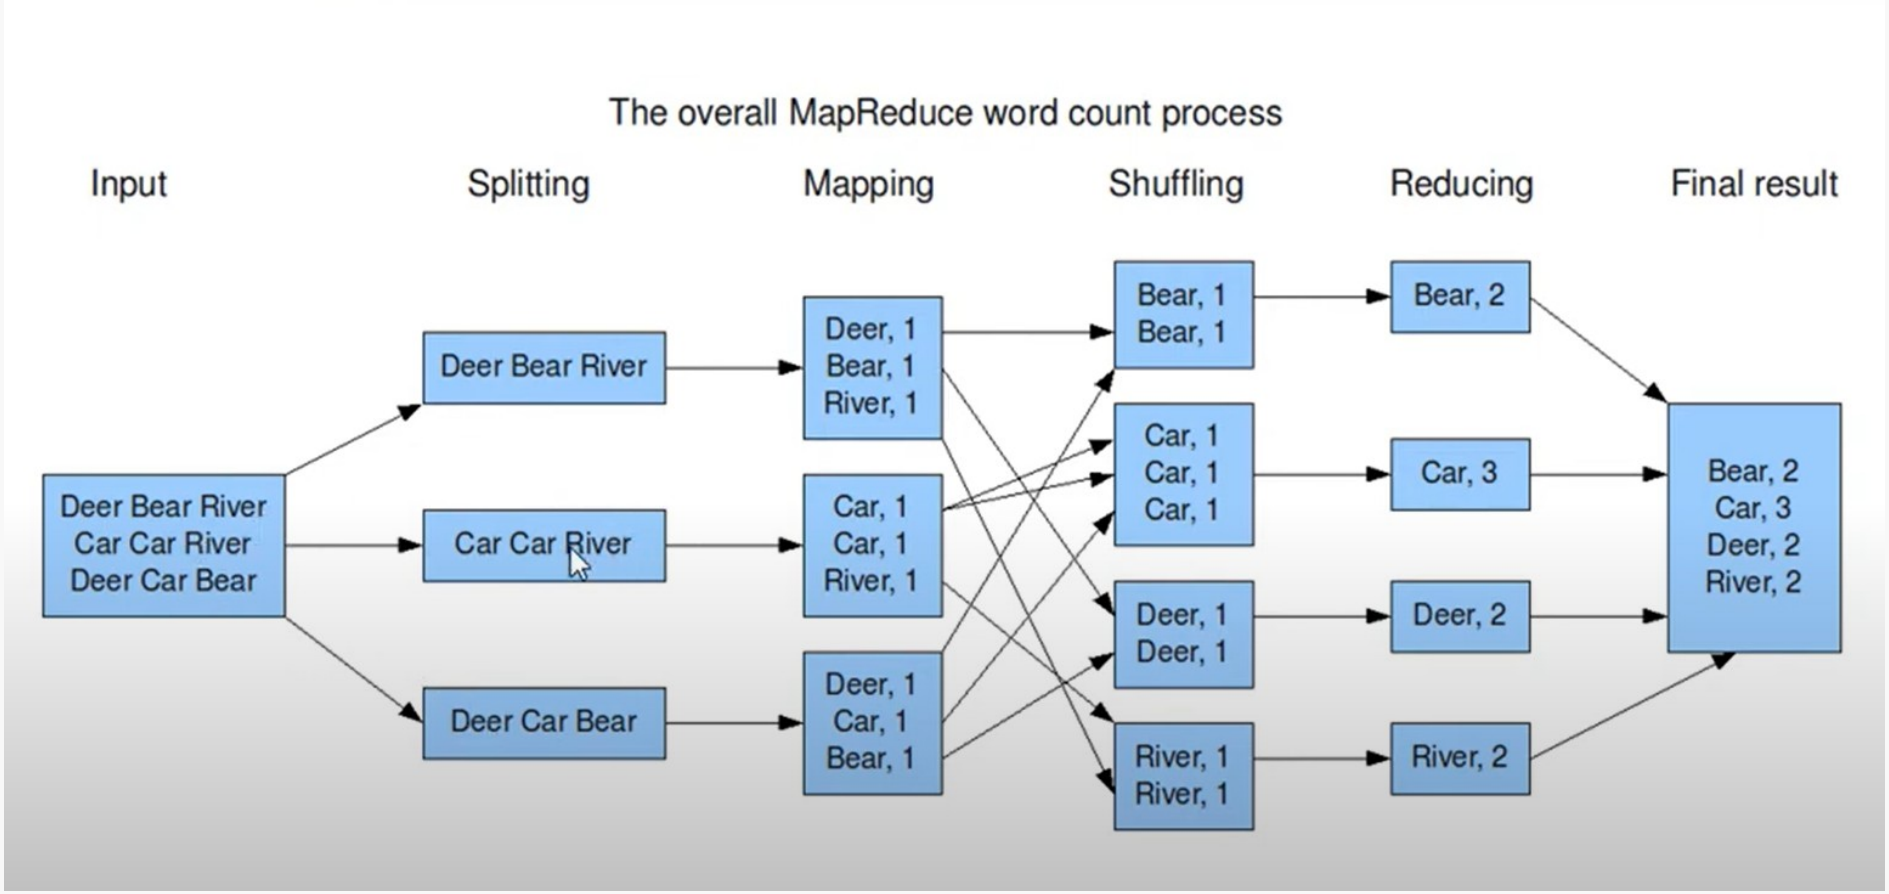

Arquitetura do MapReduce

Reducing – Faz uma agregação dos dados.

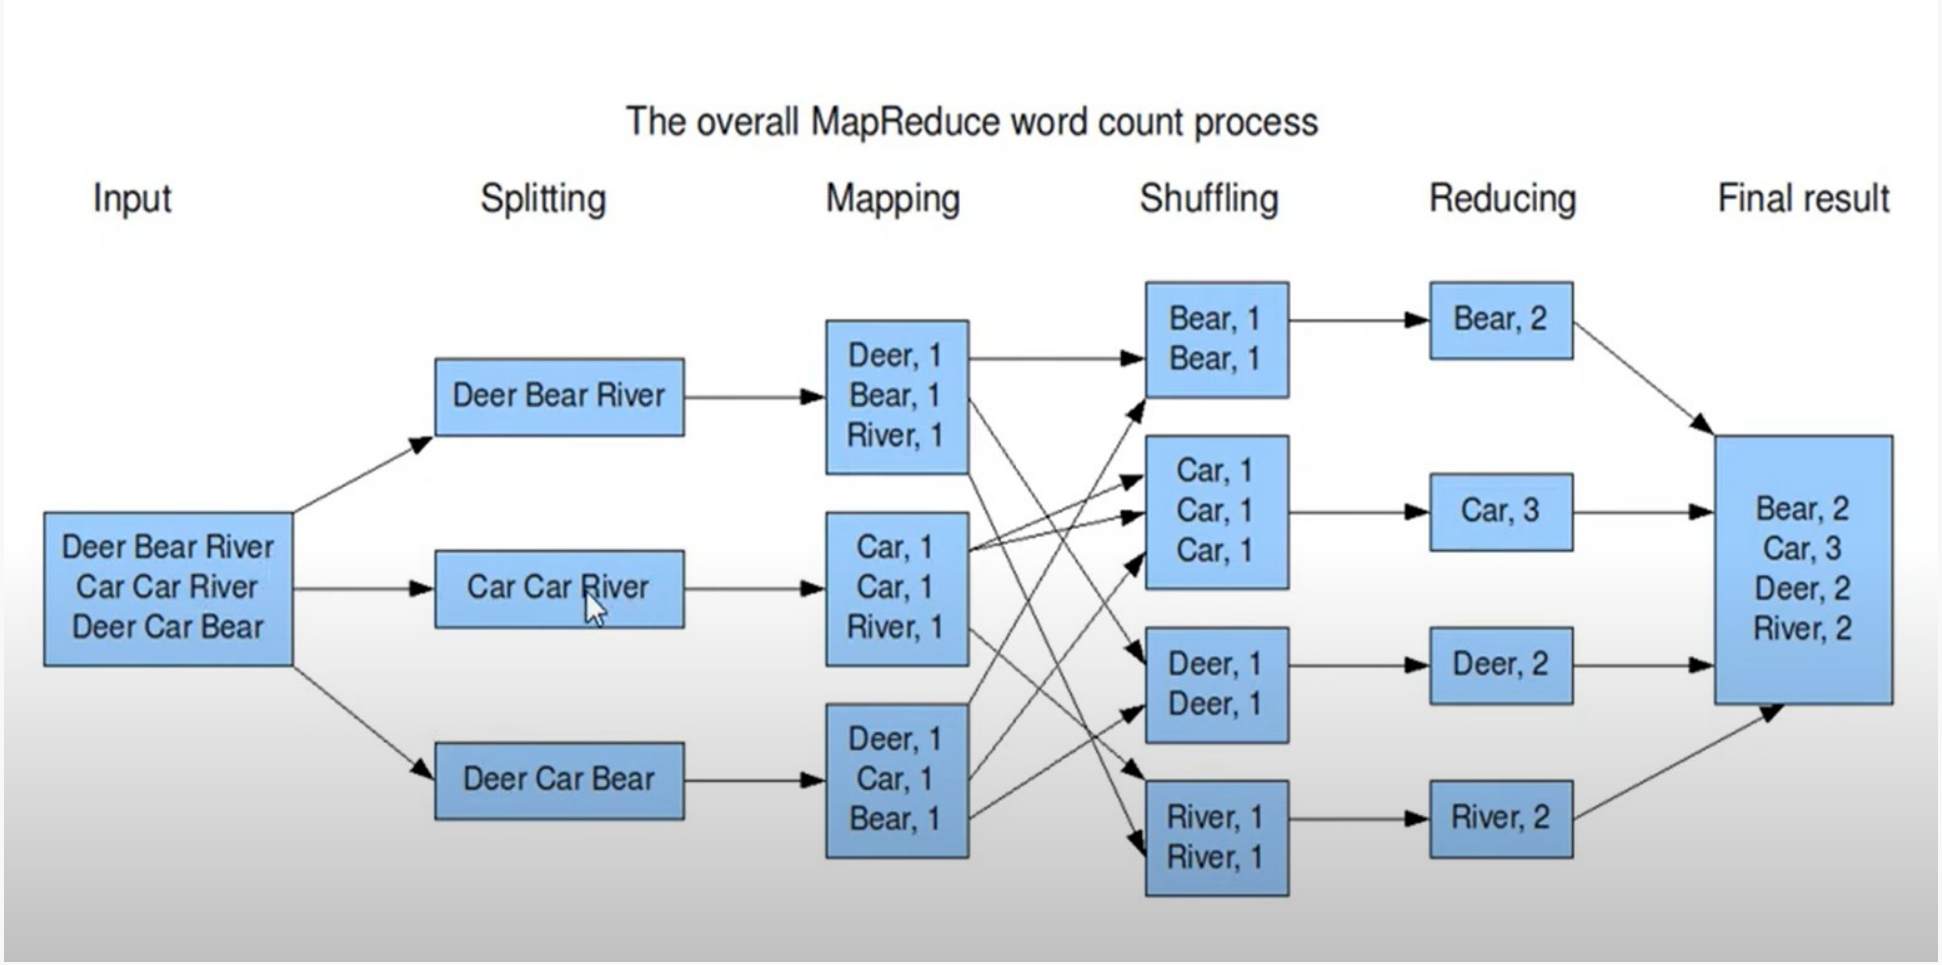

Arquitetura do MapReduce

Vantagem do funcionamento do MapReduce.

•Este tipo de solução está preparado para identificar se um novo bloco já foi armazenada e ao invés de transferir a mesma informação pela rede e replicar no HD, o mecanismo de Shuffing envia para o cluster que já tenha o dado processado, isso evita uma replicação de processamento completo do *Mapping* e do *Reducing*.

•A programação no Framework do MApReduce esconde toda esta complexidade de processamento.

•Framework é um conjunto de códigos prontos que servem como estrutura para auxiliar no desenvolvimento.

Arquitetura

- ***Yet Another Resource Negotiator* (YARN):** o YARN é responsável por gerenciar os recursos de computação em clusters. Ele realiza agendamento e alocação de recursos em todo o sistema Hadoop.
- Possui *Hadoop Common ou Core,* um conjunto de bibliotecas e utilitários dos quais os outros três módulos dependem.
- Os módulos do Hadoop são projetados para tratar as falhas de modo integrado e automatizado. Se um *cluster* falhar a solução pressupõe que a própria arquitetura consiga se resolver.

Casos de uso do HADOOP

- O Hadoop pode ser usado para processar logs gerados por aplicativos móveis e da web.
- É possível realizar a análise de dados utilizando uma solução semelhante ao SQL. Isso é possível através de um sistema integrado ao Hadoop, o Hive que transforma consultas em Jobs MapReduce.

Exercício para entregar na próxima aula.

a) Como é feita a organização dos dados no DW?

b) OLAP é um temo utilizado para descrever as análises de dados complexos a partir do DW. As ferramentas OLAP empregam as capacidades de computação distribuída para análises que requerem mais armazenamento e poder de processamento. Para este tipo solução podem ser usado computadores desktop doméstico?

c) Qual é a diferença entre ROLAP e MOLA P?

d) Um empresa que deseja processar um volume imenso de informações em paralelo para descoberto do conhecimento. Qual tipo de processamento de DW você sugere ?

e) Os DW possuem um esquema de tabela normalizado semelhante aos BD de processamento transacional sim ou não ? Explique?

f) A política de atualização do DW adota carga on line Sim ou não? Explique?

Exercícios para entregar na próxima aula.

- Cite ao menos três diferenças entre DW e Datalake.
- Cite duas diferenças entre o data lake e o data lakehouse.
- Escreva um resumo explicando como funciona o mecanismo de MapReduce.

Bibliografia

Fontes de consulta:

https://run.unl.pt/bitstream/10362/8403/1/TEGI0304.pdf

https://azure.microsoft.com/pt-br/resources/cloud-computing-dictionary/what-is-a-data-lake

https://azure.microsoft.com/pt-br/resources/cloud-computing-dictionary/what-is-a-data-warehouse

https://www.oracle.com/br/internet-of-things/what-is-iot/

https://www.dataside.com.br/dataside-community/big-data/data-lake-e-data-warehouse-do-conceito-a-arquitetura

https://azure.microsoft.com/pt-br/resources/cloud-computing-dictionary/what-is-a-data-lake

Livros

Fundamentals ofDatabaseSystems, 7thEdition
Ramez Elmasri& ShamkantB. Navathe
Pearson, 2016.

O Livro Completo da Engenharia de Dados
Aprenda com casos de uso do mundo real
https://www.databricks.com/br/resources/ebook/the-big-book-of-data-engineering (Download gratuito).

Dissertação de mestrado em estatística. Soraia Vanessa Moura Velho. -
https://run.unl.pt/bitstream/10362/8403/1/TEGI0304.pdf

Obrigado

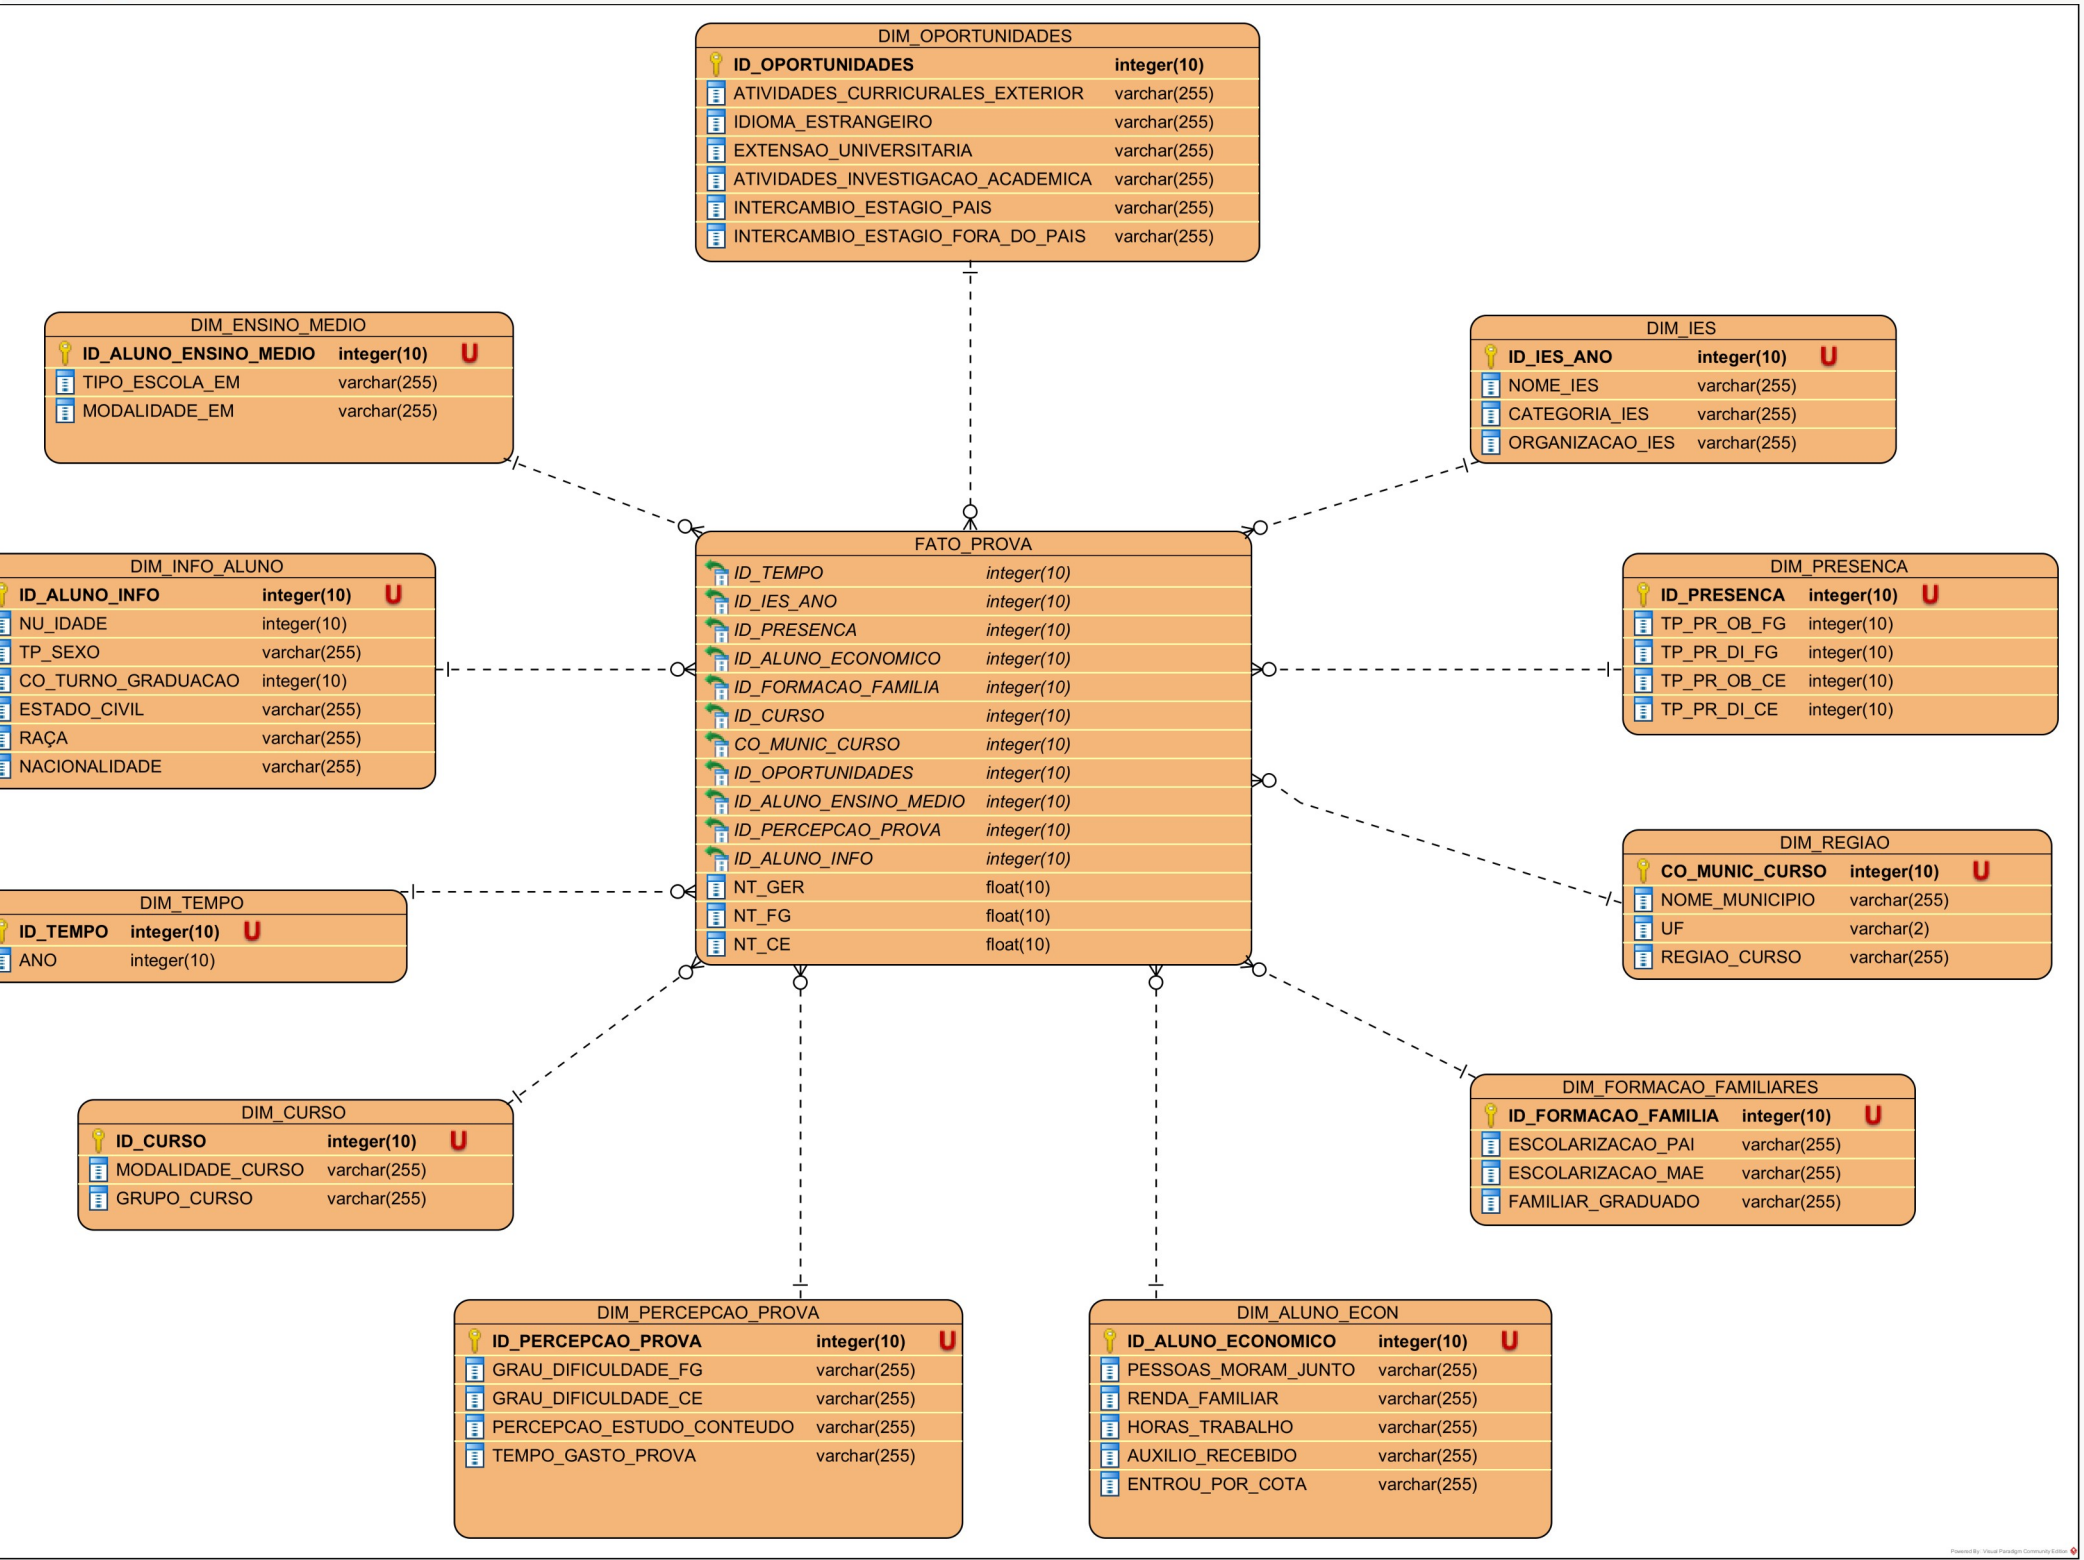
DIM_OPORTUNIDADES
ID_OPORTUNIDADES integer(10)
ATIVIDADES_CURRICURALES_EXTERIOR varchar(255)
IDIOMA_ESTRANGEIRO varchar(255)
EXTENSAO_UNIVERSITARIA varchar(255)
ATIVIDADES_INVESTIGACAO_ACADEMICA varchar(255)
INTERCAMBIO_ESTAGIO_PAIS varchar(255)
INTERCAMBIO_ESTAGIO_FORA_DO_PAIS varchar(255)
DIM_ENSINO_MEDIO
ID_ALUNO_ENSINO_MEDIO integer(10) U
TIPO_ESCOLA_EM varchar(255)
MODALIDADE_EM varchar(255)
DIM_IES
ID_IES_ANO integer(10) U
NOME_IES varchar(255)
CATEGORIA_IES varchar(255)
ORGANIZACAO_IES varchar(255)
DIM_INFO_ALUNO
ID_ALUNO_INFO integer(10) U
NU_IDADE integer(10)
TP_SEXO varchar(255)
CO_TURNO_GRADUACAO integer(10)
ESTADO_CIVIL varchar(255)
RAÇA varchar(255)
NACIONALIDADE varchar(255)
FATO_PROVA
ID_TEMPO integer(10)
ID_IES_ANO integer(10)
ID_PRESENCA integer(10)
ID_ALUNO_ECONOMICO integer(10)
ID_FORMACAO_FAMILIA integer(10)
ID_CURSO integer(10)
CO_MUNIC_CURSO integer(10)
ID_OPORTUNIDADES integer(10)
ID_ALUNO_ENSINO_MEDIO integer(10)
ID_PERCEPCAO_PROVA integer(10)
ID_ALUNO_INFO integer(10)
NT_GER float(10)
NT_FG float(10)
NT_CE float(10)
DIM_PRESENCA
ID_PRESENCA integer(10) U
TP_PR_OB_FG integer(10)
TP_PR_DI_FG integer(10)
TP_PR_OB_CE integer(10)
TP_PR_DI_CE integer(10)
DIM_TEMPO
ID_TEMPO integer(10) U
ANO integer(10)
DIM_REGIAO
CO_MUNIC_CURSO integer(10) U
NOME_MUNICIPIO varchar(255)
UF varchar(2)
REGIAO_CURSO varchar(255)
DIM_CURSO
ID_CURSO integer(10) U
MODALIDADE_CURSO varchar(255)
GRUPO_CURSO varchar(255)
DIM_FORMACAO_FAMILIARES
ID_FORMACAO_FAMILIA integer(10) U
ESCOLARIZACAO_PAI varchar(255)
ESCOLARIZACAO_MAE varchar(255)
FAMILIAR_GRADUADO varchar(255)
DIM_PERCEPCAO_PROVA
ID_PERCEPCAO_PROVA integer(10) U
GRAU_DIFICULDADE_FG varchar(255)
GRAU_DIFICULDADE_CE varchar(255)
PERCEPCAO_ESTUDO_CONTEUDO varchar(255)
TEMPO_GASTO_PROVA varchar(255)
DIM_ALUNO_ECON
ID_ALUNO_ECONOMICO integer(10) U
PESSOAS_MORAM_JUNTO varchar(255)
RENDA_FAMILIAR varchar(255)
HORAS_TRABALHO varchar(255)
AUXILIO_RECEBIDO varchar(255)
ENTROU_POR_COTA varchar(255)

DW DO ENADE

- DW criado a partir dos microdados do Enade disponibilizados pelo site do INEP. DW está baseado em dados de todos os estudantes que realizaram o exame no ano de 2017, 2018 e 2019. Criado pela Pela Litícia Tavares (Fonte: https://github.com/leticiatavaresds/Projeto_ENADE?tab=readme-ov-file).
- No presente trabalho foi utilizada a modelagem Estrela (Star Schema) caracterizada por poucas tabelas e relacionamentos, onde todas as tabelas de Dimensão se relacionam direta e unicamente com a tabela Fato, sendo assim um modelo simples e eficiente.
- O modelo elaborado neste trabalho foi desenvolvido com o intuito de ser centrado nas notas das provas (NT_FG – formação geral, NT_CE – conhecimento específico, NT_GER – nota geral), objetivando fornecer dados para análise de fatores que influenciam no desempenho de cada aluno que presta a avaliação. Dessa forma, o modelo apresenta como fato a prova que possui como métrica a nota final e as notas de formação geral incluindo seu componente específico, além de 11 tabelas de dimensão.

Exercícios prárticos - DW DO ENADE

- **(1)** Encontre a média da nota geral (FATO) para cada grupo de cursos (DIM_CURSO) e exiba as médias na ordem decrescente .
- **(2)** Encontre os cinco primeiros grupos de cursos de maior média geral.
- **(3)** Encontre a média geral do grupo do curso de medicina por sexo e raça (DIM_INFO_ALUNO) e exiba as médias na ordem decrescente.
- (4) Retorne o total de candidatos em cada instituição de ensino (DIM_IES) para o ano de 2019. O resultado deve exibir a instituição com menor número de candidatos primeiro.
- (5) Retorna uma lista contendo instituições de ensino que não tiveram candidatos em 2019.